

الجمهورية العربية السورية

المعهد العالي للعلوم التطبيقية و التكنولوجيا

قسم المعلومات – اختصاص برمجيات وذكاء صناعي

العام 2025 – 2026

مشروع أُعد لنيل إجازة الهندسة باختصاص هندسة البرمجيات والذكاء الصناعي

بعنوان

نظام مساعد لطبيب القلب لتشخيص أمراض القلب والأوعية الدموية اعتماداً على تقنيات
الذكاء الصناعي

AI-Based Cardiovascular Disease Diagnosis Support System for Cardiologists

إعداد :

أحمد أمين الكريان

إشراف :

د. ياسر رحال ما. عماد قرحيلي

الشكر

أتقدم بخالص الشكر إلى السادة المشرفين : الدكتور ياسر رحال والمهندس عماد قرحيلي لمساعدتهم في إنجاح هذا العمل ولتوجيهاتهم القيمة والنصائح المثمرة و المستمرة التي أغنت طريقة تنظيم العمل.

كما أتقدم بجزيل الشكر لرئيس قسم المعلومات الدكتور مصطفى الدقاق الذي لم يتوان عن دعمنا علمياً و معنوياً في كل لحظات هذه الرحلة الطويلة والشاقة والممتعة. كما أتقدم بالشكر لكل الزملاء و الأصدقاء الذين كانوا داعمين بحضورهم ومساعدتهم التي لا تقدر بثمن.

الإهداء

إلى كل من أحب، عائلتي، أخوتي، أصدقائي ...

الملخص

يتناول هذا المشروع تطوير نظام معلوماتي قادر على المساعدة في تشخيص أمراض القلب لدعم القرار الطبي للطبيب بالإعتماد على مصدرين للبيانات نتائج تخطيط القلب الكهربائي والبيانات السريرية المهيكلة (كالعمر، الجنس، ضغط الدم، مستوى الكوليسترول، وغيرها).

تم تصميم النظام بالإعتماد على أساليب التعلم الخاضع للإشراف Supervised Learning والتي تتيح تصنيف الحالات المرضية اعتماداً على بيانات مصنفة سابقاً تمكن النموذج من التعميم خارج نطاق بيانات التدريب .

تم دراسة خصائص مجموعات بيانات سريرية، واختيار فضاء سمات مناسب إضافة لدراسة خصائص صور لنتائج تخطيط القلب الكهربائي. تمت دراسة عدة منهجيات للتعلم الآلي، وتم انشاء نظام يجمع بين نموذج لتحليل صور تخطيط القلب باستخدام نماذج قوية في الرؤية الحاسوبية مبنية على الشبكات العصبية الالتفافية (CNN) لإستخراج الميزات من صور تخطيط القلب مثل ResNet , DensNet121 وخوارزميات تعلم الآلة لمعالجة البيانات السريرية المهيكلة منها (SVM - Gradient Boosting - Logistic Regression).

شمل المشروع تصميم معماري يستند لمبادئ البنية المعمارية متعددة الطبقات (Layerd Architecture) وتحليلاً وظيفياً لحالات الاستخدام تم تنفيذ موقع ويب تفاعلي يسمح للمستخدم (طبيب) بإدخال بيانات السريرية المهيكلة عبر نموذج إلكتروني أو رفع صورة تخطيط قلب، ليقوم النظام بتقديم تنبؤ بوجود أو عدم وجود مرض قلبي مع درجة الثقة.

وقد أجريت سلسلة من التجارب لتقييم أداء النماذج والنظام وأظهرت النتائج أن استخدام المصدرين معاً من البيانات في حال توافرها يؤدي إلى تحسين الأداء بشكل ملحوظ مقارنة باستخدام كل مصدر بمفرده مما يعزز أهمية التكامل بين الأنواع المختلفة من البيانات الطبية في رفع دقة التشخيص.

Abstract

This project focuses on developing an information system capable of aiding in the diagnosis of cardiac diseases to support physicians' decision-making. The system relies on two data sources: electrocardiogram (ECG) results and structured clinical data (such as age, sex, blood pressure, cholesterol levels, etc.).

The system was designed using supervised learning methods, which allow for the classification of medical conditions based on pre-classified data. This enables the model to generalize beyond the training dataset.

The characteristics of clinical datasets were studied, a suitable feature space was selected, and the characteristics of ECG imagery were analyzed. Several machine learning methodologies were studied, and a system was developed that combines an electrocardiogram (ECG) image analysis model using powerful computer vision models based on convolutional neural networks (CNNs) for feature extraction from ECG images, such as ResNet and DensNet121, with machine learning algorithms for processing structured clinical data, including Logistic Regression (SVM) and Gradient Boosting.

The project included an architectural design based on the principles of layered architecture and a functional analysis of use cases. An interactive website was implemented, allowing the user (doctor) to input their structured data via an electronic form or upload an ECG image. The system then provides a prediction of the presence or absence of cardiac disease, along with a confidence level and risk score. A series of experiments were conducted to evaluate the performance of the models and the system. The results showed that using both data sources together, when available, significantly improves performance compared to using each source alone. This reinforces the importance of integrating different types of medical data to enhance diagnostic accuracy.

فهرس المحتويات

8	فهرس الجداول
10	فهرس الأشكال
11	جدول المصطلحات
12	مقدمة عامة
13	الإطار العام للمشروع
13	1.1 أهداف المشروع
13	2.1 متطلبات النظام
13	1.2.1 المتطلبات الوظيفية
14	2.2.1 المتطلبات غير الوظيفية
15	الدراسة النظرية
15	1.2 أمراض القلب
16	1.1.2 مرض الشريان التاجي [4] (Coronary Artery Disease - CAD)
16	2.1.2 قصور القلب (Heart Failure)
17	3.1.2 اعتلال عضلة القلب (Cardiomyopathy) [2]
17	4.1.2 أمراض صمامات القلب (Valvular Heart Disease)
17	5.1.2 اضطرابات نظم القلب (Cardiac Arrhythmias)
17	عوامل خطر الإصابة بأمراض القلب [1]
18	2.2 تخطيط القلب الكهربائي (Electrocardiogram) [7]
18	أهمية تخطيط القلب في الطب
18	آلية توليد الإشارة الكهربائية في القلب
20	الفائدة السريرية للمساري المتعددة
21	3.2 الذكاء الصناعي
21	1.3.2 تعلم الآلة (Machine Learning (ML)
23	2.3.2 التعلم العميق ورؤية الحاسوب (Deep Learning & Computer Vision)

31.....	الدراسة المرجعية.....
1.3	التنبؤ بأمراض القلب والأوعية الدموية باستخدام خوارزميات تعلم الآلة (Predicting the Prevalence of Cardiovascular Diseases using Machine Learning Algorithms Sianga et al., 2025)
32....	نظرة عامة عن الدراسة.....
32.....	2.3 مقارنة خوارزميات التعلم الآلي للتنبؤ بأمراض القلب (Comparing some Machine Learning Models for Cardiovascular Disease)
34.....	3.3 الكشف عن أمراض القلب من خلال صور تخطيط القلب (Detection of Cardiovascular Diseases through ECG Images)
35.....	تحليل الدراسات السابقة.....
36.....	الدراسة التحليلية.....
38.....	1.4 حالات الاستخدام.....
38.....	1.1.4 مخطط حالات الاستخدام الخاصة بالطبيب.....
39.....	2.1.4 السرد النصي لحالات الاستخدام الأساسية للطبيب.....
39.....	حالة إدخال البيانات السريرية عبر تعبئة نموذج والحصول على تشخيص.....
41.....	حالة حفظ بيانات السريرية مع التشخيص.....
43.....	حالة رفع صورة تخطيط قلب وتحليلها.....
46.....	حالة عرض بيانات سريرية لمرضى سابقين.....
47.....	حالة إنشاء قالب تقرير طبي.....
50.....	تصميم النظام.....
50.....	1.5 المخطط العام للنماذج في النظام المقترح.....
51.....	2.5 مخطط النظام البرمجي المتكامل.....
51.....	1.2.5 التخزين في النظام.....
51.....	1.1.2.5 قاعدة البيانات.....
52.....	2.1.2.5 نظام ملفات يستخدم لتخزين البيانات السريرية للمرضى والتقارير الطبية.....
53.....	3.5 البنية المعمارية المعتمدة للنظام.....
53.....	1.3.5 البنية المتعددة الطبقات.....

53.....	1.1.3.5 خصائص النظام المبني وفق Layered Architecture
55.....	2.3.5 بنية النظام
57.....	النظام الذكي وتحديد المنهجية وتطبيقها
57.....	1.6 آلية العمل
57.....	1.1.6 النماذج الخاصة بالبيانات السريية
57.....	1.1.1.6 مجموعة البيانات الأولى
60.....	2.1.1.6 مجموعة البيانات الثانية
65.....	2.1.6 نماذج الخاصة بتخطيط الكهربي القلب
65.....	1.2.1.6 مجموعة البيانات الأولى
71.....	تجارب على نماذج التعلم
71.....	1.7 معايير تقييم النتائج
72.....	2.7 تجارب مجموعة البيانات (ECG Analysis)
80.....	3.7 تجارب مجموعة البيانات Cardiovascular Disease Dataset
85.....	4.7 تجارب مجموعة البيانات Heart Disease Dataset
97.....	الأدوات المستخدمة
101.....	التنجز البرمجي لنظام الويب
101.....	1.9 البنية المستخدمة في التنجز
101.....	2.9 طبقات النظام المنجز
104.....	3.9 أهم الأنماط التصميمية المستخدمة في بناء النظام
108.....	4.9 اختبارات النظام
110.....	الخاتمة والآفاق المستقبلية
111.....	المراجع

فهرس الجداول

19.....	الجدول 1 موجات تخطيط القلب
20.....	الجدول 2 المسارات في تخطيط القلب
21.....	الجدول 3 ما يكشفه تخطيط القلب
34.....	الجدول 4 نتائج التجربة
35.....	الجدول 5 نتائج التجارب
36.....	الجدول 6 نتائج التجارب
39.....	الجدول 7 السيناريو الناجح للحالة
40.....	الجدول 8 المسار البديل الأول
40.....	الشكل 9 المسار البديل الثاني
42.....	الجدول 10 السيناريو الناجح للحالة
42.....	الجدول 11 المسار البديل الأول
44.....	الجدول 12 السيناريو الناجح للحالة
44.....	الجدول 13 المسار البديل الأول
45.....	الجدول 14 المسار البديل الأول
46.....	الجدول 15 السيناريو الناجح للحالة
46.....	الجدول 16 المسار البديل الأول للحالة
48.....	الجدول 17 السيناريو الناجح للحالة
48.....	الجدول 18 المسار البديل الأول
57.....	الجدول 19 الميزات في مجموعة البيانات
60.....	الجدول 20 مجموعات الميزات المختارة
61.....	الجدول 21 الميزات في مجموعة البيانات
61.....	الجدول 22 الميزات في مجموعة البيانات
64.....	الجدول 23 مجموعات الميزات المختارة
67.....	الجدول 24 تحليل الصور المكررة
69.....	الجدول 25 قيم معدل التعلم في التجارب
73.....	الجدول 26 نتائج التجربة الأولى
74.....	الجدول 27 نتائج التجربة الثانية

76.....	الجدول 29 نتائج التجربة الثالثة
77.....	الجدول 30 نتائج التجربة الرابعة
78.....	الجدول 31 نتائج التجربة الخامسة
78.....	جدول 32 النتائج حسب الفئة
79.....	الجدول 33 نتائج التجربة السادسة
80.....	الجدول 34 النتائج حسب الفئة
81.....	الجدول 35 نتائج التجربة الأولى
81.....	الجدول 36 نتائج التجربة الثانية
82.....	الجدول 37 نتائج التجربة الثالثة
82.....	الجدول 38 نتائج التجربة الرابعة
83.....	الجدول 39 نتائج التجربة الخامسة
84.....	الجدول 40 نتائج التجربة السادسة
84.....	الجدول 41 مقارنة بين الخوارزميات
85.....	الجدول 42 نتائج التجربة الأولى
87.....	الجدول 43 نتائج التجربة الثانية
88.....	الجدول 44 نتائج التجربة الثالثة
90.....	الجدول 45 نتائج التجربة الرابعة
91.....	الجدول 46 نتائج التجربة الخامسة
93.....	الجدول 47 نتائج التجربة السادسة
95.....	نتائج التجربة السابعة 48 الجدول
96.....	الجدول 49 مقارنة عامة لافضل النماذج

فهرس الأشكال

19	الشكل 1 النبضة في تخطيط القلب
22	الشكل 2 آلة المتجهات الداعمة
25	الشكل 3 شبكة الالتفافية
26	الشكل 4 بنية الشبكة الكثيفة
27	الشكل 5 بنية الشبكة المتبقية
28	الشكل 6 بنية EfficientNet
30	رسم توضيحي 7 الشكل بنية MobileNet
33	الشكل 8 المنهجية المتبعة
38	الشكل 9 مخطط حالات الاستخدام
41	الشكل 10 مخطط تتالي النظام
43	الشكل 11 مخطط تتالي النظام
46	الشكل 12 مخطط تتالي النظام
47	الشكل 13 مخطط تتالي النظام
49	الشكل 14 مخطط تتالي النظام
51	الشكل 15 مخطط الصندوقي للنماذج في النظام
52	الشكل 16 مخطط الصفوف
53	الشكل 17 نظام الملفات
54	الشكل 18 التبعية بين الطبقات
56	الشكل 19 مخطط النظام
72	الشكل 20 مصفوفة الارتباك
73	الشكل 21 بعض الصور بعد تطبيق تقنيات زيادة البيانات
101	الشكل 22 بنية التطبيق
105	الشكل 23 واجهة ادخال البيانات السريرية
105	الشكل 24 واجهة رفع صورة تخطيط القلب
106	الشكل 25 واجهة النتائج التي قدمها النموذج من تحليل الصورة
106	الشكل 26 واجهة التقارير الطبية
107	الشكل 27 واجهة انشاء قالب تقرير طبي

الشكل 28 التقرير الطبي المصدر بصيغة pdf	107
الشكل 29 نتائج اختبارات الوحدة	108
الشكل 30 نتائج اختبارات التكامل	109
الشكل 31 نتائج اختبارات E2E	109

جدول المصطلحات

المصطلح	المعنى
Cardiovascular Diseases (CVD)	أمراض القلب والجهاز الوعائي
Myocardial Infarction (MI)	احتشاء عضلة القلب
Atrial Fibrillation	الرجفان الأذيني
Hypertension	ارتفاع ضغط الدم
Convolutional Neural Network (CNN)	الشبكة العصبية الالتفافية
FineTuning	الضبط الدقيق
Comma-Separated Values (CSV)	قيم مفصولة بالفاصلة
Precision	الموثوقية
Layerd Architecture	البنية المتعددة الطبقات
ROC Curve	منحنى خصائص تشغيل المستقبل
Epoch	الدورة
Electrocardiogram (ECG)	تخطيط القلب الكهربائي
Dropout	التسرب العشوائي
Batch Normalization	تطبيع الدفعات
ImageNet	قاعدة بيانات ضخمة للصور
Contrast Limited Adaptive Histogram Equalization (CLAHE)	تقنية لتحسين التباين المحلي للصور
SQLite	نظام إدارة قاعدة بيانات خفيف الوزن
Gradient	التدرج

مقدمة عامة

تُعد أمراض القلب والجهاز الوعائي (Cardiovascular Diseases) السبب الرئيسي للوفيات على مستوى العالم، حيث تشير إحصاءات منظمة الصحة العالمي (WHO) إلى أنها تتسبب في حوالي 19 مليون وفاة سنوياً، ما يمثل 32% من مجموع الوفيات العالمية. من بين هذه الوفيات، تحدث أكثر من 85% بسبب النوبات القلبية والسكتات الدماغية، والتي كان يمكن الوقاية منها أو التعامل معها بشكل أفضل في حال توفر تشخيص مبكر ودقيق. مع تزايد عبء هذه الأمراض على الأنظمة الصحية، خاصة في البلدان النامية، تبرز الحاجة الملحة إلى تطوير أدوات مساعدة في التشخيص تكون سريعة، منخفضة التكلفة، وقابلة للتطبيق على نطاق واسع. [1]

لا تزال أمراض القلب والسكتات الدماغية تشكل عبئاً كبيراً على أنظمة الرعاية الصحية، خاصة في طب الطوارئ وإدارة الأمراض المزمنة طويلة الأمد. يُعد الكشف المبكر عن التشوهات القلبية أمراً ضرورياً لأن العلاج في الوقت المناسب يمكن أن يقلل بشكل كبير من المضاعفات، ويحسن معدلات البقاء على قيد الحياة يُعد التخطيط الكهربائي للقلب (ECG) من أكثر الأدوات التشخيصية استخداماً في طب القلب. فهو غير مكلف، وغير جراحي، وسريع، ومتاح في المستشفيات والعيادات وسيارات الإسعاف وبيئات الرعاية الصحية. توفر تسجيلات مخطط كهربية القلب معلومات قيمة عن نظم القلب، والتوصيل الكهربائي، ونقص تروية عضلة القلب، والإحشاء، وتشوهات إعادة الاستقطاب، والتلف القلبي. ومع ذلك، يتطلب تفسير مخطط كهربية القلب خبرة طبية، وقد تكون المراجعة اليدوية مستهلكة للوقت عند التعامل مع أعداد كبيرة من سجلات مخطط كهربية القلب.

تعتمد العملية التشخيصية لأمراض القلب حالياً بشكل كبير على خبرة الطبيب المختص وقدرته على تفسير الأعراض السريرية للمريض بالإضافة إلى نتائج الفحوصات المختلفة، وأهمها تخطيط القلب الكهربائي (Electrocardiogram) إلا أن تفسير إشارات تخطيط القلب يعد مهمة معقدة تتطلب تدريباً مكثفاً، إذ قد تكون التغيرات في الموجات دقيقة أو غير نمطية، خاصة في المراحل المبكرة من المرض. تشير الدراسات إلى أن التشخيص البشري لتخطيط القلب يمكن أن يظهر حساسية محدودة تتراوح بين 60% و 80% في بعض الحالات، مما يؤدي إلى حالات من الخطأ التشخيصي إما بإغفال وجود مرض (سلبية كاذبة) أو بالتشخيص الخاطئ لمرض غير موجود (إيجابية كاذبة)، وكلاهما يحمل تبعات سريرية خطيرة. [2]

في العقد الأخير، حققت تقنيات الذكاء الاصطناعي، وخاصة التعلم الآلي والتعلم العميق، تقدماً هائلاً في المجال الطبي بشكل عام وفي تحليل الإشارات الحيوية بشكل خاص. لقد أثبتت النماذج التعليمية قدرتها على استخراج أنماط خفية من إشارات تخطيط القلب قد لا تكون مرئية للعين البشرية، وتحقيق دقة تشخيصية تضاهي أو حتى تتفوق على الأطباء المختصين في مهام محددة مثل كشف الرجفان الأذيني أو احتشاء عضلة القلب. كما أظهرت الأبحاث الحديثة أن دمج مصادر بيانات متعددة كإشارة تخطيط القلب مع البيانات السريرية للمريض يؤدي إلى تحسين الأداء بشكل ملحوظ مقارنة باستخدام كل مصدر بمفرده. وهذا هو الأساس الذي يقوم عليه هذا المشروع، حيث يهدف إلى بناء نظام معلوماتي يقوم بتحليل إشارة تخطيط القلب أو البيانات السريرية المهيكلة لتقديم تشخيص مساعد أكثر دقة وموثوقية. [3]

الفصل الأول

الإطار العام للمشروع

تهدف في هذه الفصل الى عرض تعريف عام للمشروع وذكر الدوافع والهدف الذى نسعى إليه ويتم ذلك من خلال تحديد أهداف المشروع والإشارة إلى المتطلبات الوظيفية وغير الوظيفية الخاصة بالمشروع .

1.1 أهداف المشروع

يهدف هذا المشروع إلى بناء نظام معلوماتي متكامل للمساعدة في تشخيص أمراض القلب، وذلك من خلال تحليل مصدرين رئيسيين للبيانات الطبية هما البيانات السريرية المهيكلية وصور تخطيط الكهربي للقلب من خلال توظيف التطورات الأخيرة في مجال تعلم الآلة وخاصة التعلم العميق في معالجة الصور ودراسة خصائص مجموعات البيانات المستخدمة إضافة لدراسة فضاءات السمات الممكن استخدامها وتطبيق منهجيات التعلم الآلي التقليدي والعميق واختيار الخوارزمية الأنسب لكل نوع من أنواع البيانات وصولاً لنماذج قادرة على تصنيف صور تخطيط القلب وأخرى لتصنيف المرضى اعتماداً على بيانات سريرية خاصة بهم عبر آليات التعلم الخاضع للإشراف وبالإضافة لمقارنة أداء النماذج لمصدري البيانات ودمج النماذج ضمن تطبيق برمجي (تطبيق ويب) يسمح للمستخدمين (أطباء) برفع صور تخطيط كهربي للقلب أو إدخال البيانات السريرية للمرضى والحصول على نتائج تشخيص ودرجة ثقة ومستوى خطورة بالإضافة لتمكين الطبيب من إنشاء قوالب لتقارير طبية وإدارتها حيث جرت مراعاة الأسس والمبادئ الخاصة في هندسة البرمجيات وصولاً لتطبيق قابل للتوسع وسهل الصيانة.

2.1 متطلبات النظام

نبيّن فيما يلي المتطلبات الوظيفية وغير الوظيفية للنظام .

1.2.1 المتطلبات الوظيفية

يتيح النظام لطبيب القلب الوظائف التالية:

1. استعراض نماذج الذكاء الصناعي المتاحة واختيار النموذج المناسب وفقاً لنوع البيانات المتوفرة للمريض.
2. إدخال البيانات السريرية الخاصة بالمريض عبر تعبئة نموذج والحصول على نتيجة التشخيص.
3. رفع ملف يحوي البيانات السريرية الخاصة بالمريض والحصول على نتيجة التشخيص.
4. عرض نتيجة التنبؤ للحالة المرضية مع نسبة الثقة لكل تشخيص متوقع مع مستوى خطورة.
5. تمكين الطبيب من مراجعة التشخيص الناتج وتعديل التشخيص النهائي للبيانات المهيكلية عند الحاجة.
6. تصدير البيانات السريرية للمريض ونتائج التشخيص إلى ملف خارجي Csv.

7. حفظ التشخيص النهائي المعتمد من الطبيب مع بيانات السريية للمريض في ملف Csv.
8. عرض البيانات السريية لمرضى سابقين.
9. رفع صورة لتخطيط القلب والحصول على تشخيص مع نسبة ثقة .
10. إدارة قالب التقرير الطبي يتضمن إنشاء وتعديل وحذف قالب التقرير الطبي .
11. إدارة التقرير الطبي يتضمن إنشاء وتعديل وحذف التقرير الطبي.

2.2.1 المتطلبات غير الوظيفية

1. بساطة الاستخدام عن طريق تصميم واجهات متجاوبة وبسيطة واضحة يمكن التنقل بينها بسهولة.
2. زمن الاستجابة : يجب أن لا يتجاوز زمن التنبؤ بعد ادخال البيانات السريية / الصور 5 ثوان .
3. إمكانية تشغيل الموقع على المتصفحات (Chrome , Edge , Firefox) وعلى أجهزة الكمبيوتر المكتبية والمحمولة .

الفصل الثاني

الدراسة النظرية

تقدم هذه الدراسة النظرية شرحاً مختصراً ومفيداً للمفاهيم الأساسية التي يقوم عليها هذا المشروع، وهي: امراض القلب ، تخطيط القلب الكهربائي، التعلم الآلي التقليدي، التعلم العميق.

1.2 أمراض القلب

أمراض القلب والاعوية الدموية [1] (Cardiovascular Disease – CVD) هي مجموعة من الحالات المرضية التي تصيب القلب والاعوية الدموية، حيث يمثل القلب العضلة المسؤولة عن ضخ الدم المحمل بالأكسجين والمواد المغذية إلى جميع أنسجة وأعضاء الجسم. عندما يصاب القلب بأي خلل – سواء كان في بنيته، أو في صماماته أو في أوعيته، أو في نظامه الكهربائي – فإن قدرته على أداء وظيفته الحيوية تضعف، مما قد يؤدي إلى مضاعفات خطيرة تصل إلى الوفاة. [2]

احتشاء عضلة القلب

احتشاء عضلة القلب، المعروف باسم النوبة القلبية، يحدث عندما ينخفض أو ينقطع تدفق الدم إلى جزء من عضلة القلب، مما يؤدي إلى إصابة عضلة القلب أو نخر الأنسجة. قد تشمل نتائج مخطط كهربية القلب ارتفاع مقطع ST، وانخفاض ST، وانعكاس موجة T وموجات Q المرضية، أو تغيرات في التوصيل اعتماداً على موقع الاحتشاء ومرحلته. يُعد التحديد السريع لاحتشاء عضلة القلب أمراً بالغ الأهمية سريرياً لأن التأخير في التشخيص قد يؤدي إلى فشل القلب، وعدم انتظام ضربات القلب، والصدمة القلبية، أو الوفاة. يمكن لتصنيف صور مخطط كهربية القلب الآلي أن يساعد الأطباء من خلال الإشارة إلى سجلات مخطط كهربية القلب المشبوهة للمراجعة العاجلة، خاصة في بيئات الطوارئ والطب عن بُعد. [4]

2.2. نبض القلب غير الطبيعي

يشير نبض القلب غير الطبيعي إلى نظم قلبي غير منتظم، يُوصف عادةً باسم عدم انتظام ضربات القلب. قد يشمل ذلك تسارع القلب، وبطء القلب، والرجفان الأذيني، والانقباضات البطينية المبكرة، والانقباضات الأذينية المبكرة، واضطرابات التوصيل. قد تشمل سمات مخطط كهربية القلب للنظم غير الطبيعي فترات R-R غير منتظمة، وشكل موجة P غير طبيعي، وغياب موجات P، ومجمعات QRS المتسعة، أو أنماط معدل ضربات القلب غير الطبيعية. بعض اضطرابات النظم حميدة، بينما قد يكون البعض الآخر مهدداً للحياة ويتطلب تدخلاً طبياً فوراً. تم استكشاف أساليب التعلم العميق والتعلم الآلي على نطاق واسع للكشف عن عدم انتظام ضربات القلب لأن أنماط نظم مخطط كهربية القلب غالباً ما تحتوي على توقيعات تشخيصية قوية [5]، [6].

2.3. تاريخ احتشاء عضلة القلب

يشير تاريخ احتشاء عضلة القلب إلى المرضى الذين عانوا سابقاً من نوبة قلبية. قد تظهر سجلات مخطط كهربية القلب لديهم تشوهات مستمرة ناجمة عن تندب عضلة القلب أو تلف الأنسجة السابق. قد تشمل هذه التغيرات موجات Q المرضية، وأنماط إعادة استقطاب غير طبيعية، وتغيرات ST-T المتبقية، أو اضطرابات التوصيل. يُعد التمييز بين احتشاء عضلة القلب الحالي واحتشاء عضلة القلب السابق مهماً سريرياً لأن قرارات العلاج تختلف. قد يتطلب الاحتشاء الحالي علاجاً لإعادة تروية عاجلاً، بينما قد يتطلب الاحتشاء السابق مراقبة طويلة الأمد، وأدوية، وإدارة المخاطر. [7]

2.4. مخطط كهربية القلب الطبيعي

يمثل مخطط كهربية القلب الطبيعي نشاطاً كهربائياً صحياً أو غير شاذ سريرياً للقلب. يتضمن عادةً نظم الجيوب الأنفية المنتظم، وموجات P طبيعية، ومجموعات QRS ضيقة، ومقاطع ST طبيعية، وفترات QT مقبولة. تعد الفئة الطبيعية ضرورية في أنظمة التصنيف لأنها توفر مجموعة مرجعية للتمييز بين سجلات مخطط كهربية القلب المريضة وغير المريضة. في أنظمة الذكاء الاصطناعي الطبية، تُعد الدقة العالية في تحديد سجلات مخطط كهربية القلب الطبيعية أمراً مهماً لتقليل الإنذارات الكاذبة وتجنب عبء العمل السريري غير الضروري. ومع ذلك، يجب على النموذج أيضاً تجنب تصنيف مخططات كهربية القلب غير الطبيعية بشكل خاطئ على أنها طبيعية، لأن النتائج السلبية الكاذبة قد تحمل مخاطر سريرية خطيرة. [8]

1.1.2 مرض الشريان التاجي (Coronary Artery Disease – CAD) [4]

يحدث بسبب تراكم اللويحات (الكوليسترول والدهون) على الجدران الداخلية للشرايين التاجية التي تغذي عضلة القلب بالدم. يؤدي هذا التراكم إلى تضيق الشرايين، مما يقلل تدفق الدم الغني بالأكسجين إلى عضلة القلب. من أنواعه:

- الذبحة الصدرية (Angina Pectoris): ألم أو انزعاج في الصدر يحدث عندما لا يحصل القلب على كمية كافية من الدم.
- احتشاء عضلة القلب (Myocardial Infarction): النوبة القلبية موت جزء من عضلة القلب بسبب انسداد كامل للشريان التاجي.

2.1.2 قصور القلب (Heart Failure)

يعني أن القلب غير قادر على ضخ كمية كافية من الدم لتلبية احتياجات الجسم. يمكن أن يكون قصور القلب حاداً (يحدث فجأة) أو مزمنياً (يتطور تدريجياً).

3.1.2 اعتلال عضلة القلب (Cardiomyopathy) [2]

هو مرض يصيب عضلة القلب نفسها، مما يجعلها متضخمة، أو متصلبة، أو سميكة، أو متوسعة.

4.1.2 أمراض صمامات القلب (Valvular Heart Disease)

يحتوي القلب على أربعة صمامات تتحكم في تدفق الدم. تصاب هذه الصمامات إما بالتضيق (لا تفتح بالكامل) أو القلس (لا تغلق بإحكام).

5.1.2 اضطرابات نظم القلب (Cardiac Arrhythmias)

يحدث اضطراب النظم عندما تكون النبضات الكهربائية التي تنسق نبضات القلب غير منتظمة، مما يجعل القلب ينبض بسرعة كبيرة جداً (تسرع القلب)، أو يبطئ شديد (بطء القلب)، أو بشكل غير منتظم. الأنواع:

- الرجفان الأذيني - Atrial Fibrillation: النوع الأكثر شيوعاً، وفيه تنبض الأذنان بشكل غير منتظم وسريع جداً.
- تسرع القلب البطيني - Ventricular Tachycardia: نبض سريع ينشأ من البطينين، ويكون خطيراً جداً.
- الانقباض المبكر: نبضات إضافية مبكرة تعطل النظم الطبيعي.

عوامل خطر الإصابة بأمراض القلب [1]

1. عوامل خطر لا يمكن السيطرة عليها مثل: التقدم في العمر - الجنس - التاريخ العائلي للمرض - العرق - الجينات الوراثية.
2. عوامل خطر يمكن السيطرة عليها مثل: ارتفاع ضغط الدم - ارتفاع الكوليسترول - التدخين - السكري - السمنة وغيرها.

أعراض امراض القلب

- ضيق التنفس
- ألم أو انزعاج في الصدر (الذبحة الصدرية)
- خفقان القلب
- دوخة أو اغماء.
- تورم في الساقين والكاحلين. [5]

2.2 تخطيط القلب الكهربائي (Electrocardiogram) [7]

تخطيط القلب الكهربائي (Electrocardiogram – ECG) هو تسجيل بياني للنشاط الكهربائي للقلب عبر الزمن. يتم الحصول على هذا التسجيل بوضع أقطاب كهربائية (Electrodes) على جلد الصدر والأطراف. تلتقط هذه الأقطاب الإشارات الكهربائية الدقيقة جداً بضعة ملي فولت millivolts الناتجة عن إزالة الاستقطاب (Depolarization) وعودة الاستقطاب (Repolarization) لخلايا عضلة القلب أثناء كل نبضة. [6]

أهمية تخطيط القلب في الطب [1]

- غير باضع أي لا يتطلب أي شقوق جراحية أوأبر.
- سريع و منخفض التكلفة.
- قابل للتكرار وغني بالمعلومات يمكن اكتشاف العديد من الحالات المرضية بواسطته.

آلية توليد الإشارة الكهربائية في القلب [5]

تتم عملية توليد ونقل الإشارة الكهربائية في القلب عبر خمس مراحل متسلسلة:


المرحلة الأولى: العقدة الجيبية الأذينية (Sinoatrial Node – SA Node) توجد العقدة الجيبية في الجدار العلوي للأذين الأيمن، وتعتبر منظم ضربات القلب الطبيعي. تطلق العقدة الجيبية نبضة كهربائية بشكل منتظم تلقائياً بتردد يتراوح بين 60 و 100 نبضة في الدقيقة عند البالغين أثناء الراحة.

المرحلة الثانية: انتشار النبضة في الأذنين تنتشر النبضة الكهربائية من العقدة الجيبية عبر عضلة الأذنين بسرعة، مسببة إزالة استقطاب الأذنين وانقباضهما لضخ الدم إلى البطينين. هذا الحدث الكهربائي (وهو الأول والأصغر) ينتج موجة (P wave).

المرحلة الثالثة: العقدة الأذينية البطينية (Atrioventricular Node – AV Node) تصل النبضة إلى العقدة الأذينية البطينية التي تعمل كمحول وبوابة تعمل على إبطاء النبضة قليلاً (لمدة 0.12-20.0 ثانية) للسماح للبطينين بالإمتلاء بالدم. هذا التأخير ينتج فاصل (PR interval).

المرحلة الرابعة: حزمة هيس (Bundle of His) وألياف بوركينجي (Purkinje Fibers) تنتقل النبضة عبر حزمة هيس ثم تتفرع إلى شبكة ألياف بوركينجي التي تنقل النبضة بسرعة كبيرة إلى جميع أنحاء عضلة البطينين، مسببة انقباضهما القوي لضخ الدم. هذا الحدث (الأكبر والأقوى) ينتج مركب (QRS Complex).

المرحلة الخامسة: عودة استقطاب البطينين (Ventricular Repolarization) بعد انقباض البطينين، تعود خلايا عضلة القلب إلى حالتها الكهربائية الأصلية استعداداً للنبضة التالية. هذا الحدث ينتج موجة (T wave).



الشكل 1 النبضة في تخطيط القلب

تخطيط القلب الموجات والفترات الزمنية الأساسية

الجدول 1 موجات تخطيط القلب

المكون (بالإنجليزية)	الاسم (بالعربية)	الوصف	الدلالة الفسيولوجية	المدة الطبيعية
P wave	الموجة الأذينية	أول انحراف صغير (منخفض السعة)	إزالة استقطاب الأذنين (انقباضهما)	أقل من 0.12 ثانية
PR interval	الفاصل الأذيني البطيني	من بداية P إلى بداية QRS	زمن التوصيل من العقدة الجيبية إلى البطينين	0.12-0.20 ثانية
QRS complex	مركب البطينين	ثلاثة انحرافات متتالية (Q,R,S)	إزالة استقطاب البطينين (انقباضهما) أقوى إشارة	أقل من 0.10 ثانية
ST segment	الفاصل ST	من نهاية QRS إلى بداية T	فترة ما قبل عودة استقطاب البطينين	0.08-0.12 ثانية
T wave	الموجة T	انحراف أوسع وأقل حدة	عودة استقطاب البطينين (استرخاؤهما)	0.10-0.25 ثانية

QT interval	الفاصل QT	من بداية QRS إلى نهاية T	وقت انقباض وانقباض البطينين معاً	0.35-0.44 ثانية
-------------	-----------	--------------------------	----------------------------------	-----------------

المسارات

لا يمكن الحصول على صورة كاملة للنشاط الكهربائي للقلب باستخدام زوج واحد فقط من الأقطاب الكهربائية. لذلك يستخدم تخطيط القلب القياسي السريري 12 مسرى (12-lead) وهي توفر 12 منظوراً مختلفاً للقلب. تصنيف المساري الـ 12:

الجدول 2 المسارات في تخطيط القلب

المجموعة	أسماء المساري (بالإنجليزية)	عدد	وضعية الأقطاب
المساري الطرفية الثنائية	I, II, III	3	توضع على الأطراف (الذراعين والرجل اليسرى)
المساري الطرفية المحسنة	aVR, aVL, aVF	3	توضع على الأطراف (اشتقاق رياضي)
المساري الصدرية	V1, V2, V3, V4, V5, V6	6	توضع على الصدر في مواقع محددة

الفائدة السريرية للمساري المتعددة

- تحديد موقع الإصابة بدقة مثلاً إذا كان هناك احتشاء عضلة القلب، يمكن تحديد أي جدار من عضلة القلب تأثر (أمامي، سفلي، جانبي، خلفي).
- تشخيص تضخم الأذنين والبطينين وتضخم البطين الأيسر يظهر كزيادة في سعة QRS في المساري V5 و V6.
- تشخيص اضطرابات النظم بعض اضطرابات النظم قد تكون مرئية فقط في مسرى واحد أو اثنين.

ما يمكن اكتشافه بواسطة تخطيط القلب [6]

الحالة المكتشفة	الوصف السريري	العلامات المميزة على ECG
اضطرابات نظم القلب	خلل في انتظام أو سرعة النبضات الكهربائية	غياب أو تشوه موجة P ، مسافات RR غير منتظمة ، QRS عريض
نقص تروية عضلة القلب	نقص تدفق الدم إلى عضلة القلب	انخفاض مقطع (ST depression) ST ، انقلاب موجة T
احتشاء عضلة القلب	النوبة القلبية- موت جزء من عضلة القلب	ارتفاع مقطع (ST elevation) ST ، موجة Q مرضية

3.2 الذكاء الصناعي

يعد الذكاء الصناعي (Artificial Intelligence – AI) أحد أهم فروع العلوم الحاسوب الحديثة، ويهدف إلى تطوير أنظمة قادرة على محاكاة القدرات الإدراكية البشرية مثل الفهم، التعلم، الاستنتاج، واتخاذ القرار. وقد تطور الذكاء الصناعي عبر العقود من نظم قائمة على القواعد والمنطق إلى نماذج قادرة على التعلم من خلال البيانات.

1.3.2 تعلم الآلة (Machine Learning (ML

هو فرع من فروع الذكاء الصناعي ويعد من أكثر المواضيع رواجاً في عالم الذكاء الصناعي . حيث يعتبر التعلم الآلي أحد المحاور الأساسية في الذكاء الصناعي، فيمكن الآلة من تحسين أدائها تلقائياً من خلال التجربة والبيانات دون أن تتم برمجتها صراحة. ويوجد العديد من الخوارزميات لتعلم الآلة، ضمن هذا المجال التعلم العميق (Deep Learning – DL) الذي ظهر كنهج ثوري يعتمد على شبكات عصبية متعددة الطبقات (Deep Neural Networks) لاستخراج التمثيلات المعقدة من البيانات، خصوصاً في مجال الصور، النصوص والصوت.

خوارزميات تعلم آلي

■ خوارزمية Extreme Gradient Boosting

تُعد XGBoost واحدة من أقوى خوارزميات التعلم الآلي وأكثرها استخداماً في مسابقات علم البيانات والتنبؤات الطبية تعتمد هذه الخوارزمية على مبدأ التعزيز (Boosting)، حيث يتم بناء عدة أشجار قرار بشكل متسلسل، بحيث تحاول كل شجرة تصحيح أخطاء الشجرة السابقة. [8]

■ خوارزمية Random Forest: تعتمد Random Forest على مبدأ التجميع (Ensemble Learning)، حيث


يتم بناء عدد كبير من أشجار القرار بشكل عشوائي ومستقل، ثم يتم أخذ تصويت الأغلبية للوصول إلى التنبؤ النهائي تتميز هذه الخوارزمية بقدرتها على تقليل فرط التخصيص (Overfitting) مقارنة بشجرة القرار الواحدة. [9]

■ خوارزمية شجرة القرار Decision tree : تعد هذه الخوارزمية من أشهر خوارزميات التصنيف وأكثرها فعالية، يتم بناء الشجرة عن طريق تقسيم البيانات إلى مجموعات أصغر فأصغر حتى تصبح كل تقسيمة صافية تماماً (أي تنتمي كل عناصرها لصنف واحد)، ويعتمد كل تقسيم على سمة محددة ويتم التفرع إلى قسمين حسب السمة (مثل حالة الجنس ذكر أو أنثى)، يتم بناء الشجرة من الأعلى للأسفل وعند كل تقسيم نجرب كل السمات لمعرفة أي سمة تقوم بتقسيم المجموعة الحالية إلى مجموعتين أكثر نقاء المقصود بالمجموعة النقية أي المجموعة التي غالبية عناصرها تنتمي لفئة واحدة. عند اختبار عينة جديدة لتصنيفها فإن الخوارزمية تبدأ من الجذر ثم تنتقل إلى العقدة التالية حسب المعلومات العينة وهكذا حتى الوصول للأوراق التي تحدد التصنيف النهائي للعينة.

■ خوارزمية آلة المتجهات الداعمة Support Vector Machine: تُعد SVM من الخوارزميات الفعالة في مشاكل التصنيف الثنائي، حيث تعمل على إيجاد المستوى الفائق الأمثل (Optimal Hyperplane) الذي يفصل بين فئتي من البيانات بأكبر هامش ممكن تحاول تعظيم الهامش أي المسافة الفاصلة بين خط الفصل وأقرب نقطة بيانات من الفئتين، المتجهات الداعمة Support Vectors هي نقاط البيانات الأقرب إلى خط الفصل، وهي التي تحدد موقع واتجاه المستوى الفائق. تكمن قوة SVM في قدرتها على معالجة البيانات غير القابلة للفصل خطياً باستخدام ما يُعرف بـ "خدعة النواة" (Kernel Trick) حيث تقوم دالة النواة بنقل البيانات إلى فضاء ذي أبعاد أعلى حيث يصبح الفصل ممكناً بخط مستقيم. [10]

أنواع النوى [11]

- (Radial Basis Function) الأكثر استخداماً، ومناسب للبيانات المعقدة والعلاقات غير الخطية. [8]
- (Linear) للبيانات القابلة للفصل خطياً.
- (Polynomial) للعلاقات غير الخطية من الدرجة الثانية أو الثالثة.



الشكل 2 آلة المتجهات الداعمة

- خوارزمية الانحدار اللوجستي (Logistic Regression): على الرغم من اسمه يُعد الانحدار اللوجستي خوارزمية تصنيف (وليس انحدار) تستخدم على نطاق واسع للمشاكل الثنائية. يقوم بتقدير احتمالية انتماء عينة معينة إلى فئة معينة باستخدام الدالة اللوجستية. [12]
- خوارزمية التعزيز التدرجي (Gradient Boosting): هي خوارزمية تجميعية متقدمة تبني النماذج بشكل متسلسل (Sequentially) حيث يحاول كل نموذج جديد تصحيح أخطاء النموذج السابق. الفكرة الأساسية تقوم على بناء نموذج قوي من خلال تجميع نماذج ضعيفة متعددة تتميز بدقة عالية جداً في العديد من مهام التصنيف، ويتعامل بشكل جيد مع العلاقات غير الخطية بين السمات. [13]

2.3.2 التعلم العميق ورؤية الحاسوب (Deep Learning & Computer Vision)

سنستعرف في هذه الفقرة على التعلم العميق والرؤية الحاسوبية.

الرؤية الحاسوبية

تعد الرؤية الحاسوبية Computer Vision أحد فروع الذكاء الاصطناعي وتهدف إلى تمكين الآلة من رؤية وفهم المحتوى البصري من صوراً وفيديوهات بطريقة تحاكي إدراك الإنسان. تعتمد هذه التقنية على تحليل الصور الرقمية واستخراج المعلومات منها سواء كانت تتعلق بتصنيف الكائنات أو تحديد مواقعها أو فهم العلاقات بينها وتستخدم الرؤية الحاسوبية في العديد من التطبيقات المتقدمة مثل تشخيص الصور الطبية والتعرف على الوجوه وأنظمة القيادة الذاتية وتحليل المشاهد في الفيديو وأمن المعلومات فضلاً عن استخدامها الواسع في المجال الصناعي والطبي الهندسي. [14]

التعلم العميق

قد شهد التعلم العميق تطوراً ملحوظاً في العقد الأخير بفضل توفر بيانات ضخمة وزيادة القدرة الحاسوبية مما سمح له بتجاوز النماذج التقليدية وتحقيق أداء متفوق في مهام التصنيف والترجمة وتوليد اللغة وفهم الصور.

تشكل الخلية العصبية الصناعية (Artificial Neuron)، وتسمى أيضاً البيرسبترون (Perceptron)، هي الوحدة الحسابية الأساسية في الشبكات العصبونية. [15]

الشبكة العصبونية الصناعية (Artificial Neural Network – ANN)

تتكون من ثلاث طبقات رئيسية :

- طبقة الإدخال (Input Layer): عدد الخلايا العصبية فيها يساوي عدد السمات (أو عدد بكسلات الصورة بعد تسطيحها). هذه الطبقة لا تقوم بأي عملية حسابية، فقط تستقبل البيانات وتمررها إلى الطبقة التالية.
- طبقات مخفية (Hidden Layers): طبقة واحدة أو أكثر (الشبكة عميقة إذا كان هناك أكثر من طبقة مخفية). كلما زاد عدد الطبقات المخفية وعدد الخلايا فيها، زادت قدرة الشبكة على تعلم أنماط معقدة وغير خطية، ولكن أيضاً زاد خطر فرط التخصص وزادت الحاجة إلى بيانات تدريب أكثر.
- طبقة الإخراج (Output Layer): عدد الخلايا العصبية فيها يعتمد على نوع المشكلة:
- للتصنيف الثنائي (Binary Classification) خلية واحدة بدالة تنشيط Sigmoid.
- للتصنيف المتعدد (Multiclass Classification) عدد خلايا يساوي عدد الفئات بدالة تنشيط Softmax.


الشبكة العصبونية الالتفافية (Convolutional Neural Networks)

برزت الشبكات العصبونية الالتفافية كأداة قوية وفعالة لتحليل الصور ضمن نماذج التعلم العميق، وذلك بفضل قدرتها على معالجة البيانات ذات البنية الشبكية كالصور ثنائية الأبعاد. ومع التقدم في البنى المعمارية، ظهرت نماذج جديدة تعتمد على الشبكات الالتفافية مع إضافات مختلفة حسب طبيعة التطبيق، مثل AlexNet و VGG و LeNet و ResNet وغيرها، مما أتاح تحسين الأداء في مهام التعرف البصري والتصنيف الطلي. [16]

تتكون الشبكات العصبونية الالتفافية من سلسلة من الطبقات المخفية، حيث تُرتَّب الخلايا العصبونية (العصبونات) في كل طبقة بأبعاد ثلاثة العرض، والارتفاع، بالإضافة إلى العمق (عدد القنوات اللونية أو خرائط المعالم). يرتبط كل عصبون بمنطقة صغيرة محلية من الطبقة التي تسبقها على عكس الطبقة المتصلة بالكامل (Fully Connected Layer) التي تربط كل عصبون بجميع عصبونات الطبقة السابقة. كما تشترك العصبونات التي تنتمي إلى نفس الطبقة في الأوزان ذاتها، مما يقلل بشكل كبير من عدد المعلمات (الأوزان) التي يجب تعلمها في الشبكة، طبقة الخرج النهائية في الشبكة، هي شبكة عصبية متصلة بالكامل FCN والتي تقوم بتحويل الصورة الدخل إلى شعاع وحيد مكون من مجموعة من الأرقام التي تعبر عن نتيجة كل فئة من الفئات.

الطبقات الأساسية للشبكات العصبونية الالتفافية.

1. الطبقة التلافيفية (Convolutional Layer – Conv2D): تطبق هذه الطبقة مجموعة من المرشحات (Filters) أو النوى (Kernels) على الصورة المدخلة أو على خرائط المعالم الصادرة من الطبقة السابقة. كل مرشح هو مصفوفة صغيرة الأبعاد (عادةً 3×3 أو 5×5 بكسل) تحتوي على أوزان قابلة للتعلم، وتقوم بعملية الالتفاف (Convolution) التي تكتشف الأنماط المكانية مثل الحواف، والزوايا، والأشكال البسيطة، ثم الأنماط الأكثر تعقيداً في الطبقات العميقة.




2. طبقة التجميع (Pooling Layer – POOL): تعمل على اختزال الأبعاد المكانية لخرائط المعالم، وذلك بتطبيق عملية إحصائية بسيطة مثل أخذ القيمة العظمى أو المتوسط على نوافذ صغيرة (عادة 2×2 بكسل) هذه الطبقة ليس لها أوزان للتدريب. نلاحظ أن هذه العملية تتسبب بتصغير الأبعاد مما يقلل التعقيد الحسابي مع الحفاظ على السمات .
 3. طبقة التسطيح Flatten Layer : هي طبقة تحول الدخل مصفوفة متعددة الأبعاد إلى شعاع ببعد واحد يتم إضافة هذه الطبقة بعد الإنتهاء من استخراج السمات.
 4. الطبقة المتصلة بالكامل (Fully Connected Layer – FCN): تُستخدم هذه الطبقات في نهاية الشبكة لإتخاذ القرار النهائي، وتعتمد على السمات العميقة التي استخرجتها الطبقات التلافيفية والتجميعية.
- عادةً ما يُرفق مع الطبقات التلافيفية تابع تنشيط غير خطي مثل ReLU (Rectified Linear Unit)، وذلك لإدخال اللاخطية اللازمة للشبكة لتعلم العلاقات المعقدة في البيانات. ونتيجة لإمكانية تغيير ترتيب وعدد هذه الطبقات. ظهرت هيكليات متعددة ومتنوعة من الشبكات العصبونية مثل AlexNet ، LeNet وصولاً إلى البنى الأحدث مثل ResNet و MobileNet. [16]

مع التقدم في هذا المجال ظهرت العديد من البنى المعمارية من الشبكات العصبونية التلافيفية:

■ الشبكة الكثيفة (Densely Connected Convolutional Network)

الشكل 3 شبكة الالتفافية

تُعد شبكة DenseNet واحدة من أبرز التطورات المعمارية في مجال الشبكات العصبية التلافيفية، تعتمد على مبدأ الاتصالات الكثيفة، حيث ترتبط كل طبقة بجميع الطبقات اللاحقة بشكل مباشر، بحيث تستقبل الطبقة L كمدخل لها خرائط المعالم الناتجة من جميع الطبقات السابقة $(0, L-2, \dots, L-1)$ وتدمجها معاً باستخدام عملية الربط (Concatenation) هذا التصميم يعزز تدفق المعلومات عبر الشبكة، ويقلل من مشكلة تلاشي التدرج، ويشجع على إعادة استخدام السمات (Feature Reuse) بدلاً من تعلم سمات جديدة في كل طبقة مما يجعل الشبكة ذات كفاءة عالية بالنسبة للمتغيرات. بفضل هذه الاتصالات، تستطيع DenseNet أن تكون أعمق مع عدد معاملات أقل 8 ملايين معامل فقط لـ (DenseNet-121) كما أنها مقاومة لفرط التخصص بشكل طبيعي حيث أن كثافة الاتصالات تعمل كنوع من التسوية المضمنة (Regularization). ومع ذلك، فإن التخزين المؤقت لخرائط المعالم من جميع الطبقات يتطلب ذاكرة عالية أثناء التدريب، وهو العيب الرئيسي لهذه المعمارية. [17]



الشكل 4 بنية الشبكة الكثيفة

■ الشبكة العصبية المتبقية (Residual Network)


ظهرت ResNet عام 2015، وحلت واحدة من أهم المشكلات التي واجهت تدريب الشبكات العميقة جداً، وهي مشكلة تلاشي التدرج (Vanishing Gradient) وتدهور الدقة (Degradation Problem) تكمن الفكرة في إضافة اتصالات اختصار (Skip connections) حيث يتم إضافة ناتج الطبقة مباشرة إلى ناتج الطبقة اللاحقة بعد طبقات الالتفاف قبل تمريره إلى تابع تنشيط. بدلاً من أن تتعلم الطبقة تعييناً مباشراً $H(X)$ من المدخلات إلى المخرجات، تتعلم الدالة المتبقية فقط.

$$F(x) = Hx - x$$

هذا التصميم يسمح للشبكة لأن تكون عميقة جداً حتى 152 طبقة أو أكثر مع تحسين الأداء بشكل كبير، حيث أن اتصالات الاختصار توفر مساراً مباشراً لانتشار التدرجات للطبقات المبكرة مما يمنع تلاشيها مما يسهل عملية التعلم تمتلك ResNet-50 حوالي 25 مليون معامل فقط، تأتي ResNet بعدة أحجام، أشهرها ResNet-50 ب 50 طبقة و ResNet-152 ب 152 طبقة تتميز بدقة عالية. [17]

المشاكل التي تقوم بحلها هذه الشبكة :

المشكلة	الشرح
اختفاء التدرج (Vanishing Gradient)	عند انتشار التدرجات (Gradients) عبر طبقات عديدة، تصبح صغيرة جداً لدرجة أنها لا تؤثر في تحديث أوزان الطبقات المبكرة، فتتوقف الشبكة عن التعلم.
انفجار التدرج (Exploding Gradient)	تصبح التدرجات كبيرة جداً، مما يؤدي إلى عدم استقرار التدريب.
تدهور الدقة (Degradation Problem)	حتى مع استخدام تقنيات مثل Batch Normalization التي تحسن انتشار التدرج، فإن إضافة طبقات إضافية يزيد من خطأ التدريب والاختبار.



الشكل 5 بنية الشبكة المتبقية


■ معمارية التحجيم المتوازن للشبكات العصبية التلافيفية (EfficientNet)

معمارية EfficientNet، وهي بنية تختلف جوهرياً عن سابقتها لأنها لا تركز على بعد واحد مثل إضافة طبقات جديدة، بل على تحجيم متوازن (Compound Scaling) لأبعاد الشبكة الثلاثة الرئيسية: العمق (عدد الطبقات)، والعرض (عدد القنوات)، والدقة (حجم الصورة المدخلة). وجد الباحثون أن أفضل طريقة للحصول على أداء عالٍ مع كفاءة حسابية عالية هي زيادة هذه الأبعاد الثلاثة معاً بنسبة ثابتة. يتم تحديد هذه النسب بواسطة بحث آلي صغير (Neural Architecture Search - NAS) واحد فقط. يجد النسب المثلى لكل بُعد نتج عن هذه المنهجية عائلة من النماذج من B0 إلى B7، حيث تزداد الدقة مع زيادة الحجم. على سبيل المثال EfficientNet-B0 يحتوي على عدد معاملات أقل من ResNet-50 بخمس مرات تقريباً ويحقق دقة تفوقه.

تعتمد EfficientNet على كتلة بنائية (Mobile Inverted Bottleneck Convolution – MBConv) وهي عبارة عن كتلة بنائية تهدف إلى تحقيق توازن مثالي بين الأداء والكفاءة الحسابية. تعتمد هذه الكتلة على الانعكاس المتبقي (Inverted Residual) مع استخدام الالتفاف القابل للفصل عميقاً (DepthWise Separable Convolution) لتقليل عدد المعاملات والعمليات الحسابية بشكل كبير.

تتكون من خمس مراحل رئيسية

1. توسيع القنوات Expansion.
2. الالتفاف العمقي Depthwise Convolution.
3. إعادة توزيع الأوزان على القنوات (Squeeze-and-Excitation (SE).
4. ضغط القنوات Projection.
5. الإلتصال المختصر Skip Connection.



الشكل 6 بنية EfficientNet

■ نموذج MobileNetV2

نموذج شبكي عصبية تلافيفية خفيفة الوزن طوّره شركة غوغل صمم خصيصاً للعمل بكفاءة على الأجهزة ذات القدرة المحدودة مثل الهواتف الذكية والأجهزة ذات الموارد المحدودة وتعتمد أساساً على الالتفاف القابل للفصل حسب العمق. (Depthwise Separable Convolution) مع ابتكارين رئيسيين هما : البواقي المعكوسة والاختناقات الخطية.

المفاهيم الأساسية في المعمارية

■ الالتفاف الفصلي العميق (Depthwise Separable Convolution)


يفصل عملية الالتفاف العادية إلى خطوتين: تفصيلية (Depthwise) ونقطية (Pointwise) يقلل عدد العمليات الحسابية بشكل هائل مقارنة بالالتفاف التقليدي.

■ البواقي المعكوسة (Inverted Residuals)

في الشبكات التقليدية، تبدأ البواقي بطبقات عريضة ثم تضيق. في MobileNetV2، تعكس الآلية تبدأ الطبقة بمدخل ضيق (Bottleneck)، ثم تتوسع (Expansion) لمعالجة البيانات، ثم تعود لتضيق. توفر كفاءة أفضل في استهلاك الذاكرة وسرعة نقل البيانات داخل المعالج.

■ الاختناقات الخطية (Linear Bottlenecks)

إزالة دوال التنفيع غير الخطية من طبقات الاختناق النهائية. تحافظ على الميزات والمعلومات الهامة من التلف أثناء الضغط، لأن التنفيع غير الخطية قد تدمر البيانات في الأبعاد الصغيرة.



رسم توضيحي 7 الشكل بنية MobileNet

تقنية نقل التعلم Transfer Learning

هذه التقنية يتم الاستفادة من المعرفة المحصلة سابقا من مسائل سابقة في حل المسألة الحالية. بدلا من البدء من الصفر، أي بدلا من البدء من أوزان عشوائية في حال الشبكة العصبية يمكن البدء من أوزان نموذج مدرب مسبقا. على سبيل المثال يمكن الاستفادة من نموذج يقوم بالتعرف على السيارات في الصور في مسألة التعرف على الشاحنات من خلال استعمال خبرة ومعرفة النموذج السابق عن طريق البدء بأوزان النموذج الأول التعرف على السيارات لتدريب النموذج الثاني التعرف على الشاحنات نقل المعرفة.

وبذلك تم توفير الوقت والموارد الحسابية والبدء من مرحلة متقدمة من التدريب، هذه التقنية مفيدة في حالة حجم بيانات تدريب قليل مثلا يمكن استخدام نماذج مدربة على مجموعة بيانات ضخمة مثل مجموعة بيانات ImageNet وهي قاعدة بيانات ضخمة لصور مصنفة صممت خصيصا لتطوير أبحاث الرؤية الحاسوبية والتعلم العميق. تحتوي على أكثر من 14 مليون صورة مقسمة لآلاف التصنيفات.

من حالات نقل التعلم:

- يمكن أخذ النموذج المدرب مسبقا بأوزانه وإزالة الرأس وتجميد الأوزان عدم تغييرها ومعاملة النموذج ك مستخلص سمات من البيانات الجديدة كل صورة مقابلتها ب شعاع من السمات ثم إضافة طبقات حسب المهمة.

- ويمكن أخذ النموذج المدرب مسبقا بأوزانه كما هو وإزالة الرأس منه ثم بدلا من تجميد الأوزان يمكن جعل أوزان بعض أو كل الطبقات قابلة للتدريب هذه العملية الضبط الدقيق أو الدوزنة عادة في النماذج الشهيرة الطبقات الأولى تبقى مجمدة لأنها معرفتها أكثر عمومية من لاحقاتها في الطبقات العميقة.

تقنية زيادة البيانات Data Augmentation

هي تقنية تستخدم لزيادة حجم البيانات المستخدمة في عملية تدريب النموذج وذلك من خلال توليد بيانات جديدة باستعمال البيانات الموجودة. تستخدم في حالة حجم البيانات صغيرا فيمكن عندها إضافة بيانات جديدة للوصول لحجم بيانات أكبر مما يعطي نتائج أفضل كما تستخدم أيضا لمنع الإفراط في التخصص للنماذج overfitting ليعطي نموذج يعمم بشكل أفضل على بيانات جديدة. يتم زيادة البيانات في حالة الصور من خلال تطبيق التحويلات الهندسية (دوران بزاوية - عكس الصورة - اقتصاص أجزاء من الصورة)، التعديل اللوني مثل زيادة حدة الألوان شحذ أو زيادة الضبابية وغيرها من العمليات المختلفة التي يتم تطبيقها بشكل عشوائي.

الفصل الثالث

الدراسة المرجعية

في هذا الفصل تم تلخيص بعض الأعمال المتعلقة بالعمل.

تم قراءة ومراجعة عدد من الأوراق البحثية المتعلقة بالكشف وتصنيف أمراض القلب وتم التركيز على الدراسات الأكثر حداثة.

1.3 التنبؤ بأمراض القلب والأوعية الدموية باستخدام خوارزميات تعلم الآلة (Predicting the Prevalence of Cardiovascular Diseases using Machine Learning Algorithms Sianga et al., 2025)

نظرة عامة عن الدراسة

هدفت هذه الدراسة إلى تحسين دقة التنبؤ بأمراض القلب باستخدام تقنيات التعلم الآلي (Machine Learning)، وذلك من خلال إضافة عوامل جغرافية مثل (درجة الحرارة والرطوبة والمستوى التعليمي) إلى العوامل السريرية التقليدية (مثل العمر والجنس والكوليسترول وضغط الدم). تمثل هذه الدراسة نقلة نوعية في مجال التنبؤ بأمراض القلب، حيث استخدمت بيانات من إفريقيا لأول مرة، وطبقت نماذج تعلم آلي تتعامل مع العلاقات غير الخطية المعقدة.


المنهجية المتبعة

جمع البيانات : من 4 مستشفيات في تنزانيا تتكون من ميزات سريرية وجغرافية.

عدد السجلات: 3,553 سجل .

المعالجة المسبقة للبيانات :

- ترميز النصوص (Text Encoding)
- إزالة القيم الشاذة (Outlier Removal)
- معالجة عدم التوازن باستخدام (SMOTE).



الشكل 8 المنهجية المتبعة

الخوارزميات المستخدمة

تم استخدام 6 خوارزميات (Decision Tree، Support Vector Machine، Naïve Bayes، Logistic Regression، Random Forest، XGBoost)

تم مقارنة طريقتين من ضبط المعاملات:

تجربة جميع التركيبات الممكنة، اختيار عشوائي لعدد محدود من التركيبات.

تم تنفيذ تجربتين:

- الأولى فقط ميزات سريرية .
- الثانية ميزات سريرية وميزات جغرافية .

تدريب وتقييم النماذج

- تقسيم البيانات: 80% تدريب و 20% اختبار.
- Cross-Validation: K-Fold (K=10)

تم تقييم النماذج على بيانات الاختبار وفق معايير التقييم : Precision ، Recall ، Accurcy ، F1 Score .

النتائج

الجدول 4 نتائج التجربة

الخوارزمية	بدون جغرافيا	مع جغرافيا	التحسن
XGBoost	93.49%	95.24%	+1.75%
Decision Tree	92.12%	93.87%	+1.75%
SVM	91.86%	92.87%	+1.01%

2.3 مقارنة خوارزميات التعلم الآلي للتنبؤ بأمراض القلب (Comparing some Machine Learning Models for Cardiovascular Disease)

نظرة عامة عن الدراسة

هذه دراسة علمية هدفت إلى مقارنة أداء ثلاث خوارزميات تعلم آلي (Random Forest – Decision Tree – K-Nearest Neighbors) للتنبؤ بأمراض القلب، باستخدام بيانات سريرية من مستشفى في مدينة السليمانية، العراق. [18] تمثل هذه الدراسة إضافة مهمة للمجال حيث طبقت المقارنة على بيانات من الشرق الأوسط ، واختبرت نسب تقسيم متعددة. حجم العينة 300 مريض.

المنهجية المتبعة

جمع البيانات من مستشفى Shar Hospital، السليمانية، العراق – 300 مريض 10 ميزات سريرية – بأثر رجعي .

المعالجة المسبقة : اختبار دلالات المتغيرات Chi-Square test.

الخوارزميات المستخدمة : Random Forest – Decision Tree – K-Nearest Neighbors

تم اختبار أحجام عينة مختلفة (100، 200، 300، 400، 500).

النموذج حقق توازناً ممتازاً بين Precision و Recall قلة الأخطاء من النوعين.

مقارنة الدقة (على 300 مريض - أفضل أداء)

الجدول 5 نتائج التجارب

حجم العينة	Random Forest	Decision Tree	KNN
100	86.26%	85.86%	82.25%
200	88.18%	88.32%	84.62%
300	85.05%	85.05%	81.05%
400	84.34%	84.34%	81.38%
500	83.04%	83.04%	80.41%

3.3 الكشف عن أمراض القلب من خلال صور تخطيط القلب (Detection of Cardiovascular Diseases through ECG Images) [19]

نظرة عامة عن الدراسة

تستهدف هذه الورقة الكشف عن أمراض القلب والأوعية الدموية (CVD) من خلال تحليل صور تخطيط القلب الكهربائي (ECG) باستخدام تقنيات معالجة الصور والتعلم العميق. يعد مرض القلب أحد الأسباب الرئيسية للوفيات عالمياً، مما يستدعي تطوير طرق تشخيص مبكرة ودقيقة. تقدم الورقة منهجية تعتمد على تحسين جودة صور ECG واستخلاص الميزات التي تشير إلى وجود اعتلالات قلبية باستخدام شبكات (CNN)، تهدف الدراسة إلى تحسين كفاءة التشخيص، ودعم الأطباء في اتخاذ قرارات دقيقة.

مجموعة البيانات

مصدر البيانات مجموعة صور ECG مأخوذة من مستشفيات متعددة صور تخطيط قلب ذات 12 مسار.

حجم البيانات إجمالي 929 صورة ECG موزعة على 4 فئات.

المنهجية المتبعة

■ معالجة الصور المسبقة (Preprocessing).

■ تنظيف صور ECG من الضوضاء.

- تطبيع الصور وتوحيد أبعادها لتناسب مدخلات النماذج.
- توسيع البيانات (Data Augmentation) تم تطبيق عدة تحويلات :
- تدوير عشوائي حتى 20 درجة.
- إزاحة أفقية / عمودية حتى 20%.
- انعكاس أفقي (Horizontal Flip).
- تكبير / تصغير (Zooming).
- النماذج المستخدمة (Models) : EfficientNet و MobileNet.
- مقاييس التقييم (Evaluation Metrics)
- (Accuracy)
- (Precision)
- (Error Rate)
- (Recall)

الجدول 6 نتائج التجارب

المقياس	MobileNetV2	EfficientNetV2
Accuracy	99.69%	99.72%
Error Rate	0.30%	0.28%
Precision	87.5%	87.5%
Recall	93.33%	93.33%

تحليل الدراسات السابقة

- الدراسات ركزت الدراسات ركزت على مصدر واحد للبيانات إما بيانات سريرية مهيكلة أو تخطيط قلب.
- الدراسات توقفت عند مرحلة النموذج ولم تقدم تطبيق ويب متكامل.

من خلال المراجعة للأبحاث السابقة، تم التوصل للنتائج التالية التي ستأخذ بعين الاعتبار عند اقتراح منهجية العمل:

- استخدام مصدرين منفصلين من البيانات معظم الدراسات إما ركزت على صور ECG أو على البيانات المهيكلية.
- بناء تطبيق ويب متكامل يقوم بتحليل صور تخطيط قلب وبيانات سريرية مهيكلية.

خلاصة الدراسة المرجعية

من خلال المراجعة للأبحاث السابقة، تم التوصل للنتائج التالية التي ستأخذ بعين الاعتبار في منهجية العمل لمشروعنا، تشخيص أمراض القلب عن طريق تحليل صور تخطيط قلب لأهميته ودلالاته في التشخيص. باستخدام تقنيات التعلم العميق وتحديد البنى المختلفة للشبكات العصبونية التلافيفية أظهرت نتائج مميزة، والبيانات السريرية المهيكلية استخدام خوارزميات تعلم الآلة المختلفة ومقارنة أدائها واختيار الأفضل (SVM - Random Forest - XGBoost - Decision Tree) وغيرها أظهرت نتائج ممتازة، أظهرت الدراسات السابقة نتائج واعدة تجاوزت في بعض الحالات أداء الأطباء. يبرز هذا المشروع من خلال إنشاء نماذج للبيانات السريرية وصور تخطيط الكهربي للقلب ECG وتنفيذ نظام ويب متكامل كأداة مساعدة موثوقة لطبيب القلب في التشخيص. وتقييم أداء النماذج من باستخدام معايير الدقة والحساسية والاسترجاع تماشياً مع المنهجيات المتبعة في الأبحاث المشابهة.

الفصل الرابع


الدراسة التحليلية

في هذا الفصل سيتم تحليل المشروع من خلال تحليل المتطلبات وستشمل عملية التحليل كل من مخطط حالات الاستخدام والسرد النصي لكل منها.

1.4 حالات الإستخدام

النظام المساعد الذي نسعى لتحقيقه مؤلف موقع ويب خاص بطبيب قلبية يتم استخدامه من قبل الطبيب فقط.

1.1.4 مخطط حالات الاستخدام الخاصة بالطبيب.



الشكل 9 مخطط حالات الاستخدام

2.1.4 السرد النصي لحالات الاستخدام الأساسية للطبيب

حالة إدخال البيانات السريرية عبر تعبئة نموذج والحصول على تشخيص.

اسم حالة الاستخدام: إدخال البيانات السريرية عبر نموذج.

الفاعل الأساسي: الطبيب.

الفاعل الثانوي: لا يوجد.

الملخص: يقوم الطبيب بإدخال البيانات السريرية للمريض.

الشروط المسبقة: تم إختيار النموذج و طريقة الإدخال عبر تعبئة نموذج.

الشروط اللاحقة: عرض نتيجة التشخيص مع نسبة الثقة.

السيناريو الرئيسي الناجح:

يظهر الجدول التالي السيناريو الرئيسي الناجح لحالة إدخال البيانات السريرية من قبل الطبيب.

الجدول 7 السيناريو الناجح للحالة

الفاعل	النظام
1- تبدأ الحالة عندما يقوم الطبيب باختيار أحد النماذج الذكية.	
	2- يقوم النظام بعرض الواجهة لإدخال البيانات.
3- يدخل الطبيب البيانات السريرية.	
	4- ترسل البيانات للنموذج يقوم بتحليلها والتنبؤ.
	5- يعرض النظام نتيجة التشخيص مع نسبة الثقة ومستوى خطر للطبيب.

المسارات البديلة:

مسار 1 : النموذج الذكي غير متاح أو غير متصل .

يبدأ المسار بعد الخطوة 4 من السيناريو الرئيسي الناجح يظهر الجدول التالي السيناريو البديل 1.

الجدول 8 المسار البديل الاول

الفاعل	النظام
	5- يكتشف النظام أن النموذج غير متصل أو غير متاح
	6- يظهر النظام رسالة : " النموذج الذكي غير متاح حاليا "

مسار 2 : أخطاء في إدخال البيانات السريية .


يبدأ المسار بعد الخطوة 3 من السيناريو الرئيسي الناجح يظهر الجدول التالي السيناريو البديل 2.

الشكل 9 المسار البديل الثاني

الفاعل	النظام
	4- يتحقق النظام ان البيانات المدخلة غير صالحة.
	5- يظهر النظام للطبيب رسالة : " توضح الخطأ".

مسارات الخطأ: لا يوجد .

مخطط تتالي النظام للحالة :



الشكل 10 مخطط تنالي النظام

حالة حفظ بيانات السريرية مع التشخيص.

اسم حالة الاستخدام: حفظ بيانات السريرية مع التشخيص.

الفاعلون الأساسيون : الطبيب.

الفاعلون الثانويون: لا يوجد.

الملخص : يقوم الطبيب بطلب حفظ البيانات السريرية مع التشخيص الناتج.

الشروط المسبقة : تم إدخال البيانات السريية وتم عرض النتيجة.

الشروط اللاحقة : تم حفظ البيانات السريية مع التشخيص في النظام.

السيناريو الرئيسي الناجح:

يظهر الجدول التالي السيناريو الرئيسي الناجح لحفظ بيانات السريية مع التشخيص.

الجدول 10 السيناريو الناجح للحالة

الفاعل	النظام
1- تبدأ الحالة عندما يقوم الطبيب بطلب حفظ التشخيص بدون أو بعد تعديل نتيجة التشخيص "خياريا".	
	2- ترسل البيانات مع التشخيص.
	3- يقوم النظام بحفظ التشخيص مع البيانات السريية.
	4- يعرض النظام رسالة تأكيد نجاح العملية.

مسارات البديلة :

المسار 1 : خطأ بحفظ البيانات .


يبدأ المسار بعد الخطوة 3 من السيناريو الناجح يظهر الجدول التالي المسار 1 البديل

الجدول 11 المسار البديل الأول

الفاعل	النظام
	4- يكتشف النظام بوجود خطأ بالحفظ.
	5- يظهر النظام رسالة : " توضح المشكلة"

مسارات الخطأ: لا يوجد .

مخطط تتالي النظام للحالة :



الشكل 11 مخطط تنالي النظام

حالة رفع صورة تخطيط قلب وتحليلها.

اسم حالة الاستخدام: رفع صورة تخطيط القلب وتحليلها من قبل النموذج.

الفاعلون الأساسيون : الطبيب.

الفاعلون الثانويون: لا يوجد.

الملخص : يقوم الطبيب برفع صورة تخطيط القلب للمريض.

الشروط المسبقة : النموذج الذكي الخاص بتخطيط القلب مختار.

الشروط اللاحقة : عرض النتائج أي خرج النموذج.

السيناريو الرئيسي الناجح:

يظهر الجدول التالي السيناريو الرئيسي الناجح لحالة رفع صورة تخطيط القلب من قبل الطبيب لتحليلها .

الجدول 12 السيناريو الناجح للحالة

الفاعل	النظام
1- تبدأ الحالة عندما يقوم الطبيب برفع صورة تخطيط القلب.	
	2- ترسل الصورة للنموذج الذكي.
	3- يحلل النموذج الصورة ويتنبأ.
	4- يعرض النظام نتيجة التحليل مع نسبة ثقة .

المسارات البديلة :

مسار 1 : النموذج الذكي غير متاح.

يبدأ هذا المسار بعد الخطوة 2 من السيناريو الرئيسي الناجح يظهر الجدول التالي المسار 1 البديل.

الجدول 13 المسار البديل الأول

الفاعل	النظام
	2- يكتشف النظام أن النموذج غير متصل أو غير متاح
	3- يظهر النظام رسالة : " النموذج الذكي غير متاح حاليا "

مسار 2 : الصورة غير صالحة


يبدأ المسار بعد الخطوة 1 من السيناريو الرئيسي الناجح يظهر الجدول التالي المسار 2 البديل.

الجدول 14 المسار البديل الأول

الفاعل	النظام
	2- يتحقق النظام ان الملف المرفوع ليس صورة تخطيط قلب صالحة بناء على (الحجم أوالنوع أو الدقة)
	1- يعرض النظام للطبيب رسالة توضح الخطأ

مسارات الخطأ : لا يوجد

مخطط تنالي النظام للحالة :



الشكل 12 مخطط تنالي النظام

حالة عرض بيانات سريرية لمرضى سابقين.

اسم حالة الاستخدام: عرض بيانات سريرية لمرضى سابقين.

الفاعلون الأساسيون : الطبيب.

الفاعلون الثانويون: لا يوجد.

الملخص : يقوم الطبيب بطلب عرض البيانات السريرية لمرضى سابقين.

الشروط المسبقة : وجود مرضى مسجلين بالنظام.

الشروط اللاحقة : عرض بيانات لمرضى سابقين.

السيناريو الرئيسي الناجح:

يظهر الجدول التالي السيناريو الرئيسي الناجح لحالة عرض البيانات السريرية لمرضى سابقين.

الجدول 15 السيناريو الناجح للحالة

الفاعل	النظام
1- تبدأ الحالة عندما يقوم الطبيب بطلب عرض بيانات مرضى سابقين.	
	2- يرسل الطلب للنظام ويتحقق من وجود الملفات مخزن عليها بيانات المرضى ثم يرجع البيانات.
	3- يعرض النظام بيانات مرضى سابقين.

مسارات البديلة :

المسار 1 : الملف غير متاح او خطأ بقراءة الملف.

يبدأ المسار بعد الخطوة 2 من السيناريو الناجح يظهر الجدول التالي المسار 1 البديل.


الجدول 16 المسار البديل الأول للحالة

الفاعل	النظام
	3- يكتشف النظام أن الملف غير موجود أو تعذر القراءة منه أو تالف.

4 - يظهر النظام رسالة : " البيانات غير متاحة
ويظهر السبب".

مسارات الخطأ : لا يوجد .

مخطط تتالي النظام للحالة:



الشكل 13 مخطط تتالي النظام

حالة إنشاء قالب تقرير طبي.

اسم حالة الاستخدام: إنشاء قالب تقرير طبي.

الفاعلون الأساسيون : الطبيب.

الفاعلون الثانويون: لا يوجد.

الملخص : يقوم الطبيب بطلب إنشاء قالب.

الشروط المسبقة : لا يوجد.

الشروط اللاحقة : تم إنشاء قالب تقرير طبي.

السيناريو الرئيسي الناجح:

يظهر الجدول التالي السيناريو الرئيسي الناجح لحالة إنشاء قالب تقرير طبي.

الجدول 17 السيناريو الناجح للحالة

الفاعل	النظام
1- تبدأ الحالة عندما يقوم الطبيب بطلب إضافة قالب تقرير طبي.	
	2- يعرض النظام واجهة الإنشاء.
3- ينشأ الطبيب القالب ويطلب حفظه.	
	4- يقوم النظام بحفظ القالب.

مسارات البديلة :

المسار 1 : خطأ بحفظ القالب.


يبدأ المسار بعد الخطوة 4 السيناريو الناجح يظهر الجدول التالي المسار 1 البديل.

الجدول 18 المسار البديل الأول

الفاعل	النظام
	5- حدوث خطأ أثناء حفظ القالب.
	6- يظهر النظام رسالة توضح المشكلة

مسارات الخطأ : لا يوجد .

مخطط تنالي النظام للحالة:



الشكل 14 مخطط تنالي النظام

الفصل الخامس

تصميم النظام

في هذا الفصل، سيتم تقديم المخطط العام للنظام والبنية المعمارية المعتمدة، مع توضيح مكونات النظام الرئيسية


1.5 المخطط العام للنماذج في النظام المقترح

يُعد تشخيص أمراض القلب من التحديات الكبرى في المجال الطبي، حيث تعتمد الطرق التقليدية بشكل كبير على خبرة الطبيب وتفسيره لنتائج تخطيط القلب والعلامات السريرية، مما قد يؤدي إلى أخطاء تشخيصية خاصة في المراحل المبكرة من المرض.

يقدم النظام المقترح حلاً متكاملًا للمساعدة في تشخيص أمراض القلب بالاعتماد على مصدرين رئيسيين للبيانات السريرية المهيكلة وتخطيط القلب الكهربائي (ECG)، بالإضافة لإنشاء قوالب تقارير طبية وتقارير طبية وتصديرها.

فتم تصميم النظام بحيث يأخذ نوعين من البيانات أما صورة للتخطيط الكهربائي للقلب كدخل له فيتمكن نموذج الذكاء الاصطناعي من تحليل الحالة وتصنيف المرض التي توضحه الصورة المدخلة. يتم تطبيق سلسلة من خطوات تمثل المعالجة المسبقة للصورة قبل أن تمرر للنموذج الخطوة الأولى قص أجزاء من الصورة لإزالة الأجزاء غير المفيدة ثم تطبيق عدة فلاتر لتحسين جودة الصورة وإزالة الضوضاء وبعدها تغيير أبعادها لتصبح بأبعاد تناسب النموذج، ثم يتم تطبيق تطبيع Normalization لقيم البكسلات لتوحيد نطاق قيم البكسلات، ثم تمرر بعد المعالجة إلى نموذج يقوم باستخراج التمثيل الشعاعي للصورة (Image Embedding) وتمرر التمثيل لمصنف يقوم بتصنيف الصورة للفئة الموافقة لها. أو يأخذ بيانات سريرية مهيكلة للشخص يتم تطبيق المعالجة المسبقة عليها لتكون جاهزة لتمرر للنموذج الذي يقوم بتحليلها ويعيد التشخيص.

يظهر الشكل التالي مخطط الصندوقي للنماذج.



الشكل 15 مخطط الصندوقي للنماذج في النظام


2.5 مخطط النظام البرمجي المتكامل

1.2.5 التخزين في النظام

من الدراسة التحليلية السابقة نجد أن التخزين في النظام يتألف من مكونين رئيسيين :

1.1.2.5 قاعدة البيانات

تتكون من عدة جداول مرتبطة نوضحها من خلال مخطط الصفوف التالي.




الشكل 16 مخطط الصفوف

وهذه البيانات تمثل :

1. Template : يمثل قوالب للتقارير الطبية.

2. Report : يمثل التقارير الطبية حيث كل تقرير تابع لقالب.

2.1.2.5 نظام ملفات يستخدم لتخزين البيانات السريرية للمرضى والتقارير الطبية.



وهذه الملفات والمجلدات تمثل.

- ملف Top 4 features: بيانات سريرية للمرضى مع التشخيص النهائي الخاص بالنموذج الموافق 4 ميزات.
- ملف Top 8 features: بيانات سريرية للمرضى مع التشخيص النهائي الخاص بالنموذج الموافق 8 ميزات.
- ملف Top 11 features: بيانات سريرية للمرضى مع التشخيص النهائي الخاص بالنموذج الموافق ل 11 ميزة.
- مجلد لتخزين ملفات Pdf: لتخزين التقارير الطبية بصيغة pdf.

3.5 البنية المعمارية المعتمدة للنظام

من المهم قبل البدء في بناء أي نظام برمجي تحديد منهجية واضحة للبناء. بهدف الوصول إلى رماز مصدري قابل للإختبار والتعديل بسهولة واحد من افضل الخيارات الممكنة للإنشاء نظام يحقق لهذه الشروط هو تنجيز وفق المعمارية متعددة الطبقات Layered Architecture.

1.3.5 البنية المتعددة الطبقات

نمط تصميمي معماري يهدف لبناء نظام مقسم لعدة طبقات حيث تمثل كل طبقة مستوى معيناً من التجريد وتؤدي مجموعة محددة من المسؤوليات والوظائف يقوم هذا النمط على مبدأ فصل الاهتمامات (Separation of Concerns) ، حيث يتم عزل منطق العرض عن منطق الأعمال عن منطق الوصول إلى البيانات، مما يسهل عملية التطوير والصيانة والتوسع والاختبار.

1.1.3.5 خصائص النظام المبني وفق Layered Architecture

يتميز النظام المبني وفق البنية متعددة الطبقات بمجموعة من الخصائص الأساسية، يمكن تلخيصها فيما يلي:

أولاً: خصائص التنظيم والهيكلية يعتمد النظام على تقسيم هرمي للوظائف، مع فصل منطقي واضح بين مكوناته، وتتميز كل طبقة بوضوح مسؤولياتها وتنظيمها وفقاً للوظيفة.

ثانياً: خصائص التبعية والاتصال الطبقة العليا تعتمد على الطبقة السفلى، مما يضمن تبعيات أحادية الاتجاه. تتواصل الطبقات عبر إستدعاءات مباشرة، وتُقدّم كل طبقة واجهة محددة تُخفي تفاصيل التنفيذ الداخلية.

ثالثاً: خصائص الصيانة والتطوير تتميز البنية بسهولة الصيانة والاختبار والتطوير المتوازي حيث يمكن لفِرَق مختلفة العمل على طبقات مختلفة في نفس الوقت.

رابعاً: خصائص المرونة والتوسع توفر البنية مرونة تقنية عالية (استخدام تقنيات مختلفة في كل طبقة)، وقابلية للتوسع (توسيع كل طبقة بشكل مستقل)، وقابلية للإضافة والاستبدال طالما بقيت الواجهات كما هي.

خامساً: خصائص الجودة والأداء يقوم النظام على مبدأ فصل الاهتمامات، مما يُقلل التعقيد، ويوحد المعايير، ويعزل الأخطاء داخل الطبقة التي حدثت فيها، مع أداء مقبول بفضل الاتصال المباشر بين الطبقات.


تساهم هذه الخصائص مجتمعة في جعل النظام أكثر قابلية للفهم والصيانة والتطوير، مع الحفاظ على مرونة كافية للتكيف مع المتطلبات المستقبلية.

يتكون النظام في هذا النمط المعماري من أربع طبقات رئيسية (قد تزيد أو تقل حسب احتياجات النظام)، مرتبة من الأعلى (الأقرب إلى المستخدم) إلى الأسفل (الأقرب إلى البيانات)

- طبقة العرض (Presentation): الطبقة المسؤولة عن عرض البيانات واستقبال مدخلات المستخدم هي الواجهة التي يتفاعل معها المستخدم.
- طبقة الأعمال (Business Layer): هي الطبقة التي تحتوي منطق الأعمال وقواعد العمل.
- طبقة الوصول للبيانات (Data Access Layer): هي الطبقة المسؤولة عن تخزين واسترجاع البيانات.
- طبقة البيانات (Data Layer): هي التخزين الفعلي للبيانات في النظام وتشمل قواعد البيانات والملفات.

يقوم هذا النمط المعماري على قاعدة أساسية تُعرف بقاعدة التبعية (Dependency Rule) الطبقة العليا تعتمد على الطبقة السفلى، ولا تعتمد الطبقة السفلى على الطبقة العليا أي أن اتجاه التبعية يكون من الأعلى إلى الأسفل، وهذا يضمن:

- سهولة الاختبار: يمكن اختبار كل طبقة بشكل منفصل.
- وضوح المسؤوليات: كل طبقة تعرف فقط ما تحتاجه من الطبقات التي تحتها.




الشكل 18 التبعية بين الطبقات

2.3.5 بنية النظام

بعد الدراسات التحليلية والتصميمية، يمكن الوصول إلى البنية النظامية النهائية المصممة وفق نمط المعمارية متعددة الطبقات (Layered Architecture)، والتي تجمع بين التنظيم الطبقي وفصل المسؤوليات لضمان نظام طبي متكامل لتشخيص أمراض القلب وإدارة قوالب التقارير الطبية، يتكون النظام من جزئين رئيسيين: واجهة مستخدم Front-end وخادم Back-end يتولى معالجة الطلبات وتنفيذ منطق الأعمال حيث يتفاعل المستخدم (الطبيب) مع واجهة المستخدم التي ترسل طلبات HTTP إلى طبقة بوابة API Layer في الخادم المسؤولة عن استقبال الطلبات وتوجيهها إلى الوحدات المناسبة.

وتمثل طبقة منطق الأعمال Business Logic Layer قلب النظام حيث تتم فيها المعالجات والعمليات وقواعد العمل الأساسية مثل التشخيص وإدارة البيانات، والتي تعتمد بدورها على طبقة البنية التحتية Infrastructure المسؤولة عن التعامل مع قاعدة البيانات ونظام الملفات في طبقة التخزين Storage Layer التي يتم فيها التخزين الفعلي للبيانات وملفات المرضى والتقارير المصدرة وقواعد البيانات. تعزز هذه البنية مع أنماط التصميم المستخدمة فصل المسؤوليات، وقابلية الصيانة، وقابلية التوسع، حيث يمكن إضافة نماذج جديدة أو أنواع جديدة دون التأثير على المكونات الموجودة.



الشكل 19 مخطط النظام

الفصل السادس

النظام الذكي وتحديد المنهجية وتطبيقها

في هذه الفصل سيتم توضيح آلية العمل المتبعة.

1.6 آلية العمل

في الفقرات القادمة سيتم توضيح خطوات العمل المتبعة بهدف تنجيز النظام.

1.1.6 النماذج الخاصة بالبيانات السريرية

قمنا بالعمل على عدة مجموعات بيانات خاصة بالبيانات المهيكلة السريرية سيتم توضيح منهجية العمل على كل منها .

1.1.1.6 مجموعة البيانات الأولى

اختيار مجموعة البيانات من Kaggle

تمثل مجموعة البيانات مرضى القلب والأوعية الدموية Cardiovascular Disease Dataset المتوفرة على منصة Kaggle مصدراً غنياً لتدريب نماذج الصنعي في مجال الطبي والتي تحتوي على 70,000 سجل لمرضى. تتضمن البيانات 11 متغيراً (متنوعة بين القياسات الحيوية، المؤشرات السريرية، وعوامل نمط الحياة) ومتغيراً هدفيّاً ثنائياً (cardio) شبه متوازن يشير إلى وجود مرض قلبي وعائي من عدمه.

تصنيف الميزات كالتالي:

الجدول 19 الميزات في مجموعة البيانات

الوصف	اسم الميزة	نوع الميزة
العمر بالأيام	Age	الهدف (Objective)
الطول (سم)	Height	
الوزن (كغ)	Weight	
جنس المريض (1: نساء، 2: رجال)	Gender	
ضغط الدم الانقباضي	ap_hi	الفحص (Examination)
ضغط الدم الانبساطي	ap_lo	
قيمة ترتيبية (1: عادي، 2: أعلى، 3: أعلى بكثير)	cholesterol	
قيمة ترتيبية مثل الكوليسترول	gluc	
تدخين المريض (ثنائي)	smoke	الذاتي (Subjective)
تناول الكحول (ثنائي)	alco	

النشاط البدني (ثنائي)	active	
وجود المرض: 0 = لا يوجد، 1 = يوجد	cardio	الهدف (Target)

تجهيز مجموعة البيانات

خلال التحليل الاستكشافي والإحصائي للمتغيرات اكتشفنا وجود عدة مشاكل في البيانات الخام تم تطبيق مجموعة من الخطوات على البيانات بهدف تحسين جودة البيانات وتصبح مناسبة لتدريب النماذج.

عملية التنظيف التحضير :

- إزالة عمود المعرف للسجل لأنه غير متعلق بالمسألة.
- تحويل العمر من الأيام للسنوات.
- إزالة الصفوف التي تحوي قيم مستحيلة طبيياً للضغط الانقباضي والانبساطي.
- إزالة الصفوف المكررة .
- التحقق من صحة القيم للمتغيرات الفئوية.
- تصفية الوزن والطول لقيم المستحيلة التي تم حذفها.

بعد التحليل الأحادي للمتغيرات انتقلنا لتحليل العلاقات بين السمات المختلفة مع بعضها ومع الهدف لفهم العوامل الرئيسية المؤثرة في الإصابة بأمراض القلب والاعوية الدموية مع تصورات بصرية لإكتشاف الأنماط والإرتباطات الخفية منها مصفوفة الارتباط الحرارية التي تهدف لإظهار العلاقات الخطية بين جميع المتغيرات في البيانات و تحديد قوة واتجاه الارتباط تبين وجود ارتباط قوي بين ضغط الدم الانقباضي والانبساطي إضافة لارتباط كل من الوزن والعمر والضغط الانبساطي والانقباضي مع الهدف مما يوجه الانتباه لأهميتها في النمذجة اللاحقة . كما اظهر ارتباط سلبي بين المرض ومتغير التدخين وشاربي الكحول على غير المتوقع بتحليل العوامل المربكة تبين أن المدخنون وشاربي الكحول في هذه البيانات هم مجموعة هم أصغر سناً، وأقل وزناً، وأكثر نشاطاً بدنياً. من غير المدخنين وغير شاربي الكحول هذا يشير غالباً إلى أن المدخنون غير الأصحاء ماتوا في سن مبكرة لم يتم تضمينهم في البيانات.

وتم دراسة عوامل الخطر أي المتغيرات التي ترتبط بزيادة احتمال الإصابة بالمرض، مثل: ضغط الدم الانقباضي، الكوليسترول، السكري، مؤشر كتلة الجسم، التدخين. وتم تحليل انتشار هذه العوامل داخل في كلا الجنسين.

وتم تطبيق تحليل طبقي تم تصنيف البيانات حسب الجنس و ثلاث فئات عمرية وتم إجراء دراسة نسبة الإصابة بالمرض وعوامل الخطر و تطبيق تقنيات التجميع العنقودي (Clustering) تهدف إلى تقسيم الأفراد إلى مجموعات متشابهة (عناقيد) بناءً على متغيرات متعددة في هذا التحليل، تم استخدام خوارزمية K-Means لتجميع الأفراد، وحساب نسبة المرضى في كل عنقود، مما يعطي رؤية أعمق لأنماط المجموعات الفرعية الخفية.

تم إنشاء ميزات جديدة من الميزات الموجودة

- مؤشر الكتلة BMI يحسب من الطول والوزن.
- تحويل العمر لفئات عمرية.

فضاءات السمات واختيار الميزات.

بعد تحليل العلاقات بين المتغيرات بشكل مفصل ننتقل لإزالة المتغيرات غير المرتبطة التي تؤثر سلباً على الإداء وتحديد المجموعة المثلى من الميزات المستقلة عن بعضها والمتعلقة بالمسألة التي تحسن أداء النموذج وتزيد قابلية التفسير وتجنب النموذج فرط التخصص تم تطبيق عدة طرق لإختيار الميزات.

- المعلومات المتبادلة Mutual Information تقيس كمية المعلومات التي تحملها الميزة عن الهدف بغض النظر نوع العلاقة فكانت مجموعة الميزات بالترتيب هي (الضغط الانقباضي والانبساطي -العمر - الكوليسترول- مؤشر الكتلة -الوزن).
- F-statistic تقيس الفروق بين مجموعات المرضى والأصحاء كانت المجموعة بالترتيب (الضغط الانقباضي والانبساطي -العمر - الكوليسترول- مؤشر الكتلة).
- Random Forest Importance تقيس أهمية الميزات في نموذج Random Forest بناء على مدى مساهمتها في تقليل عدم النقاء (Gini Impurity) فكانت المجموعة بالترتيب (مؤشر الكتلة -الضغط الانقباضي -العمر -الوزن - الطول - الضغط الانبساطي).
- Recursive Feature Elimination (RFE) يحذف الميزات الأقل أهمية بشكل متكرر فكانت المجموعة (العمر - الطول - الوزن - الضغط الانقباضي - الضغط الانبساطي - مؤشر الكتلة)
- تجميع من جميع الطرق (Consensus Ranking) أي اخذ متوسط الترتيب للميزات المختارة في الطرق الأربعة السابقة المجموعة الناتجة (الضغط الانقباضي - العمر - الضغط الانبساطي - مؤشر الكتلة - الكوليسترول - الوزن).

آلية التدريب

تحضير البيانات للنموذج توحيد البيانات Data Standardization.

التطبيع Normalization تطبيق التطبيع على الميزات العددية لتوحيد المقاييس وتحسين التقارب وتسريع التدريب ومنع الإنحياز للميزات ذات القيم الكبيرة تم تطبيق StandardScaler (Z-score).

قمنا بإجراء عدة تجارب على ست خوارزميات تعلم آلي مختلفة على مجموعة بيانات أمراض القلب، مع دراسة تأثير عدد الميزات على أداء النماذج. تم اختبار أربع مجموعات مختلفة من الميزات وست خوارزميات تعلم آلي

(Random Forest- KNN – Decision Tree – Gradient Boosting – XGBoost – LightGBM)
مع ضبط المعاملات الفائقة.

تجهيز مجموعة التدريب

تمت التجارب على البيانات النظيفة عدد السجلات 68.647 سجل توزيع المتغير الهدف 50.52% أصحاء، 49.48% مرضى .
مجموعات الميزات المستخدمة تم اختبار 4 مجموعات من الميزات لدراسة تأثير عدد الميزات على الأداء.
يظهر الجدول التالي المجموعات.

الجدول 20 مجموعات الميزات المختارة

المجموعة	الميزات	عدد الميزات	الوصف
Set 1	ap_hi – age – bmi	3	الميزات الأكثر أهمية
Set 2	ap_hi – age – bmi – ap_lo – cholesterol	5	إضافة مؤشرات سريرية
Set 3	ap_hi – age – bmi – ap_lo – cholesterol – active – smoke	7	إضافة عوامل نمط الحياة
Set 4 (All 11)	جميع الميزات الأصلية	11	المجموعة الكاملة

نظرا لكون أداء النماذج لمجموعة البيانات السابقة غير مرضي على الرغم من أن مجموعة بيانات هذه توفر حجماً كبيراً وتوزيعاً متوازناً، إلا أن جودة البيانات، محدودية الميزات، والأداء غير الكافي للنماذج أفضل دقة 73% يجعلها غير مناسبة للتطبيقات السريرية الحقيقية. سنبحث عن مجموعة بيانات أكثر شمولاً وموثوقية لبناء نماذج ذات أداء قوي للتطبيقات الطبية الفعالية.

2.1.1.6 مجموعة البيانات الثانية

قمنا بالبحث عن مجموعات بيانات سريرية لتصنيف أمراض القلب. وجدنا مجموعة البيانات Heart Disease Dataset.

اختيار مجموعة البيانات من Kaggle

تمثل مجموعة البيانات Heart Disease Dataset لمرضى القلب هي مجموعة بيانات مركبة تم إنشاؤها بدمج خمس مجموعات بيانات شهيرة و مستقلة لعدة مراكز صحية عالمية لأمراض القلب (Cleveland – Hungarian – Switzerland – Long

(Beach – Stalog) يجعل هذه المجموعة المتنوعة مصدر ثري لتدريب نماذج ذكية تتميز بقابلية تعميم كبيرة لتصنيف امراض القلب. تتضمن 11 متغيراً (متنوعة بين القياسات الحيوية، المؤشرات السريرية) ومتغيراً هدفاً ثنائياً (target) بتوزيع شبه متوازن يشير إلى وجود مرض قلبي من عدمه.

تصنيف الميزات كالتالي:

الجدول 21 الميزات في مجموعة البيانات

المدى	الوصف	الوحدة	اسم الميزة
29 - 77	العمر بالسنوات	سنوات	Age
80 - 200	ضغط الدم الانقباضي أثناء الراحة	mm Hg	Resting bp s
0 - 603	الكوليسترول الكلي في الدم	mg/dl	Choleserol
71 - 202	أقصى معدل لضربات القلب أثناء الجهد	bpm	Max heart rate
-2.6 - 6.2	انخفاض ST يسببه الجهد مقارنة بالراحة	-	Oldpeak

الجدول 22 الميزات في مجموعة البيانات

الوصف	القيم	اسم الميزة
الجنس	0 : female 1 : male	sex
سكر الدم للصائم (fasting blood sugar > 120 mg/dl) if	0 : no 1 : yes	fasting blood sugar
1 = yes ; 0 = no	0, 1	exercise angina
نوع ألم الصدر	1 : Typical Angina 2 : Atypical Angina 3 : Non-anginal Pain 4 : Asymptomatic	Chest pain type
نتائج تخطيط القلب	0 : normal 1: ST wave abnormality 2: definite left ventricular	Resting ecg

ST slope	1 : upsloping : flat2 3: downsloping	ميل المقطع ST اثناء الجهد
Tareget	1: heart disease 0 : normal	الهدف

تجهيز مجموعة البيانات

تم تحميل مجموعة البيانات من موقع Kaggle ملف بصيغة csv تم التحقق من صحة التحميل وخلال استكشاف البيانات واجراء بعض التحليلات تبين وجود عدة مشاكل فيها تم تطبيق مجموعة من الخطوات على البيانات بهدف تحسين جودتها لتصبح مناسبة للنمذجة .

عملية التنظيف التحضير :

- إزالة عمود المعرف للسجل لأنه غير متعلق بالمسألة .
- إزالة الصفوف المكررة كي لا تسبب مشاكل مثل انحياز النموذج للبيانات المكررة.
- تعويض المتغيرات التي تحوي قيم مفقودة باستخدام تقنية KNN Imputer الذي يعوض القيم المفقودة بمتوسط اقرب خمس جيران.
- التحقق من صحة القيم للمتغيرات الفئوية.

تم تطبيق التحليل الأحادي للمتغيرات ودراسة القيم الشاذة مع تصورات مثل مقارنة توزيع المتغيرات قبل وبعد التنظيف لاحظنا قبل التنظيف تظهر القيم الصفيرية للكوليسترول كذروة غير طبيعية مما يشوه التوزيع الطبيعي للبيانات بعد التنظيف اختفت الذروة غير الطبيعية واصبح التوزيع اكثر سلاسة وطبيعية ثم انتقلنا لتحليل العلاقات بين السمات المختلفة مع بعضها ومع الهدف لفهم العوامل الرئيسية المؤثرة في الإصابة بأمراض القلب مع تصورات بصرية لاكتشاف الأنماط و الارتباطات الخفية منها مصفوفة الارتباط الحرارية التي تهدف ل اظهار العلاقات الخطية بين جميع المتغيرات في البيانات و تحديد قوة واتجاه الارتباط تبين وجود ارتباط قوي بين chest pain و st slope و oldpeak مع الهدف مما يوجه الانتباه لاهميتها في النمذجة اللاحقة .

فضاءات السمات واختيار الميزات

بعد تحليل العلاقات بين السمات بشكل مفصل ننتقل لدراسة المتغيرات غير المرتبطة التي تؤثر سلباً على الاداء وتحديد المجموعة المثلى من الميزات المستقلة عن بعضها والمتعلقة بالمسألة التي تحسن أداء النموذج والتخلص من الضوضاء وتزيد قابلية التفسير وتجنب النموذج فرط التخصص تم تجريب عدة طرق لاختيار الميزات

- المعلومات المتبادلة Mutual Information تقيس كمية المعلومات التي تحملها الميزة عن الهدف بغض النظر نوع العلاقة فكانت مجموعة الميزات بالترتيب هي
(ST slope – exercise angina – chest pain type).
- الانحدار اللوجستي في الانحدار اللوجستي، يمثل المعامل (coefficient) لكل ميزة وزنها في المعادلة الخطية التي تتنبأ باحتمالية الانتماء لفئة معينة. فكانت النتيجة
(ST slope – chest pain type – sex)
- Random Forest Importance تقيس أهمية الميزات في نموذج Random Forest بناء على مدى مساهمتها في تقليل عدم النقاء (Gini Impurity) بالترتيب
(ST slope – chest pain type – oldpeak).
- Recursive Feature Elimination (RFE) يحذف الميزات الأقل أهمية بشكل متكرر فكانت المجموعة
(ex, chest pain type, fasting blood sugar, exercise angina, oldpeak, ST slope)
- SelectKBest (F-Score) تستخدم اختبار ANOVA (تحليل التباين) لحساب نسبة التباين بين المجموعات إلى التباين داخل المجموعات. تقيس F-Score قدرة الميزة على التمييز بين فئات الهدف المختلفة فكانت النتيجة. (ST slope – exercise angina – chest pain type).

آلية التدريب

تجهيز مجموعة التدريب

تم تحميل البيانات بعد التنظيف تحتوي البيانات على 918 سجل و 12 متغير. و تم تطبيق تقنية التطبيع (StandardScaler) على جميع الميزات الرقمية. هذه الخطوة مهمة للخوارزميات الحساسة لمقياس البيانات .

التطبيع Normalization تطبيق التطبيع على الميزات العددية لتوحيد المقاييس وتحسين التقارب وتسريع التدريب ومنع الانحياز للميزات ذات القيم الكبيرة .

$$z = (x - \mu) / \sigma$$

حيث:

σ : الانحراف المعياري - μ : المتوسط

النماذج المستخدمة

قمنا باجراء عدة تجارب على سبعة خوارزميات تعلم آلي مختلفة، تغطي النماذج القائمة على الأشجار، القائمة على المسافات، ونماذج الحدود الفاصلة على مجموعة بيانات أمراض القلب، مع دراسة تأثير عدد الميزات على أداء النماذج حيث تم اختيار ست مجموعات من الميزات. (KNN, Decision Tree, Gradient Boosting, Logistic Regression, XGBoost, SVM, Random Forest) مع ضبط المعاملات الفائقة باستخدام تقنية Grid Search التي تقوم بالبحث عن أفضل مجموعة من المعاملات (hyperparameters) للنموذج. تقوم بتجربة جميع التركيبات الممكنة لقيم المعاملات المحددة، وتقييم كل تركيب باستخدام التحقق المتقاطع (Cross-Validation)، ثم اختيار التركيبة التي تعطي أفضل أداء.

يظهر الجدول التالي المجموعات .

الجدول 23 مجموعات الميزات المختارة

المجموعة	الميزات	العدد	الوصف
Set1_Top_6	ST slope, chest pain type, exercise angina, oldpeak, max heart rate, sex	6	أفضل 6 ميزات من الترتيب النهائي
Set2_Top_8	Set1 + fasting blood sugar, cholesterol	8	إضافة ميزات مخبرية مهمة
Set3_Top_10	Set2 + age, resting bp s	10	إضافة الميزات الديموغرافية والحبيوية
Set4_All_11	جميع الميزات الأصلية	11	مرجع للمقارنة
Set5_Clinical	chest pain type, resting bp s, max heart rate, oldpeak, ST slope	5	ميزات سريرية بحتة (بدون مخبرية)
Set6_Minimal	ST slope, exercise angina, chest pain type, oldpeak	4	أقل عدد ممكن من الميزات

2.1.6 نماذج الخاصة بتخطيط الكهربي القلب

قمنا بالعمل على عدة مجموعات بيانات لتخطيط القلب سيتم توضيح منهجية العمل على كل منها .

1.2.1.6 مجموعة البيانات الأولى

اختيار مجموعة البيانات من Kaggle

تمثل مجموعة البيانات "ECG Analysis" المتوفرة على منصة Kaggle مصدراً غنياً لتدريب نماذج الذكاء الاصطناعي في المجال الطبي والتي تحتوي على صور تخطيط قلب (ECG) مصنفة إلى أربع فئات مختلفة. تتكون مجموعة البيانات من 928 صورة موزعة على أربع فئات هي ضربات قلب غير طبيعية Abnormal Heartbeat 233 صورة و Myocardial Infarction احتشاء عضلة القلب 239 صورة بالإضافة لـ Normal طبيعي 284 و History of MI 172 صورة تاريخ احتشاء عضلة القلب تتضمن كل صورة 12 مسار Lead تقدم الصور في هذه المجموعة بتنسيق JPG مع تنظيم الملفات ضمن مجلدات حسب الفئة الموافقة للصورة يسهل عملية التحميل والمعالجة حيث يمكن التعامل مع كل مجلد كتسمية label مباشرة للصورة .

يمكن الاستفادة من هذه المجموعة في تصنيف صور تخطيط الكهربي للقلب من خلال بناء نموذج يصنف الصور الى أربع فئات.

من خلال هذه المواصفات كانت مجموعة البيانات هذه مناسبة لبناء نموذج لتصنيف صور تخطيط الكهربي للقلب.

النموذج المستخدم

كما هو واضح بالدراسة المرجعية فإن النموذج المقترح لهذه العمل هو نموذج يعتمد على الشبكات العصبية الالتفافية CNN التي برزت كأداة قوية وفعالة لتحليل الصور وذلك بفضل قدرتها على استخراج الميزات المكانية من البيانات ذات البنية الشبكية كالصور والتعبير عنها بتمثيلات غنية. نموذج CNN كما أشرنا سابقاً يحتوي رمزاً للصورة.

آلية التدريب

بنية النموذج النهائي

تم تدريب النماذج وفق عدة بنى من الشبكات العصبية الالتفافية (CNN) شملت نماذج تقليدية مصممة خصيصاً للمهمة ونماذج مدربة مسبقاً تم الاستفادة من معارفها العامة المكتسبة على مجموعات ضخمة من البيانات (Transfer Learning) وتمت مقارنة أداء النماذج المختلفة وهي: (Custom CNN – DenseNet121 – ResNet50 – MobileNet)

وللوصول إلى البيئة النمذجية المثلى أجريت مجموعة من التجارب المنهجية على عدة نماذج واستراتيجيات معالجة مسبقة وعلى أعداد مختلفة الفئات المستهدفة (التفاصيل موضحة في قسم التجارب العملية) بعد تحليل النتائج تم الإعتماد على البنية التالية :

DenseNet121 كمرّز للصور Image Encoder حيث تم إعتماد طريقة نقل التعلم المرحلة الأولى تجميد الطبقات الأساسية بحيث تظل أوزانها ثابتة ولا تتغير وتدريب الرأس المخصص للتصنيف فقط المكون من Dense – Dropout – BatchNormalization استمرت هذه المرحلة لمدة 20 دورة epochs للاستفادة من المعرفة العامة التي يملكها النموذج على مهمة كبيرة كأساس لمهمتنا المحددة (تصنيف صور تخطيط كهربائي للقلب) والمرحلة الثانية الضبط الدقيق (Fine-tuning) تم إلغاء تجميد جزء من الطبقات الأساسية وجعلها قابلة للتدريب مع معدل تعلم أقل لتجنب فقدان المعرفة المكتسبة سابقاً استمرت هذه المرحلة لمدة 10 دورات epochs مما يسمح للنموذج بالتكيف مع خصائص الصور في مجموعة البيانات. وتحسين الدقة من خلال ضبط الأوزان بما يتناسب مع المهمة، ويحسن الأداء خاصة مع صغر حجم مجموعة البيانات المتاحة وقد أثبتت هذه الاستراتيجية فعاليتها في تحسين أداء النموذج مقارنة بالتدريب من الصفر.

تجهيز مجموعة التدريب

قبل البدء في عملية التدريب تم تطبيق مجموعة من الخطوات التحضيرية على الصور بهدف توحيد الشكل العام للبيانات وضمان توافقها مع النماذج.

خصائص الصور :

- جميع الصور بتنسيق JPG .
- صور تحوي 12 مسار كل منها يمثل منظور للقلب.
- الصور ملونة RGB .
- جميع لصور موحدة الأبعاد (2213*1572 pixel) .

التحديات:

- خلال التحليل الاستكشافي للبيانات تم إجراء عملية فحص شاملة للصور لكشف وجود صور مكررة باستخدام خوارزمية SHA-256 لتوليد بصمة رقمية فريدة لكل صورة، ثم مقارنة البصمات لتحديد الصور المكررة وجدنا تكرار كبير بالصور تحتوي مجموعة البيانات على 437 صورة مكررة أي 47% من إجمالي البيانات.
- عدم توازن الفئات تفاوت كبير بين الفئات بعد التنظيف أي حذف المكرر الصور الفريدة بعد التنظيف 491 صورة موزعة على الشكل التالي :

- ضربات قلب غير طبيعية 233 صورة.

- طبيعي 142 صورة.
- احتشاء عضلة القلب 30 صورة.
- تاريخ احتشاء عضلة القلب 86 صورة.

يوضح الجدول التالي تحليل الصور المكررة في مجموعة البيانات

الجدول 24 تحليل الصور المكررة

الفئة	قبل التنظيف	بعد التنظيف	المحذوف	نسبة الحذف
Abnormal	233	233	0	0.0%
MI	239	30	209	87.4%
Normal	284	142	142	50.0%
History_MI	172	86	86	50.0%

قمنا بعدة تجارب في التدريب على عدد الفئات المأخوذة بعين الاعتبار

- نماذج تصنيف ثنائي فئتين طبيعي وغير طبيعي.
- نموذج تصنيف ثلاث فئات طبيعي وغير طبيعي وتاريخ احتشاء.
- نموذج تصنيف للأربع فئات .

المعالجة المسبقة للصور :

- قص أجزاء الصورة Cropping من الأعلى 18% – 20% ومن الأسفل الأعلى 6% – 7% إزالة المناطق غير المفيدة (قالب معلومات المريض الترويسة مقياس الرسم) كي لا تسبب ضوضاء أثناء التدريب.
- إزالة الضوضاء مع الحفاظ على الحواف Median Filter أو Gaussian Blur تنعيم وتقليل الضوضاء
- تحسين التباين المحلي CLAHE لتحسين الرؤية المحلية للمسارات في ECG .
- إعادة التحجيم تم تعديل أبعاد جميع الصور لتكون بقياس موحد لتناسب مع النماذج 224*224 بكسل.
- تحويل الصور الى مصفوفات عددية Tensors مناسبة لشبكة الرؤية.
- التطبيع Normalization تطبع الصور لتوحيد القيم و تقارب أسرع واستقرار بالتدريب تم تطبيق Min-Max Normalization لتصبح بالمجال [0,1] .

تم تطبيق تقنيات زيادة البيانات (Data Augmentation) لتحسين تعميم النموذج وتقليل فرط التخصص وتشمل هذه التقنيات :
القلب الأفقي (Horizontal Flip) بنسبة 50% التدوير (Rotation) بزاوية 15 درجة، التكبير/التصغير (Zoom) بنطاق

0.85-1.15، وتعديل السطوع (Brightness) بنسبة 20%. تطبق هذه التقنيات بشكل عشوائي أثناء التدريب لزيادة تنوع البيانات وتحسين قدرة النموذج على التعامل مع الظروف المختلفة لصور تخطيط القلب.

تحميل البيانات وتنسيق الدفعات

تم تصميم محمل بيانات (ECGDataLoader) مخصص لتحميل الصور والتصنيفات المقابلة لها .

- تم تنظيم مجموعة الصور قبل التنظيف ضمن مجلدات مصنفة حسب اسم الفئة بالإضافة لتنظيم مجموعة الصور النظيفة الحالية من التكرار في مجلدات تحوي اسم الفئة الموافقة.
- آلية إنشاء الدفعات (Mini-Batch Generation) : تم استخدام مولد البيانات DataGenerator المخصص لتوليد دفعات بشكل فعال أثناء التدريب وفق الخطوات التالية:
- تحيئة المولد من خلال استلام DataFrame الذي يحتوي على مسارات الصور والتصنيفات وتحديد حجم الدفعة (Batch Size) وهو عدد الصور التي تتم معالجتها في كل خطوة تدريب ثم تحديد ما إذا كان سيتم تطبيق زيادة البيانات (Augmentation) على الصور أم لا وإنشاء مصفوفة من المؤشرات (Indices) وخلطها عشوائياً إذا كان الخلط مفعلاً .
- حساب عدد الدفعات يتم حسابه بكل epoch عبارة عن نسبة عدد الصور ل حجم الدفعة.
- توليد دفعة (Batch Generation) اختيار المؤشرات اختيار مجموعة من المؤشرات العشوائية أو المتتالية في حالة عدم الخلط لتشكيل الدفعة.
- تحميل الصور : لكل مؤشر يتم تحميل الصورة من المسار المحدد باستخدام دالة المعالجة المسبقة. تطبيق سلسلة المعالجة المسبقة.
- تطبيق زيادة البيانات : إذا كان الخلط مفعلاً، يتم تطبيق تقنيات زيادة البيانات.
- تحويل التسميات : تحويل التسميات إلى صيغة One-Hot Encoding.
- تكوين الدفعة : تجميع الصور والتسميات في مصفوفات NumPy وإرجاعها كدفعة (Batch) جاهزة للتدريب.
- خلط البيانات (Shuffle After Each Epoch) يتم خلط مؤشرات البيانات بشكل عشوائي في نهاية كل دورة لضمان تنوع البيانات.

التدريب

في سياق مشروعنا تُعدّ صور تخطيط القلب (ECG) مثلاً نموذجياً للبيانات ذات الخصائص المكانية المهمة التي تتناسب مع قدرات CNNs، فهي تحتوي على أنماط محلية واضحة مثل شكل موجات P ، QRS ، T، وعلاقات بين هذه الموجات (كالسعة والفترات الزمنية)، تتيح الشبكات العصبونية الالتفافية اكتشاف هذه الأنماط المكانية تلقائياً دون الحاجة إلى هندسة يدوية للسمات، مما يجعلها خياراً مناسباً لتحليل وتصنيف صور ECG. قمنا بعدة تجارب على بنى ونماذج مختلفة من الشبكات العصبونية الالتفافية (CNN) تم اعتماد تم

تقسيم البيانات موحد في جميع التجارب تقسم البيانات إلى ثلاث مجموعات بتقسيم طبقي (Stratified Split) للحفاظ على توزيع الفئات في كل مجموعة بشكل متجانس.

- مجموعة التدريب Training 70% توفر كمية كافية من البيانات لتعلم النموذج.
- مجموعة التحقق Validation 15% كافية لتقييم الأداء وضبط المعلمات.
- مجموعة الاختبار Test 15% توفر تقييماً موثقاً للأداء النهائي للنموذج.

تم تدريب النماذج باستخدام خوارزمية التحسن من نوع آدم Adam وتم اعتماد استراتيجية جدولة معدل التعلم المكونة من مرحلتين، مع تطبيق تقنية ReduceLROnPlateau لخفض معدل التعلم تلقائياً عند توقف تحسن خسارة التحقق.

المرحلة الأولى: نقل التعلم (Transfer Learning)

في هذه المرحلة، تم استخدام معدل تعلم 10^{-3} لتدريب الرأس المخصص للتصنيف فقط، مع تجميد الطبقات الأساسية للنموذج. هذا المعدل المرتفع نسبياً يسمح للرأس المخصص بالتعلم السريع للملامح الخاصة بصور ECG، مع الاستفادة من المعرفة العامة للنموذج المدرب مسبقاً على ImageNet. استمرت هذه المرحلة لمدة 20 (Epochs).

المرحلة الثانية: الضبط الدقيق (Fine-tuning) بعد انتهاء المرحلة الأولى، تم خفض معدل التعلم إلى 10^{-4} و 10^{-5} لتدريب النموذج بالكامل. هذا المعدل المنخفض يضمن إجراء تعديلات دقيقة على الأوزان دون فقدان المعرفة المكتسبة سابقاً، مما يسمح للنموذج بالتكيف مع خصائص صور ECG مع الحفاظ على الاستقرار. استمرت هذه المرحلة لمدة 10 (Epochs) دورات إضافية.

الجدول 25 قيم معدل التعلم في التجارب

التجربة	معدل التعلم (المرحلة 1)	معدل التعلم (المرحلة 2)	ReduceLR
CNN مخصص	10^{-4}	لم يتغير	تم استخدامه
EfficientNetB0	10^{-3}	10^{-5}	تم استخدامه
ResNet50	10^{-3}	10^{-5}	تم استخدامه
DenseNet121	10^{-3}	10^{-5}	تم استخدامه

موازنة الفئات

تعاني مجموعة البيانات لدينا من عدم توازن بين الفئات بعد التنظيف حيث تكون بعض الفئات فيها أكثر شيوعاً من غيرها. حيث بلغت نسبة عدم التوازن 1.64:1 بين الفئة الأكبر والأصغر يؤدي عدم التوازن يؤدي إلى تحيز النموذج نحو الفئة الأكبر مما ينتج عنه دقة عالية مضللة مع أداء ضعيف للفئة الأقل تمثيلاً.

تم استخدام Class Weights (أوزان الفئات) كإستراتيجية رئيسية لموازنة الفئات. تعتمد هذه الآلية على إعطاء وزن أكبر للفئات الأقل تمثيلاً أثناء حساب دالة الخسارة، مما يجعل أخطاء هذه الفئات أكثر تكلفة وبالتالي يدفع النموذج للتركيز على تعلمها بشكل أفضل.

حساب الأوزان لكل فئة كالتالي :

$$weight = total_samples / (n_classes \times samples_per_class)$$

حيث :

- total_samples عدد الكلي للعينات
- n_classes عدد الفئات
- samples_per_class عدد العينات لكل فئة

دالة الخسارة

دالة الخسارة المستخدمة في جميع التجارب (Categorical Crossentropy - الإنتروبيا المتقاطعة الفئوية) وهي الدالة القياسية لمشاكل التصنيف المتعدد تعمل على قياس الفرق بين التوزيع الاحتمالي المتوقع والفعلي.

$$Loss = -\Sigma(y_true * \log(y_pred))$$

مع تطبيق موازنة الفئات ClassWeight تم تعديل دالة الخسارة لجعلها أكثر حساسية للفئات الأقل تمثيلاً لتصبح:

$$Loss = -\Sigma(weight * y_true * \log(y_pred))$$

حيث

- y_true التسمية الحقيقية في صيغة One-Hot Encoding
- y_pred الاحتمالية المتوقعة من النموذج
- Log اللوغاريتم الطبيعي
- weight وزن الفئة

الفصل السابع

تجارب على نماذج التعلم

يعرض هذا الفصل معايير التقييم للنماذج مع مجموعة التجارب لكل مجموعة بيانات وعرض التقييمات لعمل كل تجربة بهدف الوصول للنماذج المطلوبة.

1.7 معايير تقييم النتائج

تم استخدام مجموعة من المعايير لتقييم أداء النماذج في كل مجموعات البيانات مع وجود خصوصية لبعضها .

(1) دقة التصنيف **Accurcy** مؤشر للتقييم هو النسبة المئوية للتنبؤات الصحيحة التي قام بها النموذج من إجمالي التنبؤات مفيد في حال البيانات متوازنة.

(2) الدقة التنبؤية **Precision** تمثل النسبة المئوية للتنبؤات الإيجابية الصحيحة من من إجمالي التنبؤات الإيجابية تقيس مدى دقة النموذج عندما يتوقع فئة معينة.

(3) الاسترجاع **Recall** معيار أساسي للتقييم في مسألتنا لأنه يعبر عن الحالات المرضية المكتشفة من إجمالي الحالات تقيس قدرة النموذج على اكتشاف جميع الحالات الإيجابية.

(4) مقياس **F1-Score** هو المتوسط التوافقي بين Precision و Recall ، ويوفر مقياساً واحداً متوازناً لأداء النموذج. يعتبر مناسباً بشكل خاص في حالة عدم توازن بين الفئات.

(5) مصفوفة الارتباك **Confusion Matrix** جدول يوضح أداء النموذج بشكل مفصل من خلال مقارنة القيم الحقيقية و المتوقعة وتساعد لتحليل أخطاء النموذج بشكل مفصل.

		Predicted Class		
		Negative	Positive	
Actual Class	Negative	True Negative (TN)	False Positive (FP) (Type I Error)	Specificity $\frac{TN}{(TN + FP)}$
	Positive	False Negative (FN) (Type II Error)	True Positive (TP)	Recall/Sensitivity $\frac{TP}{(TP + FN)}$
		Negative Predictive Value $\frac{TN}{(TN + FN)}$	Precision $\frac{TP}{(TP + FP)}$	Accuracy $\frac{(TP+TN)}{(TP+FP+TN+FN)}$

الشكل 20 مصفوفة الارتباك


2.7 تجارب مجموعة البيانات (ECG Analysis)

في التجارب الأربعة الأولى تم دراسة التصنيف الثنائي Abnormal - Normal

■ التجربة الأولى CNN مخصص تصنيف ثنائي :

تم استخدام مجموعة البيانات النظيفة بعد عملية إزالة الصور المكررة، حيث بلغ إجمالي الصور 375 صورة موزعة كالتالي : 142 صورة Normal - 233 صورة Abnormal .

تم تقسيم البيانات ما اشرنا سابقا بنسبة 70% للتدريب، 15% للتحقق، و15% للاختبار. وتم تطبيق المعالجة المسبقة التالية (قص أجزاء من الصورة من الأعلى 20% ومن الأسفل 7%) - (تطبيق فلتر الوسيط لإزالة الضوضاء مع نواة حجم 3*3) - (تحسين التباين المحلي ب CLAHE مع clip_limit=2.0, tile_grid_size=(8,8)) تغيير الحجم ل 128*128 وتطبيع قيم البكسلات توحيد القيم لتكون في المجال [0,1] وتحويل ل Tensors، النموذج المستخدم CNN مخصص مكون من 21 طبقة 4 كتل و شبكة متصلة بالكامل وطبقة تصنيف وتم تطبيق استراتيجية موازنة البيانات Class Weight وكالأتي القلب الأفقي (Horizontal Flip) بنسبة 50% التدوير (Rotation) بزاوية 10 درجات في الاتجاهين الموجب والسالب ، التكبير/التصغير (Zoom) بنطاق -0.9 - 1.1، وتعديل السطوع (Brightness) بنسبة 15% زيادة أو نقصان تم التدريب ل 30 دورة مع حجم دفعة 16 ومعدل تعلم 10^{-3} ومحسن Adam.



الشكل 21 بعض الصور بعد تطبيق تقنيات زيادة البيانات

نتائج التجربة الأولى :

الجدول 26 نتائج التجربة الأولى

المقياس	القيمة
دقة الاختبار	61.40%
دقة التدريب	75.2%
الدقة التنبؤية (Precision)	61.4%
الحساسية (Recall)	61.4%
AUC-ROC	0.96

حصل فرط تخصص Overfitting الفجوة بين دقة التدريب (75.2%) ودقة التحقق (37.50%) بلغت 45% النموذج يعاني من فرط تخصص يحفظ البيانات بدلاً من تعلمها. النموذج يعاني من انحياز ل الفئة غير الطبيعي لا يعمم على بيانات جديدة يعود سبب الإفراط بالتخصص لعدة عوامل منها محدودية الصور في مجموعة التدريب غير كافية ليتعلم منها مقارنة بتعقيد بنية النموذج. تُعد هذه النتائج متوافقة مع ما توصلت إليه دراسات سابقة في مجال تحليل صور تخطيط القلب باستخدام نماذج CNN المخصصة، كما النماذج المخصصة غالباً ما تعاني من ضعف الأداء عند تطبيقها على مجموعات بيانات محدودة، مقارنة بالنماذج المدربة مسبقاً (Pre-trained) والتي تستفيد من المعرفة المكتسبة على مجموعات بيانات ضخمة. وتوفر الوقت والموارد من خلال البدء من مرحلة متقدمة من التعلم وهذا ما يفسر الحاجة

إلى اعتماد استراتيجية نقل التعلم (Transfer Learning) في التجارب اللاحقة، للاستفادة من الميزات العامة التي تعلمتها النماذج على مجموعة بيانات ImageNet وتطبيقها على مهمة تصنيف صور ECG.

■ التجربة الثانية ResNet50 تصنيف ثنائي .

تم استخدام مجموعة البيانات النظيفة بعد عملية إزالة الصور المكررة، حيث بلغ إجمالي الصور 375 صورة موزعة كالتالي : 142 صورة Normal - 233 صورة Abnormal .

تم تقسيم البيانات بنسبة 70% للتدريب، و15% للتحقق، و15% للاختبار. و تطبيق سلسلة المعالجة المسبقة الموضحة في الفصل السابق (قص أجزاء من الصورة من الأعلى 20% ومن الأسفل 7%) - (تطبيق فلتر الوسيط لإزالة الضوضاء مع نواة حجم 3×3) - (تحسين التباين ب CLAHE مع $\text{clip_limit}=2.0, \text{tile_grid_size}=(8,8)$) تغيير الحجم ل 224×224 وتطبيع قيم البكسلات توحيد القيم لتكون في المجال $[0,1]$ و مع تطبيق زيادة البيانات Agmentation هي القلب الأفقي (Horizontal Flip) بنسبة 50% التدوير (Rotation) بزاوية 15 درجة في الاتجاهين الموجب والسالب ، التكبير/التصغير (Zoom) بنطاق 0.85-15.1، وتعديل السطوع (Brightness) بنسبة 20% زيادة أو نقصان.

وتم تطبيق استراتيجية موازنة البيانات Class Weight تم اعتماد النموذج ResNet50 كمرمز للصور (Image Encoder) و الاستفادة من الأوزان المدربة مسبقاً. على مجموعة بيانات ImageNet. وإضافة رأس مخصص للتصنيف تم اعتماد استراتيجية نقل التعلم (Transfer Learning) المكونة من مرحلتين الأولى نقل التعلم من ResNet50 تجميد الطبقات الأساسية له وتدريب الرأس فقط اول 20 دورة مع معدل تعلم مرتفع ثم المرحلة الثانية إلغاء تجميد الطبقات العليا وتدريب النموذج بالكامل مع معدل تعلم أقل لمدة 10 دورات.

نتائج التجربة :

الجدول 27 نتائج التجربة الثانية

المقياس	القيمة
دقة الاختبار	77.1%
دقة التدريب	74.5%
الدقة التنبؤية (Precision)	77.2%
الحساسية (Recall)	77.2%
AUC-ROC	88%

أظهرت النتائج تحسن في الأداء مقارنة مع التجربة الأولى حيث انخفض معدل فرط التخصص ويظهر تعميم جيد للنموذج بشكل ملحوظ يعود لعدة عوامل منها استخدام المعرفة المسبقة للنموذج المدرب مسبقاً وتطبيق تقنيات زيادة البيانات أما بالنسبة لقيمتي Preciso و Recall ، فقد تزامنتا عند 77.2% ، مما يعكس أداءً متوازناً للنموذج في اكتشاف الحالات المرضية (Recall) وتجنب الإنذارات الكاذبة (Precision). هذه النتيجة تعد مقبولة سريرياً مقارنة بالتجربة السابقة، حيث ارتفعت الحساسية من 61.4% إلى 77.2% ، مما يعني أن النموذج أصبح قادراً على اكتشاف حوالي 82.5% من الحالات المرضية، وهو تحسن كبير يقلل من خطر تخطي النموذج حالات مرضية.

■ التجربة الثالثة MobileNetV2 .

تم استخدام مجموعة البيانات النظيفة بعد عملية إزالة الصور المكررة، تم اجراء ثلاث تجارب على اعداد مختلفة من الفئات تم تقسيم البيانات بنسبة 70% للتدريب 262 صورة، 15% للتحقق 56 صورة ، و15% للاختبار 57 صورة. تم زيادة بيانات التدريب للفئات لتصبح كل منها 200 باستخدام التقنيات التالية القلب الأفقي (Horizontal Flip) بنسبة 50% التدوير (Rotation) بزاوية 10 درجة في الاتجاهين الموجب والسالب، التكبير/التصغير (Zoom) بنطاق 0.9-1.1، وتعديل السطوع (Brightness) بنسبة 15% زيادة او نقصان. وبالإضافة لتطبيق سلسلة المعالجة المسبقة التالية (قص أجزاء من الصورة من الأعلى 20% ومن الأسفل 7%) - (تطبيق نواة الوسيط لإزالة الضوضاء مع نواة حجم 3*3) - (تحسين التباين ب CLAHE مع clip_limit=2.0, tile_grid_size=(8,8) تغيير الحجم ل 224*224 وتطبيع قيم البكسلات توحيد القيم لتكون في المجال [0,1] وتطبيق زيادة البيانات Agmentation اثناء التدريب لتحسين قابلية التعميم.

تم اعتماد النموذج MobileNetV2 كمرکز للصور (Image Encoder) مع الإستفادة من الأوزان المدربة مسبقاً. تمت إضافة رأس مخصص للتصنيف تم اعتماد استراتيجية نقل التعلم المكونة من مرحلتين الأولى نقل التعلم من MobileNetV2 بتحميد الطبقات الأساسية له وتدريب الرأس فقط اول 20 دورة مع معدل تعلم 10^{-3} المرحلة الثانية ثم إلغاء تحميد جزء من الطبقات العليا وتدريب النموذج بالكامل مع معدل تعلم اقل 10^{-5} .

مع استخدام كل من التقنيات التالية EarlyStopping، ReduceLROnPlateau، و ModelCheckpoint لتحسين عملية التدريب ومنع فرط التخصص.

نتائج التجربة

المجدول 28 نتائج التجربة الثالثة

الدقة	الفئات
92%	Normal/abnormal
75%	3 classes
42%	4 classes

أظهرت نتائج هذه التجربة أظهرت التصنيف الثنائي باستخدام MobileNetV2 حقق دقة ممتازة (92.98%) ولكن انخفضت الدقة بشكل كبير مع زيادة عدد الفئات المهدف من الأسباب قلة العينات للفئات الجديدة أي البيانات غير كافية ضعف التعلم لا يستطيع التمييز بين الفئات وانحياز النموذج لفئات دون غيرها إضافة لفرط تخصص ضعف قدرة عالتعميم النموذج يحفظ لا توجد بيانات كافية لتغطية التنوع.

■ التجربة الرابعة DenseNet121 تصنيف ثنائي .

تم استخدام مجموعة البيانات النظيفة بعد عملية إزالة الصور المكررة، حيث بلغ إجمالي الصور 375 صورة موزعة كالتالي : 142 صورة Normal - 233 صورة Abnormal .

تم تقسيم البيانات بنسبة 70% للتدريب، و15% للتحقق، و15% للاختبار. تم تطبيق oversampling لتصبح كل فئة 200 صورة باستخدام التقنيات التالية القلب الأفقي (Horizontal Flip) بنسبة 50% التدوير (Rotation) بزاوية 10 درجة في الاتجاهين الموجب والسالب، التكبير/التصغير (Zoom) بنطاق 0.9-1.1، وتعديل السطوع (Brightness) بنسبة 15% زيادة او نقصان. وتم تطبيق سلسلة المعالجة المسبقة الموضحة في الفصل السابق (قص أجزاء من الصورة من الأعلى 20% ومن الأسفل 7%) - (تطبيق نواة الوسيط لإزالة الضوضاء مع نواة حجم 3*3) - تغيير الحجم ل 224*224 وتطبيع قيم البكسلات توحيد القيم لتكون في المجال [0,1] لكي يكون التدريب مستقر وتسريع التقارب وقمنا تطبيق زيادة البيانات Agumentation. أثناء التدريب تم اعتماد النموذج DenseNet121 كمرمز للصور (Image Encoder) لإستفادة من الأوزان المدربة مسبقاً تمت إضافة رأس مخصص للتصنيف واعتماد استراتيجية نقل التعلم المكونة من مرحلتين الأولى نقل التعلم DenseNet121 المدرب على Imagenet تجميد الطبقات الأساسية وتدريب الرأس المخصص فقط، أول 20 دورة مع معدل تعلم 10^{-3} المرحلة الثانية تم إلغاء تجميد جزء من الطبقات العليا وإبقاء جزء مجمد وتدريب النموذج بالكامل مع الرأس مع معدل تعلم اقل 10^{-5} . وتم تطبيق استراتيجية موازنة البيانات Class Weight والمحسن من نوع آدم وحجم الدفعة 16 مع استخدام كل من التقنيات EarlyStopping إيقاف التدبيل عند عدم تحسن الأداء و ReduceLROnPlateau خفض معدل التعلم عند التوقف و ModelCheckpoint حفظ أفضل نموذج لتحسين عملية التدريب ووجود طبقات Dropout لمنع فرط التخصص.

نتائج التجربة

المقياس	القيمة
دقة الاختبار	93%
الدقة التنبؤية (Precision)	92.5%
الحساسية (Recall)	92.5%
AUC-ROC	0.972

أظهرت النتائج حقق أعلى دقة اختبار (93%) ممتاز في التدريب لا توجد تقلبات كبيرة في دقة التحقق و Dense Connections فعالة تحسن تدفق التدرج وإعادة استخدام الملامح (AUC-ROC 0.97)، مما يشير إلى قدرة تمييزية ممتازة للنموذج بين الفئتين Normal و Abnormal والنموذج يعمم بشكل جيد لا يوجد فرط تخصص.

■ التجربة الخامسة DenseNet121 تصنيف ل ثلاث فئات .

تم استخدام مجموعة البيانات النظيفة بعد إزالة الصور المكررة، حيث بلغ إجمالي الصور 461 صورة موزعة كالتالي : 142 صورة Normal - 233 صورة Abnormal - 86 صورة History of MI. تم تقسيم البيانات بنسبة 70% للتدريب، 15% للتحقق، و 15% للاختبار.

تم تطبيق oversampling لتصبح كل فئة 200 صورة باستخدام التقنيات التالية بشكل عشوائي القلب الأفقي (Horizontal Flip) بنسبة 50% التدوير (Rotation) بزاوية 10 درجة في الاتجاهين الموجب والسالب، التكبير/التصغير (Zoom) بنطاق 0.9-1.1، وتعديل السطوع (Brightness) بنسبة 15% زيادة أو نقصان.

وتم تطبيق سلسلة المعالجة المسبقة الموضحة في الفصل السابق (قص أجزاء من الصورة من الأعلى 20% ومن الأسفل 7%) - (تطبيق نواة الوسيط لإزالة الضوضاء مع نواة حجم 3×3) - تغيير الحجم ل 224×224 وتطبيع قيم البكسلات توحيد القيم لتكون في المجال $[0,1]$ لكي يكون التدريب مستقر وتسريع التقارب وقمنا تطبيق زيادة البيانات Agmentation. اثناء التدريب تم اعتماد النموذج

تم اعتماد النموذج DenseNet121 كمرکز للصور (Image Encoder) مع الاستفادة من الأوزان المدربة مسبقاً. يتميز بقدرته على منع تلاشي التدرج وإعادة استخدام الميزات. تمت إضافة رأس مخصص للتصنيف الثلاثي وتم اعتماد استراتيجية نقل التعلم المكونة من مرحلتين الأولى نقل التعلم DenseNet121 تجميع الطبقات الأساسية له وتدريب الرأس فقط اول 20 دورة مع معدل تعلم 10^{-3} المرحلة

الثانية الضبط الدقيق تم إلغاء تجميد الطبقات العليا فقط وتدريب النموذج بالكامل مع معدل تعلم اقل 10^{-5} وتم تطبيق استراتيجية موازنة البيانات Class Weight لموازنة الفئات الثلاث وزن اكبر للفئة الأصغر مع استخدام كل من التقنيات EarlyStopping إيقاف التدريب عندما لا يتحسن النموذج لمنع فرط التخصص و ReduceLROnPlateau، تخفيض معدل التعلم عندما يتوقف التحسن و ModelCheckpoint لحفظ أفضل نموذج أثناء التدريب واستخدامه لاحقاً.

نتائج التجربة

المجدول 30 نتائج التجربة الخامسة

المقياس	القيمة
دقة الاختبار	80%
الحساسية (Recall)	78.6%
الدقة التنبؤية (Precision)	78.6%
AUC-ROC	90-97

جدول 31 النتائج حسب الفئة

الفئة	الدقة
Abnormal	86%
Normal	73%
History_MI	77%

أظهرت النتائج حقق دقة اختبار (80%) جيدة في ظل محدودية البيانات مع دقة تحقق تفوق دقة التدريب تعكس قدرة النموذج على التعميم على بيانات جديدة ومع استراتيجية زيادة البيانات كي لا ينحاز النموذج للفئات الأكثر تمثيلاً في البيانات واستخدام معرفة الموديل السابقة وضبطها على صور التخطيط في البيانات حسن أداء النموذج والاتصالات الكثيفة Dense Connections فعالة في منع تلاشي التدرج وإعادة استخدام الميزات وقيم (AUC-ROC) ممتازة يشير إلى قدرة تمييزية جيدة للنموذج بين الفئات و استراتيجيات التنظيم المطبقة نجحت في منع فرط التخصص والنموذج يعمم بشكل جيد.

بتطبيق نموذج DenseNet121 مع استراتيجية نقل التعلم و الضبط الدقيق لتصنيف صور ECG إلى ثلاث فئات. حقق النموذج دقة 80% على بيانات الاختبار، مع أداء ممتاز لفئة (86%) Abnormal، وأداء جيد لـ (77%) History_MI، وأداء متوسط لـ (73%) Normal أظهر النموذج قدرة تعميم ممتازة مع مستوى منخفض من Overfitting.

■ التجربة السادسة DenseNet121 تصنيف ل أربع فئات .

تم استخدام مجموعة البيانات بعد إزالة الصور المكررة، حيث بلغ إجمالي الصور 491 صورة موزعة كالتالي : 142 صورة Normal - 233 صورة Abnormal - 30 صورة MI - 86 صورة History of MI .

تم تقسيم البيانات بنسبة 70% للتدريب، 15% للتحقق، و 15% للاختبار. وتم تطبيق سلسلة المعالجة المسبقة التالية تحويل ل RGB (قص أجزاء من الصورة من الأعلى 20% ومن الأسفل 7%) - (تطبيق نواة الوسيط لإزالة الضوضاء مع الحفاظ على الحواف مع نواة حجم 3*3) - تغيير الحجم ل 224*224 وتطبيع قيم البكسلات و تطبيع القيم لتكون في المجال [0,1].

لموازنة الفئات تم تطبيق تقنيات زيادة البيانات Agumentation على بيانات التدريب لتصبح كل فئة 200 صورة. التحويلات المطبقة هي القلب الأفقي (Horizontal Flip) بنسبة 50% التدوير (Rotation) بزاوية 10 درجة في الاتجاهين الموجب والسالب ، التكبير/التصغير (Zoom) بنطاق 0.9-1.1، وتعديل السطوع (Brightness) بنسبة 15% زيادة او نقصان.

تم اعتماد النموذج DenseNet121 كمرمّز للصور (Image Encoder) مع الاستفادة من الأوزان المدربة مسبقاً. تمت إضافة رأس مخصص للتصنيف الرباعي مع SoftMax تم اعتماد استراتيجية نقل التعلم المكونة من مرحلتين الأولى نقل التعلم DenseNet121 تجميد الطبقات الأساسية له وتدريب الرأس فقط اول 20 دورة مع معدل تعلم 10^{-3} المرحلة الثانية الضبط الدقيق تم إلغاء تجميد الطبقات العليا فقط وتدريب النموذج بالكامل مع معدل تعلم اقل 10^{-5} . وتم تطبيق استراتيجية موازنة البيانات Class Weight وحجم دفعة 16 مع استخدام كل من التقنيات ReduceLROnPlateau، EarlyStopping، و ModelCheckpoint لتحسين عملية التدريب ومنع فرط التخصص.

نتائج التجربة

الجدول 32. نتائج التجربة السادسة

المقياس	القيمة
دقة الاختبار	80%
دقة التحقق	83%
F1	0.70

الجدول 33 النتائج حسب الفئة

الفئة	Accuracy	Recall
Abnormal	86.3%	0.86
MI	50%	0.62
Normal	86%	0.86
History_MI	61.6%	0.50

بتطبيق نموذج DenseNet121 مع استراتيجية نقل التعلم و الضبط الدقيق لتصنيف صور ECG إلى أربع فئات. حقق النموذج دقة 80% على بيانات الاختبار، مع أداء ممتاز لفئتي Normal و Abnormal، بينما كان الأداء ضعيفاً لفئة (50%) Myocardial Infarction بسبب محدودية البيانات الأصلية.

3.7 تجارب مجموعة البيانات Cardiovascular Disease Dataset

■ التجربة الأولى K-Nearest Neighbors (KNN)

هي خوارزمية تعلم تعتمد على حساب المسافات بين العينات. لكل نقطة جديدة، يتم حساب المسافة إلى جميع نقاط التدريب، ثم اختيار أقرب K جيران وأخذ أغلبية تصويتهم.

نظراً لأن KNN تعتمد على حساب المسافات فإن الميزات ذات المقاييس المختلفة تؤثر على حساب المسافات أي الميزات ذات القيم الكبيرة تأثيرها أكبر تم تطبيع البيانات باستخدام StandardScaler ولإيجاد أفضل تركيبة من المعاملات الفائقة تم استخدام GridSearch.

النتائج :

الجدول 34. نتائج التجربة الأولى

مجموعة الميزات	AUC	Accuracy
Set 1 (3)	76.85%	70.70%
Set 2 (5)	77.63%	71.67%
Set 3 (7)	78.00%	71.89%
Set 4 (11)	77.83%	71.94%

نلاحظ أن النتائج جيدة ومتقاربة بين مختلف مجموعات السمات أفضل أداء ل Set4 مع 78% لكن حسب النتائج أدائها أقل من النماذج الأخرى وهذه الخوارزمية بطيئة في التنبؤ التنبأ تحتاج حساب مسافات لكل نقطة من بيانات التدريب.

■ التجربة الثانية شجرة القرار Decision Tree

شجرة القرار هي خوارزمية تعلم تقوم بتقسيم البيانات بشكل متكرر بناءً على الميزات، لإنشاء نموذج يشبه الشجرة. كل عقدة داخلية تمثل اختباراً على ميزة، وكل فرع يمثل نتيجة الاختبار، وكل عقدة ورقية تمثل التصنيف النهائي. لا يحتاج تطبيع غير حساس لمقاييس الميزات تم باستخدام GridSearch لإيجاد أفضل تركيبة من المعاملات الفائقة. النتائج:

الجدول 35. نتائج التجربة الثانية

مجموعة الميزات	AUC	Accuracy
Set 1 (3)	77.80%	71.60%
Set 2 (5)	78.51%	72.37%
Set 3 (7)	78.58%	72.16%
Set 4 (11)	78.53%	72.08%

نتائج جيدة وقرينة من النماذج التعزيزية في بعض الحالات أفضل أداء ل Set 2 هي خوارزمية بسيطة وفعالة وسهلة التفسير.

■ التجربة الثالثة Gradient Boosting

هي خوارزمية تعزيز (Boosting) تعتمد على بناء الأشجار بشكل متسلسل حيث تحاول كل شجرة تصحيح أخطاء الشجرة السابقة لها تستمر العملية حتى الوصول للعدد المطلوب من الأشجار الهدف تقليل الانحياز Bias وهي من أقوى الخوارزميات في التعامل مع البيانات الجدولية.

لا تحتاج تطبيع لأنه يعتمد على الأشجار، تم باستخدام GridSearch لضبط المعاملات الفائقة وإيجاد التركيبة المثلى.

الجدول 36 نتائج التجربة الثالثة

مجموعة الميزات	AUC	Accuracy
Set 1 (3)	78.21%	71.85%
Set 2 (5)	79.02%	72.57%
Set 3 (7)	79.23%	72.77%
Set 4 (11)	79.33%	72.70%

نلاحظ أنه من أفضل النماذج بشكل عام كونه يستخدم مجموعة من الأشجار التي تصحح أخطاء بعضها البعض بشكل تسلسلي مما حسن الأداء بشكل طفيف الفروق صغيرة بين التدريب والاختبار لا يوجد فرط تخصص النموذج يعمم بشكل ممتاز.

■ التجربة الرابعة Extreme Gradient Boosting

هو تطوير ل Gradient Boosting مع تحسينات كبيرة في السرعة والأداء، بما في ذلك التنظيم المدمج (L1/L2) ، ومعالجة القيم المفقودة، والتوازي في التدريب و قدرته التعامل مع البيانات الكبيرة والمعقدة بكفاءة.

لا يحتاج تطبيع القيم تم باستخدام GridSearch لإيجاد أفضل المعاملات الفائقة.

الجدول 37 نتائج التجربة الرابعة

مجموعة الميزات	AUC	Accuracy
Set 1 (3)	77.62%	71.42%
Set 2 (5)	78.60%	72.30%
Set 3 (7)	78.71%	72.41%
Set 4 (11)	78.84%	72.69%

أداء جيد متقارب من باقي الخوارزميات هي الخوارزمية الأسرع واثاني أفضل أداء بعد Gradient Boosting.

■ التجربة الخامسة Light Gradient Boosting Machine

LightGBM هو تطوير ل Gradient Boosting يركز على السرعة و كفاءة الذاكرة، بإستخدام تقنيات متطورة مثل :

■ (Gradient-based One-Side Sampling) حساب التدرجات أخذ عينات ذكية من البيانات

لتسريع التدريب دون فقدان الدقة.

■ Leaf-wise Tree Growth ينمو ويتفرع من العقدة الأكثر فائدة.

■ (Exclusive Feature Bundling) دمج الميزات المتفرقة لتقليل الأبعاد تقليل استهلاك الذاكرة.

تم باستخدام GridSearch لضبط المعاملات الفائقة وإيجاد التركيبة المثلى.

المجدول 38 نتائج التجربة الخامسة

مجموعة الميزات	AUC	Accuracy
Set 1 (3)	78.13%	71.65%
Set 2 (5)	79.00%	72.66%
Set 3 (7)	79.62%	72.89%
Set 4 (11)	79.27%	72.98%

نلاحظ أنه الأداء قريب من Gradient Boosting ولا يوجد فرط تخصص لأن الفرق صغير جداً بفضل التقنيات

المبتكرة والتنظيم المدمج يقدم أفضل توازن بين السرعة والأداء

■ التجربة السادسة Random Forest

هي خوارزمية تجميعية (Bagging) تعتمد على بناء الأشجار بشكل متوازي (Parallel) ، حيث كل شجرة تُبنى بشكل مستقل عن

الأخرى باستخدام عينات عشوائية من البيانات والميزات يتم أخذ القرار النهائي عن طريق التصويت. الهدف تقليل التباين Variance

تم باستخدام GridSearch لضبط المعاملات الفائقة وإيجاد التركيبة المثلى.

الجدول 39 نتائج التجربة السادسة

مجموعة الميزات	AUC	Accuracy
Set 1 (3)	70.62%	64.85%
Set 2 (5)	72.30%	66.45%
Set 3 (7)	72.82%	66.79%
Set 4 (11)	75.11%	69.57%

نلاحظ من النتائج أنه أضعف أداء بين جميع النماذج المختبرة.

مقارنة شاملة بين جميع الخوارزميات .

الجدول 40 مقارنة بين الخوارزميات

الخوارزمية	AUC	Accuracy	مجموعة الميزات
Gradient Boosting	79.33%	72.70%	Set 4
LightGBM	79.27%	72.98%	Set 3
XGBoost	78.84%	72.69%	Set 4
Decision Tree	78.53%	72.08%	Set 2
KNN	77.83%	71.94%	Set 4
Random Forest	75.11%	69.57%	Set 4

خلاصة التجارب تُعد خوارزميات التعزيز (Boosting) الخيار الأمثل لبيانات أمراض القلب الجدولية، حيث يتفوق كل من Gradient Boosting و LightGBM في الأداء والسرعة. يقدم أفضل توازن بين السرعة والدقة، مما يجعله خيار مثالي للنظام النهائي. في المقابل،

تبين أن KNN غير مناسب للبيانات الكبيرة، و Forest Random كان الأضعف أداءً في هذه التجارب. كما أظهرت النتائج أن 5-7 ميزات كافية لتحقيق أداء ممتاز، مما يبسط النماذج ويحسن كفاءتها.

4.7 تجارب مجموعة البيانات Heart Disease Dataset

■ التجربة الأولى K-Nearest Neighbors (KNN)

هي خوارزمية تعلم تعتمد على حساب المسافات بين العينات. لكل نقطة جديدة، يتم حساب المسافة إلى جميع نقاط التدريب، ثم اختيار أقرب K جيران وأخذ أغلبية تصويتهم.

تم تطبيع البيانات باستخدام StandardScaler وتطبيق GridSearch لاجتداد أفضل تركيبة من المعاملات الفائقة المعاملات المختبرة :

- n_neighbors: [3, 5, 7, 9] (عدد الجيران)
- weights: ['uniform', 'distance'] (وزن الجيران)
- metric: ['euclidean', 'manhattan'] (مقياس المسافة)

نتائج التجارب :

الجدول 41 نتائج التجربة الأولى

مجموعة الميزات	أفضل معاملات	F1-Score	الدقة	ROC-AUC
Set1_Top_6	{'metric': 'manhattan', 'n_neighbors': 9, 'weights': 'uniform'}	85.02%	83.15%	89.77%
Set2_Top_8	{'metric': 'manhattan',	86.79%	84.78%	90.37%

	'n_neighbors': 7, 'weights': 'uniform'}			
Set3_Top_10	{'metric': 'manhattan', 'n_neighbors': 9, 'weights': 'uniform'}	90.29%	89.13%	93.04%
Set4_All_11	{'metric': 'manhattan', 'n_neighbors': 7, 'weights': 'uniform'}	89.32%	88.04%	92.36%
Set5_Clinical	{'metric': 'manhattan', 'n_neighbors': 9, 'weights': 'uniform'}	82.93%	80.98%	89.16%
Set6_Minimal	{'metric': 'euclidean', 'n_neighbors': 5, 'weights': 'uniform'}	83.96%	81.52%	88.93%

التحليل نلاحظ:

- تظهر نتائج تجارب خوارزمية KNN تفوقاً واضحاً عند استخدام مجموعة الميزات Set3_Top_10 ، حيث حققت أعلى F1-Score هذا الأداء المتميز يشير أن 10 ميزات شكلت التوازن الأمثل بين توفير معلومات كافية للتمييز بين الفئات وتجنب إدخال ضوضاء أو ميزات غير ذات صلة هذه الميزات المختارة من تحليل الارتباط واختيار الميزات توفر معلومات غنية للتصنيف.
- حساس لاختيار الميزات (أداء ضعيف مع 4-5 ميزات).

■ التجربة الثانية شجرة القرار Decision Tree

شجرة القرار هي خوارزمية تعلم تقوم بتقسيم البيانات بشكل متكرر بناءً على الميزات، لإنشاء نموذج يشبه الشجرة. كل عقدة داخلية تمثل اختباراً على ميزة، وكل فرع يمثل نتيجة الاختبار، وكل عقدة ورقية تمثل تصنيفاً نهائياً.

تم تطبيق GridSearch لايجاد افضل تركيبة من المعاملات الفاتكة

المعاملات المختبرة :

- max_depth: [5, 10, None] (أقصى عمق للشجرة)
- min_samples_split: [2, 5, 10] (الحد الأدنى للعينات لتقسيم العقدة)
- criterion: ['gini', 'entropy'] (معياري التقسيم)

نتائج التجارب

الجدول 42 نتائج التجربة الثانية

مجموعة الميزات	أفضل معاملات	F1-Score	الدقة	ROC-AUC
Set1_Top_6	{'criterion': 'entropy', 'max_depth': 10, 'min_samples_split': 10}	83.00%	81.52%	85.88%
Set2_Top_8	{'criterion': 'gini', 'max_depth': 5, 'min_samples_split': 2}	80.60%	78.80%	84.24%
Set3_Top_10	{'criterion': 'entropy', 'max_depth': 5, 'min_samples_split': 2}	85.00%	83.70%	87.46%
Set4_All_11	{'criterion': 'entropy', 'max_depth': 5, 'min_samples_split': 2}	85.00%	83.70%	87.13%

Set5_Clinical	{'criterion': 'gini', 'max_depth': 5, 'min_samples_split': 2}	82.18%	80.43%	86.13%
Set6_Minimal	{'criterion': 'entropy', 'max_depth': 5, 'min_samples_split': 2}	84.42%	83.15%	90.15%

التحليل:

- أقل أداء بين جميع الخوارزميات بسبب طبيعة شجرة القرار فهي تميل ل فرط التخصص خاصة مع محدودية البيانات.
- تعاني من فرط تخصص صغير. جميع مجموعات الميزات حققت أفضل أداء لها مع عمق 5 بالإضافة لتحسن الأداء بشكل ملحوظ عند الانتقال من Set2 إلى Set3 مما يشير نلاحظ أيضاً أن أداء الشجرة تحسن بشكل ملحوظ عند الانتقال من Set2_Top_8 (F1=80.60%) إلى Set3_Top_10 (F1=85.00%) ، فارق 4.40%، مما يشير إلى أن إضافة ميزتي age و resting bps قدمتا معلومات جيدة لتحسين قرارات التقسيم.

- التجربة الثالثة نموذج الانحدار اللوجستي Logistic Regression نموذج خطي يستخدم الدالة اللوجستية (Sigmoid) لتحويل المخرجات الخطية إلى احتمالات بين 0 و 1. يعتبر من أبسط النماذج وأكثرها قابلية للتفسير.

تم تطبيق GridSearch لايجاد افضل تركيبة من المعاملات الفائقة

المعاملات المختبرة:

- C: [0.01, 0.1, 1, 10] (قوة التنظيم العكسي)
- solver: ['lbfgs', 'liblinear'] (خوارزمية التحسين)

نتائج التجارب

الجدول 43 نتائج التجربة الثالثة

ROC-AUC	الدقة	F1-Score	أفضل معاملات	مجموعة الميزات
---------	-------	----------	--------------	----------------

Set1_Top_6	{'C': 0.01, 'solver': 'lbfgs'}	87.38%	85.87%	89.68%
Set2_Top_8	{'C': 0.1, 'solver': 'lbfgs'}	87.74%	85.87%	90.78%
Set3_Top_10	{'C': 10, 'solver': 'lbfgs'}	88.57%	86.96%	90.63%
Set4_All_11	{'C': 0.1, 'solver': 'lbfgs'}	87.74%	85.87%	90.78%
Set5_Clinical	{'C': 0.01, 'solver': 'liblinear'}	85.85%	84.24%	87.52%
Set6_Minimal	{'C': 0.1, 'solver': 'lbfgs'}	85.02%	83.15%	87.05%

التحليل:

- قدم نموذج الانحدار اللوجستي أداء مستقر وجيد ومقاوم للـ Overfittin عبر جميع مجموعات الميزات أفضل أداء مع Set3_Top_10 هذا الأداء يعكس طبيعة النموذج الخطي البسيط الذي لا يتأثر بشكل كبير بزيادة عدد الميزات.
- نلاحظ أيضاً أن معامل التنظيم C أخذ قيمة مختلفة حسب مجموعة الميزات. عندما كانت الميزات أقل (Set1_Top_6)، كانت أفضل قيمة C=0.01 تنظيم قوي، بينما مع Set3_Top_10 أصبحت C=10 تنظيم ضعيف. هذا يشير إلى أنه كلما زادت الميزات، احتاج النموذج إلى تنظيم أقل لأن المعلومات الإضافية ساعدت في تحسين التمييز بين الفئات، مما قلل الحاجة إلى تقييد النموذج.

■ التجربة الرابعة نموذج الغابة العشوائية Random Forest

مجموعة من أشجار القرار تعمل معاً (Ensemble Learning) كل شجرة تُبنى على عينة عشوائية من البيانات وتستخدم مجموعة عشوائية من الميزات في كل تقسيم.

تم تطبيق GridSearch لايجاد أفضل تركيبة من المعاملات الفائقة

المعاملات المختبرة :

- n_estimators: [50, 100, 200] (عدد الأشجار)
- max_depth: [5, 10, None] (أقصى عمق للشجرة)
- min_samples_split: [2, 5] (الحد الأدنى للعينات لتقسيم العقدة)

نتائج التجارب

الجدول 44 نتائج التجربة الرابعة

مجموعة الميزات	أفضل معاملات	F1-Score	الدقة	ROC-AUC
Set1_Top_6	{'max_depth': 5, 'min_samples_split': 2, 'n_estimators': 100}	86.83%	85.33%	91.42%
Set2_Top_8	{'max_depth': 5, 'min_samples_split': 2, 'n_estimators': 200}	88.89%	87.50%	92.85%
Set3_Top_10	{'max_depth': 10, 'min_samples_split': 2, 'n_estimators': 200}	89.66%	88.59%	92.98%
Set4_All_11	{'max_depth': 10, 'min_samples_split': 5, 'n_estimators': 100}	88.78%	87.50%	92.47%
Set5_Clinical	{'max_depth': 5, 'min_samples_split': 5, 'n_estimators': 50}	85.44%	83.70%	89.64%
Set6_Minimal	{'max_depth': 5, 'min_samples_split': 5}	83.90%	82.07%	90.09%

	2, 'n_estimators': 50}			
--	---------------------------	--	--	--

التحليل:

- أفضل أداء مع (89.66% F1) Set3_Top_10 ثاني أعلى أداء بين جميع الخوارزميات المختبرة هذا الأداء القوي يبين قدرة النموذج على التعامل مع البيانات المعقدة وغير الخطية من خلال تجميع قرارات العديد من الأشجار، مما يقلل من التباين ويحسن من دقة التنبؤ.
- نلاحظ أن عدد الأشجار لعب دورا مهما في الأداء مع المجموعات الأكبر من الميزات زيادة عدد الأشجار يحسن عندما تكون البيانات غنية بالميزات على عكس المجموعات الصغيرة من الميزات لا تتطلب عدد كبير من الأشجار.

■ التجربة الخامسة نموذج التعزيز التدريجي Gradient Boosting

يبني الأشجار بشكل متسلسل، حيث تحاول كل شجرة جديدة تصحيح أخطاء الأشجار السابقة. وبالتالي زيادة الدقة. تم تطبيق GridSearch لايجاد افضل تركيبة من المعاملات الفائقة المعاملات المختبرة :

- n_estimators: [50, 100, 200] (عدد الأشجار)
- learning_rate: [0.01, 0.1, 0.2] (معدل التعلم)
- max_depth: [3, 5, 7] (أقصى عمق للشجرة)

نتائج التجارب

الجدول 45 نتائج التجربة الخامسة

مجموعة الميزات	أفضل معاملات	F1-Score	الدقة	ROC-AUC
----------------	--------------	----------	-------	---------

Set1_Top_6	{'learning_rate': 0.1, 'max_depth': 3, 'n_estimators': 50}	87.68%	86.41%	91.98%
Set2_Top_8	{'learning_rate': 0.1, 'max_depth': 5, 'n_estimators': 100}	85.43%	84.24%	91.13%
Set3_Top_10	{'learning_rate': 0.01, 'max_depth': 5, 'n_estimators': 200}	88.35%	86.96%	92.49%
Set4_All_11	{'learning_rate': 0.2, 'max_depth': 5, 'n_estimators': 50}	85.42%	84.78%	92.84%
Set5_Clinical	{'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 200}	86.96%	85.33%	89.72%
Set6_Minimal	{'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 100}	84.55%	81.52%	89.19%

التحليل:

- نلاحظ أداء متغير بين مجموعات الميزات المختلفة أفضل أداء مع Set3 كان أفضل أداء مع Set3_Top_10 ($F1=88.35\%$) هذا يشير إلى أن التعزيز التدريجي يستفيد من الميزات الإضافية ولكنه يحتاج إلى ضبط دقيق للمعاملات لتجنب التعلم المفرط.
- كما نلاحظ أن معدل التعلم كان المعامل الأكثر تأثير في الأداء أفضل قيمة $\text{learning_rate}=0.01$ مع عدد كبير من الأشجار 200 هذا يشير إلى أن التعلم البطيء والتدريجي مع العديد من الأشجار كان أكثر فعالية.
- بالنسبة لعمق الأشجار (max_depth) ، كانت القيم المثلى بين 3 و 5 هذا يؤكد أن Gradient Boosting يحتاج إلى أشجار أقل عمقاً لمنع Overfitting ، لأن كل شجرة تحاول تصحيح أخطاء السابقة، والأشجار العميقة قد تتعلم تفاصيل دقيقة جداً تؤدي إلى ضعف التعميم.

■ التجربة السادسة نموذج Extreme Gradient Boosting

هو تطوير متقدم لـ Gradient Boosting مع تحسينات كبيرة في السرعة والأداء، بما في ذلك التنظيم المدمج (L1/L2)، ومعالجة القيم المفقودة، والتوازي في التدريب.

تم تطبيق GridSearch لايجاد افضل تركيبة من المعاملات الفائقة
المعاملات المختبرة :

- n_estimators: [50, 100, 200] (عدد الأشجار)
- learning_rate: [0.01, 0.1, 0.2] (معدل التعلم)
- max_depth: [3, 5, 7] (أقصى عمق للشجرة)
- subsample: [0.8, 1.0] (نسبة العينات المستخدمة)

نتائج التجارب

الجدول 46 نتائج التجربة السادسة

مجموعة الميزات	أفضل معاملات	F1-Score	الدقة	ROC-AUC
Set1_Top_6	{'learning_rate': 0.1, 'max_depth': 3, 'n_estimators': 50, 'subsample': 1.0}	87.56%	86.41%	91.24%
Set2_Top_8	{'learning_rate': 0.2, 'max_depth': 3, 'n_estimators': 100, 'subsample': 0.8}	88.56%	87.50%	91.05%
Set3_Top_10	{'learning_rate': 0.2, 'max_depth': 5, 'n_estimators': 100, 'subsample': 0.8}	89.11%	88.04%	91.69%
Set4_All_11	{'learning_rate': 0.1, 'max_depth': 3, 'n_estimators': 50, 'subsample': 1.0}	89.22%	88.04%	92.84%

Set5_Clinical	{'learning_rate': 0.1, 'max_depth': 3, 'n_estimators': 50, 'subsample': 1.0}	85.71%	84.24%	89.08%
Set6_Minimal	{'learning_rate': 0.1, 'max_depth': 3, 'n_estimators': 50, 'subsample': 0.8}	84.58%	83.15%	90.67%

التحليل:

- حقق نموذج XGBoost ثالث أفضل أداءً مع (89.22% F1) Set4_All_11 ، بين جميع الخوارزميات المختبرة، بعد KNN (90.29%) و Random Forest (89.66%) هذا الأداء القوي يعكس التحسينات الكبيرة التي يقدمها XGBoost عن Gradient Boosting التقليدي، خاصة من حيث التنظيم المدمج والتعامل مع التعقيد.
- نلاحظ أن معدل التعلم (learning_rate) و عدد الأشجار (n_estimators) تفاعلا بشكل مختلف عن Gradient Boosting فمع Set4_All_11 ، كانت أفضل تركيبة هي learning_rate=0.1 مع 50 شجرة فقط، بينما في Gradient Boosting كانت أفضل تركيبة مع Set3_Top_10 هي learning_rate=0.01 مع 200 شجرة. هذا يشير إلى أن XGBoost يمكنه تحقيق أداء ممتاز مع عدد أقل من الأشجار بفضل آلية التنظيم المدججة التي تمنع Overfitting حتى مع التعلم الأسرع.
- بالنسبة لمعامل subsample، كانت القيمة 1.0 (استخدام جميع العينات) هي الأفضل في 4 من 6 مجموعات، بينما كانت 0.8 أفضل مع Set2_Top_8 و Set3_Top_10 و Set6_Minimal. هذا يشير إلى أنه عندما تكون الميزات أقل عدداً، فإن استخدام عينة فرعية من البيانات يساعد في تقليل التباين وتحسين التعميم.

▪ التجربة السابعة نموذج Support Vector Machine

الفكرة أنه يبحث عن المستوى الفائق (Hyperplane) الذي يفصل بين الفئات بأكبر هامش ممكن. يستخدم دالة النواة (Kernel) لتحويل البيانات إلى فضاء عالي الأبعاد.

تم تطبيع البيانات باستخدام StandardScaler وتطبيق GridSearch لايجاد افضل تركيبة من المعاملات الفائقة المعاملات المختبرة

- C: [0.1, 1, 10] (معامل التنظيم)
- kernel: ['rbf', 'linear'] (نوع النواة)
- gamma: ['scale', 'auto'] (معامل النواة)

نتائج التجارب

الجدول 47 نتائج التجربة السابعة

مجموعة الميزات	أفضل معاملات	F1-Score	الدقة	ROC-AUC
Set1_Top_6	{'C': 1, 'gamma': 'scale', 'kernel': 'rbf'}	87.20%	85.33%	86.86%
Set2_Top_8	{'C': 1, 'gamma': 'scale', 'kernel': 'rbf'}	86.92%	84.78%	89.67%
Set3_Top_10	{'C': 1, 'gamma': 'scale', 'kernel': 'rbf'}	88.37%	86.41%	90.99%
Set4_All_11	{'C': 0.1, 'gamma': 'scale', 'kernel': 'rbf'}	88.68%	86.96%	91.99%
Set5_Clinical	{'C': 10, 'gamma': 'scale', 'kernel': 'rbf'}	83.17%	81.52%	84.52%
Set6_Minimal	{'C': 10, 'gamma': 'scale', 'kernel': 'rbf'}	83.33%	81.52%	88.38%

التحليل:

- أفضل أداء مع Set4_All_11 (88.68% F1) أظهر نموذج آلة المتجهات الداعمة (SVM) أداءً جيداً مع الميزات الغنية، حيث حقق أعلى F1-Score بلغ 88.68% مع مجموعة Set4، ولكن أدائه تراجع بشكل ملحوظ مع مجموعات الميزات القليلة حيث وصل إلى 83.17% أداء ضعيف مع الميزات القليلة.
- كما تبين أن النواة RBF كانت الخيار الأمثل في جميع المجموعات، يعكس طبيعة البيانات غير الخطية حيث أن النواة الخطية (Linear) لم تكن قادرة على التقاط التعقيدات الموجودة في العلاقات بين الميزات والهدف. هذا يؤكد أن حدود القرار بين المرضى والأصحاء ليست خطية ببساطة.
- نلاحظ أن معامل التنظيم C تأثر بشكل كبير بعدد الميزات. مع المجموعات الغنية Set3_Top_10 و Set4_All_11 كانت C=1 أو C=0.1 هي الأفضل (تنظيم معتدل)، بينما مع المجموعات قليلة الميزات Set5_Clinical و Set6_Minimal أصبحت C=10 هي الأفضل (تنظيم ضعيف). هذا يشير إلى أنه عندما تكون الميزات قليلة، يحتاج النموذج إلى تنظيم أقل للسماح للحدود بالانحناء بشكل كافٍ لالتقاط الأنماط الموجودة.

خلاصة التجارب

تم تنفيذ 42 تجربة تدريبية شاملة بهدف بناء نموذج تنبؤي دقيق لتشخيص أمراض القلب. اعتمدت التجارب على ست مجموعات مختلفة من الميزات وسبع خوارزميات تعلم آلة، مع استخدام تقنية GridSearch لضبط المعاملات تلقائياً. الهدف الأساسي هو تحديد النموذج الأمثل الذي يحقق أعلى دقة مع قدرة جيدة على التعميم على بيانات جديدة.

مقارنة عامة لأفضل النماذج

الجدول 48 مقارنة عامة لأفضل النماذج

الترتيب	الخوارزمية	أفضل F1-Score	مجموعة الميزات
1	KNN	90.29%	Set3_Top_10
2	Random Forest	89.66%	Set3_Top_10
3	XGBoost	89.22%	Set4_All_11

Set4_All_11	88.68%	SVM	4
Set3_Top_10	88.57%	Logistic Regression	5
Set3_Top_10	88.35%	Gradient Boosting	6

الفصل الثامن

الأدوات المستخدمة

يعرض هذا الفصل الأدوات والمكاتب والطرق المستخدمة لتنفيذ النظام.

الأدوات المستخدمة:

Python

هي لغة برمجية عالية المستوى ومفتوحة المصدر، تستخدم في نطاق واسع في علم البيانات، تطوير البرمجيات، الذكاء الصناعي، وتطبيقات الويب. تدعم Python نماذج برمجة متعددة مثل البرمجة الكائنية والوظيفية. بفضل مكتباتها الغنية وإطار عملها القوي، أصبحت خياراً شائعاً لتطوير خوادم الويب، مثل Flask و Django و FastAPI، كما تُستخدم بشكل أساسي في تدريب وتشغيل نماذج الذكاء الصناعي.

Flask

هو إطار عمل مصغر لتطوير تطبيقات ومواقع الويب باستخدام لغة Python. يتميز بالخفة والمرونة ما يجعله مناسباً للمشاريع الصغيرة والمتوسطة، حيث يوفر الأدوات الأساسية للتطوير دون فرض قواعد صارمة مما يعطي حرية اختيار التقنيات والمكتبات اللازمة يسمح Flask بكتابة كود نظيف وقابل للتوسعة، مما يجعله مناسباً لتطبيقات الويب التي تتطلب أداءاً عالياً، مثل أنظمة الذكاء الاصطناعي.

Google.Colab

تعتبر منصة غوغل كولا ب من أشهر المنصات التي تتيح إمكانية بناء مشاريع ذكاء اصطناعي وتعلم الآلة، حيث أنها تقوم بتقديم إمكانية الاستفادة من وحدة معالجة رسومية GPU مجانية، ويمكن استخدام هذه المنصة بدون أي اعدادات وباستخدام لغة بايثون حيث تتيح للمستخدم كتابة وتنفيذ رمازات بايثون ضمن مفكرة Notebook ضمن المتصفح بشكل تفاعلي وتمكن المستخدم من حفظ ونشر هذه المفكرة عن طريق مشاركة رابط فقط. من مزايا هذه المنصة هي أنها تتيح وصل (ربط) مع سحابة غوغل Google Drive وبالتالي يمكن الوصول بشكل مباشر إلى كافة البيانات المخزنة على قرص غوغل واستخدامها أو حتى تخزين النتائج التي توصلنا إليها بعد تنفيذ الرماز المطلوب. يتم وصل قرص السحابة عن طريق التعليمات التالية:

```
from google.colab import drive
drive.mount('/content/drive')
```

Vs Code

هو محرر أكواد متقدم مفتوح المصدر يستخدم بكثرة لكتابة وتعديل البرمجيات بمختلف اللغات عبر نظام إضافات مرنة تعتمد على تقنيات الويب.

SQLite

نظام إدارة قواعد بيانات علائقية خفيف مفتوح المصدر، لا يحتاج خادم منفصل، يخزن جميع البيانات في ملف واحد على القرص، يدعم ميزات لغة الاستعلام القياسية SQL، يتميز بمرونة عالية في التعامل مع البيانات بالإضافة لتوافقه مع مختلف أنظمة التشغيل ويعد من أفضل الخيارات للتطبيقات الصغيرة.

Git

هو نظام تحكم في الإصدارات (version control system) مفتوح المصدر، يستخدم لتتبع التغيرات في الرماز المصدري (source code) أثناء تطوير البرمجيات، حيث يسمح لمطوريين متعددين بالتعاون في مشروع واحد من خلال إدارة التغيرات التي تم إجراؤها على الرماز المصدري، مما يجعل من السهل تنسيق العمل وتتبع التغيرات ضمن المشروع.

GitHub

هي منصة سحابية تعمل ضمن الويب توفر أدوات التحكم بالإصدارات والتعاون بين المطورين لتطوير البرامج، حيث أنها مبنية على نظام التحكم بالإصدارات Git. تسمح هذه المنصة بتخزين الكود البرمجي ومشاركته بين مجموعة من المطورين كما تقدم مجموعة من الأدوات للتعامل مع بيانات التطوير إلى السحابة (cloud) واستضافة مواقع الويب الثابتة.

Tensorflow

هي إطار عمل للتعلم الآلي مفتوح المصدر من تطوير Google. تستخدم على نطاق واسع في العديد من تطبيقات التعلم العميق، مما يوفر نظاماً شاملاً مرناً للأدوات والمكتبات تم الاعتماد عليها بشكل رئيسي في بناء نموذج التعلم العميق.

Bootstrap5

هو إطار عمل (Framework) مجاني ومفتوح المصدر لتصميم واجهات وتطبيقات الويب يركز على لغات (HTML – Css – JavaScript) ويهدف إلى تسريع عملية التطوير ويوفر نظام شبكي (Grid System)، ومكونات جاهزة مثل (أزرار، بطاقات، نماذج، نوافذ منبثقة)، وتصميم حديث و متجاوب (Responsive) يتكيف تلقائياً مع جميع أحجام الشاشات.

Jinja2

هو محرك قوالب (Template Engine) مخصص للغة بايثون مع Flask يفصل بين كود Python ومنطق العرض (Presentation)، وظيفته الأساسية هي دمج البيانات الديناميكية مع ملفات ثابتة مثل HTML أو XML لإنتاج صفحات ويب أو ملفات إعدادات تتغير بناءً على مدخلات المستخدم أو قواعد البيانات

Fetch API

هي واجهة برمجة تطبيقات حديثة في JavaScript تتيح إرسال طلبات HTTP بشكل غير متزامن لجلب البيانات أو إرسالها دون إعادة تحميل الصفحة. تعتمد كلياً على ال Promises وتُعد البديل الحديث لطلبات AJAX التقليدية (XMLHttpRequest) بفضل تصميمها الأبسط والأكثر مرونة من ميزاتها تدعم ال Promises ومدمجة بالمتصفح لا تحتاج لأي مكتبات خارجية.

المكاتب المستخدمة :

Werkzeug هي مجموعة أدوات WSGI قوية في لغة بايثون، وتعد الأساس الذي يعتمد عليه إطار عمل Flask لتوفير إدارة الطلب والاستجابة، وتوجيه الروابط، وتصحيح الأخطاء، وتشغيل خادم التطوير المحلي.

OpenCV: مكتبة مفتوحة المصدر تدعم العديد من لغات البرمجة مثل C++ و Python و Java كما أنها تدعم مختلف أنظمة التشغيل تستخدم لبناء تطبيقات الرؤية الحاسوبية التي تحتاج تنفيذ مهامها بسرعة عالية وبشكل فعال.

PIL: مكتبة Python Imaging هي مكتبة إضافية مجانية ومفتوحة المصدر للغة بايثون، وتتيح دعماً لقراءة ومتابعة ومعالجة الصور بالعديد من التنسيقات المختلفة.

SQLAlchemy: مكتبة قوية وشائعة في لغة Python تستخدم للتفاعل مع قواعد البيانات العلائقية مع تربط بين جداول قاعدة البيانات والصفوف في كود Python، بدلاً من كتابة أكواد SQL المعقدة، تتيح لك المكتبة إدارة قواعد البيانات بالكامل وكتابة الاستعلامات باستخدام لغة بايثون الخالصة مما يسرع التطوير ويقلل الأخطاء.

Pandas: مكتبة قوية لمعالجة وتحليل البيانات بنيت خصيصاً للتعامل مع البيانات المهيكلة والجدولية كالبيانات الواردة من ملفات CSV أو قواعد البيانات.

NumPy: مكتبة أساسية للحوسبة الرياضية والعلمية في بايثون، وتعنى بإدارة مصفوفات البيانات الكبيرة متعددة الأبعاد بكفاءة عالية.

Matplotlib: تعتبر هذه المكتبة من أقدم المكاتب الخاصة بلغة بايثون، وتستخدم لأجل توليد رسوم بيانية وأشكال خاصة بالبيانات باستخدام بضع أسطر برمجية فقط، وتظهر فائدتها أثناء عمليات تحليل البيانات وتجهيز التقارير الإحصائية وعمليات تنقيب وتحليل البيانات وتعليم الآلة، ويمكن من خلالها حفظ الصور والرسوم بعدة صيغ.

مكاتب مساعدة أخرى:

Chart.js: مكتبة لإنشاء الرسوم البيانية التفاعلية والإحصاءات بشكل بياني في واجهة المستخدم.

Font Awesome: مكتبة أيقونات شهيرة تمكن إضافة أيقونات لواجهة المستخدم مما يحسن تجربة المستخدم.

AOS(Animate On Scroll): مكتبة لتحريك العناصر عند التمرير تمكن من إضافة تأثيرات حركية للصفحات جعل التصفح أكثر حيوية ومتعة.

Cairo Font: عرض التصوص العربية بشكل احترافي خط عربي جميل وسهل القراءة تحسين قراءة المحتوى دعم اللغة العربية بشكل كامل.

OS: مكتبة تأمن طريقة محمولة لاستخدام الوظائف المعتمدة على نظام التشغيل. حيث يمكن من خلالها فتح ملف لقراءته أو الكتابة فيه كما توفر إمكانية معالجة المسارات.

الفصل التاسع

التنفيذ البرمجي لنظام الويب

في هذا الفصل نقدم شرحاً عن معمارية النظام وتنفيذه البرمجي إضافة إلى المكاتب والبيئات المستخدمة.

1.9 البنية المستخدمة في التنفيذ

تم اعتماد البنية متعددة الطبقات في تنفيذ النظام المقترح كما ذكرنا في فصل تصميم النظام، تم اختيارها ليكون النظام قابل للصيانة والتوسع والتعديل. حيث يقسم حسب الوظائف لطبقات لكل طبقة منها مسؤولية محددة حيث تعتمد كل طبقة على الطبقة التي تحتها مباشرة.

2.9 طبقات النظام المنجز

سنشرح كل طبقة بالترتيب من الأسفل للأعلى.


طبقة التخزين Storage Layer

الطبقة الأساسية المسؤولة عن حفظ جميع بيانات التطبيق، وتضمن أمان البيانات وسلامتها الأمثلة قواعد البيانات العلائقية أو غير العلائقية ومخازن الملفات.

طبقة البنية التحتية Infrastructure Layer

طبقة البنية التحتية تمثل أساس النظام هي المسؤولة عن تقديم الخدمات الأساسية التي تعتمد عليها جميع الطبقات الأخرى. تحتوي على آليات الوصول إلى قاعدة البيانات، نماذج البيانات، ودوال التهيئة. ومستودع البيانات تمثل هذه الطبقة تطبيقاً لنمط Data Mapper عبر SQLAlchemy ORM.

طبقة الأعمال Business Layer



الشكل 22 بنية التطبيق

هي نواة النظام التي تحتوي على كل المنطق والخوارزميات وقواعد العمل (Business Rules) تحقق هذه الطبقة أهداف النظام. هذه الطبقة مستقلة تماماً عن واجهة المستخدم لا تعرف شيئاً عن HTTP أو HTML و قواعد البيانات، تحوي خدمات النماذج وإدارة التقارير ومعالجة البيانات.

طبقة التطبيق Application Layer

هي طبقة التنسيق (Coordination Layer) في البنية متعددة الطبقات تعمل كوسيط بين طبقة العرض وطبقة الأعمال تدير سير العمل (Workflows) مسؤوليتها الأساسية هي استقبال طلبات HTTP ، التحقق من صحة المدخلات، وتقوم بتوجيه الطلب إلى خدمة الأعمال المناسبة، ثم تنسيق الاستجابة بالشكل الذي تطلبه طبقة العرض. اعتمد النظام على نظام التوجيه في Flask الذي يربط بين عنوان URL و دالة المعالجة (View Function) تم تنظيم المسارات في وحدات مستقلة، كل وحدة مسؤولة عن مجموعة مترابطة وظيفياً من نقاط النهاية (Endpoints) هذا التقسيم يطبق مبدأ Responsibility Principle Single من مبادئ SOLID على مستوى المسارات ويتم فيها معالجة الاستثناءات بشكل مركزي ،تحتوي كائنات نقل البيانات بين الطبقات.

طبقة العرض Presentation Layer

هي الطبقة المسؤولة عن التفاعل المباشر مع المستخدم، وتُعرف أيضاً بواجهة المستخدم (User Interface) في تطبيقات الويب الحديثة، تتكون هذه الطبقة من ثلاث مكونات أساسية تعمل معاً HTML للهيكل و CSS للتنسيق و Javascript للتفاعل الديناميكي تعتمد على نظام قوالب Jinja2 المدمج مع Flask لتوليد صفحات ديناميكية والذي يطبق مفهوم توريث القوالب (Template Inheritance) وللاتصال بالخادم FetchAPI.

الاستثناءات (Exceptions)

الاستثناء هو حدث غير متوقع يحدث أثناء تنفيذ البرنامج، ويعطل التدفق الطبيعي للتعليمات البرمجية. تهدف المعالجة المركزية والموحدة للاستثناءات في جميع طبقات التطبيق إلى جعل الكود أنظف وأسهل في الصيانة، مع توفير تسجيل مركزي لجميع الأخطاء في مكان واحد. كل الأخطاء تُعالج في مكان واحد تم انشاء استثناءات مخصصة لتمثيل حالات خطأ محددة بالنظام كل استثناء مخصص بحمل معلومات عن نوع الخطأ، ورسالة واضحة، وكود حالة HTTP مناسب، ورمز خطأ فريد.

الاستثناءات المخصصة (Custom Exceptions)

تم إنشاء تسلسل هرمي من الاستثناءات المخصصة لتمثيل حالات الخطأ المختلفة في النظام. كل استثناء مخصص بحمل معلومات شاملة عن نوع الخطأ، ورسالة واضحة باللغة العربية، وكود حالة HTTP مناسب، ورمز خطأ فريد لتسهيل التتبع والتصنيف وبتنوع مرونة في المعالجة.

المعالجة المركزية للاستثناءات (Centralized Exception Handling)

هي نط معماري يتم فيه توحيد آلية التعامل مع جميع الأخطاء والاستثناءات في مكان واحد محدد، بدلاً من معالجتها في كل جزء من أجزاء التطبيق. يعتمد هذا النمط على مبدأ عدم التكرار (DRY – Don't Repeat Yourself) ويضمن أن جميع الاستثناءات، مهما كان مصدرها، تمر عبر نفس مسار المعالجة.

معالجات الاستثناءات هي دوال مسجلة في إطار العمل Flask باستخدام المزخرف `@app.errorhandler`، وتستخدم لالتقاط أنواع محددة من الاستثناءات وتحويلها إلى استجابات مناسبة للمستخدم. حيث يبدأ بالمعالجات الخاصة بأنواع محددة من الاستثناءات، وينتقل إلى المعالجات الأكثر عمومية إذا لم يتم التعرف على نوع الاستثناء هذا النظام يضمن أن التطبيق يتعامل مع الأخطاء بشكل احترافي ويوفر تجربة مستخدم ممتازة حتى عند حدوث أخطاء

التسجيل Logging

تسجيل الأحداث هو عملية توثيق كل ما يحدث في التطبيق بشكل منظم ومؤرخ. يعتبر نظام التسجيل بمثابة الصندوق الأسود للتطبيق، حيث يسجل كل الأحداث المهمة، الأخطاء، التحذيرات، والعمليات التي يتم تنفيذها. إنه بمثابة الذاكرة طويلة المدى للتطبيق، حيث يوفر سجلاً تاريخياً كاملاً لنشاط النظام.

مستويات التسجيل مستويات التسجيل تحدد أهمية كل رسالة مسجلة. هذا يسمح للمطورين بتصفية السجلات وعرض فقط ما يهمهم في كل موقف. كل مستوى له دلالة محددة ويساعد في تصنيف الأحداث حسب خطورتها وأهميتها منها الأخطاء والتحذيرات والمعلومات العامة.

يتم تخزين السجلات في ملفات نصية منظمة. في النظام، هناك نوعان رئيسيان من ملفات السجلات

ملف السجلات العامة: `app.log` يسجل جميع الأحداث بما فيها المعلومات والتحذيرات والأخطاء. هذا الملف هو المصدر الرئيسي لتتبع نشاط التطبيق اليومي. ملف الأخطاء: `errors.log` يسجل الأخطاء فقط. (هذا الملف يساعد المطورين على التركيز على المشاكل الحقيقية دون تشتيت الانتباه بالمعلومات العامة.

تدوير الملفات هو عملية إنشاء ملفات سجلات جديدة بشكل دوري أو عند الوصول لحجم معين، مع أرشفة أو حذف الملفات القديمة. هذا يمنع ملفات السجلات من النمو بشكل لا نهائي، مما يحافظ على أداء النظام ويمنع نفاذ الذاكرة.

نظام التسجيل هو أداة مهمة لفهم ما يحدث في التطبيق، وتصحيح الأخطاء، وتحسين الأداء، وضمان الأمان. يمثل الذاكرة طويلة المدى للتطبيق.

3.9 أهم الأنماط التصميمية المستخدمة في بناء النظام

تغيير طريقة الإنشاء في مكان واحد |

Singleton

يتم تحميل النماذج المدربة مرة واحدة عند بدء التطبيق، ثم يتم استخدامها في الطلبات دون إعادة تحميل، هذا يقلل من زمن الاستجابة بشكل كبير ويحافظ على موارد النظام مما يحسن من أداء التطبيق ويقلل من استهلاك الذاكرة. نسخة واحدة من الخدمات نفس البيانات متاحة لجميع الطلبات.

Repository

نمط تصميم يفصل منطق الوصول للبيانات من قاعدة البيانات عن منطق العمل الأساسي. يعمل كوسيط بين طبقة الأعمال ومصدر البيانات حيث يتحقق من خلاله تطبيق نظيف و قابل للتوسع ويوفر سهولة التبديل بين قواعد البيانات دون التأثير على باقي أجزاء التطبيق.

Data Transfer Object

نمط تصميم هيكلي هدفه الأساسي تجميع ونقل البيانات بين طبقات النظام في كائن خال من منطق الأعمال يقوم بفصل نموذج قاعدة البيانات عن واجهة العرض مما يوفر الأمان وحماية البيانات بمنح مرونة وتحكم كبير لكل طلب عن طريق هياكل بيانات مختلفة حسب الحاجة.

Factory Pattern

نمط تصميم برمجي أنشائي يستخدم لإنشاء الكائنات دون الحاجة لتحديد الفئة الدقيقة للكائن المراد إنشاؤه في كل مرة بدلاً من استخدام كلمة new مباشرة في كود البرنامج، يتم تفويض مهمة إنشاء الكائنات إلى دالة أو فئة خاصة تُسمى "المصنع"، مما يقلل من الارتباط بين أجزاء الكود ويسهل التعديل لاحقاً والتوسع إضافة أنواع جديدة لا تتطلب تغيير الكود الأساسي، بل إضافة صنف جديد للمصنع. ينشئ كائنات معقدة بطريقة موحدة، يخفي تفاصيل الإنشاء عن المستخدم.


Strategy Pattern

نمط تصميم الاستراتيجي هو نمط سلوكي يعرف عائلة من الخوارزميات أو السلوكيات، ويضع كل منها في وحدة مستقلة ويجعلها قابلة للتبديل فيما بينها أثناء وقت التشغيل دون تغيير الكود الأساسي المكونات الأساسية العقد الموحد تلتزم به كل الخوارزميات و الاستراتيجيات الفرعية والسياق الذي يحتفظ بمراجع لواجهة الاستراتيجية و يفاوض العمل لها والعميل هو الصف الذي يحدد الاستراتيجية المناسبة ويزود بها السياق تم تطبيق هذا النمط في تنجيز خوارزميات التنبؤ للتبديل بينها.


Chain of Responsibility

هو نمط تصميم سلوكي يسمح لك بتمرير الطلبات على طول سلسلة من كائنات المعالجة (Handlers) عند استلام الطلب، يقرر كل كائن إما معالجته أو تمريره إلى الكائن التالي في السلسلة دون أن يعلم المرسل أي كائن سيقوم بالحل النهائي يمرر الطلب عبر سلسلة من المعالجات حتى يتم معالجته.


بعض واجهات المشروع




الشكل 23 واجهة ادخال البيانات السريرية



الشكل 24 واجهة رفع صورة تخطيط القلب



الشكل 25 واجهة النتائج التي قدمها النموذج من تحليل الصورة



الشكل 26 واجهة التقارير الطبية

مساعدة طبيب قلبية

الرئيسية | الشخص الجديد | الشخص الحالي | تحليل احطية قلبية | وحدة التحكم | المرضى | التقارير

محرر القوالب الطبية

قم بإضافة الحقول لبناء قالب التقرير الطبي.

إضافة حقل

اسم الحقل

نص قصير

نص طويل

رقم

تاريخ

مختارات

قائمة مسبقة

مربع اختيار (نعم/لا)

تخطيط

عنوان قسم

عنوان فرعي

فاصل

Activate Windows
Go to Settings to activate Windows.

أضف حقولاً من القائمة الجانبية لبناء القالب

←

الشكل 27 واجهة انشاء قالب تقرير طبي

طبيب قلبية

تقرير طبي للعاملين

تقرير: REP-ECE4FCE8 | مريض: PAT-FBFB7E5 | تاريخ: 05:13 07-08-2026

2026-08-07	التاريخ
ناصر محمد	الاسم
56	رقم
ذكر	الجنس
المريض يعاني من روماتيزم القلب وقد تم اجراء عملية قلب مفتوح وتغيير صمامين منذ سنتين وهو بحاجة للعلاج المستمر .	
توقيع الطبيب	

مساعدة طبيب قلبية | 05:13 07-08-2026 (c) 2026

الشكل 28 التقرير الطبي المصدر بصيغة pdf

4.9 اختبارات النظام

تم إنشاء مجموعة من الاختبارات للتأكد من تحقيق تبعيات النظام بين الطبقات لقواعد البنية متعددة الطبقات.

كما تم إنشاء مجموعة من اختبارات الوحدة (Unit tests) وتهدف إلى التحقق من صحة أصغر الوحدات البرمجية تقوم بعملها على أكمل شكل بشكل معزول عن باقي مكونات النظام ، حيث اختبار كل مكون بشكل مستقل للتأكد من أدائه وفقاً للمواصفات المطلوبة يتم ذلك من خلال القيام بإنشاء كائنات زائفة Mocking عند الحاجة للتواصل مع قاعدة المعطيات، تعيد هذه الكائنات معطيات معرفة مسبقاً المكونات المختبرة نماذج قاعدة البيانات، خدمات الاعمال دوال معالجة البيانات.

نتائج أحد اختبارات الوحدة

```
collected 25 items
tests/test_unit/test_database.py::TestGenerateID::test_generate_id without_prefix PASSED [ 4%]
tests/test_unit/test_database.py::TestGenerateID::test_generate_id with_prefix PASSED [ 8%]
tests/test_unit/test_database.py::TestGenerateID::test_generate_multiple_ids unique PASSED [ 12%]
tests/test_unit/test_database.py::TestTemplateModel::test_create_template PASSED [ 16%]
tests/test_unit/test_database.py::TestTemplateModel::test_template_get_structure PASSED [ 20%]
tests/test_unit/test_database.py::TestTemplateModel::test_template_field_count PASSED [ 24%]
tests/test_unit/test_database.py::TestTemplateModel::test_template_report_count_zero PASSED [ 28%]
tests/test_unit/test_database.py::TestTemplateModel::test_template_report_count_with_reports PASSED [ 32%]
tests/test_unit/test_database.py::TestTemplateModel::test_template_to_dict PASSED [ 36%]
tests/test_unit/test_database.py::TestTemplateModel::test_template_to_dict with reports PASSED [ 40%]
tests/test_unit/test_database.py::TestTemplateModel::test_template_str_representation PASSED [ 44%]
tests/test_unit/test_database.py::TestTemplateModel::test_template_default_values PASSED [ 48%]
tests/test_unit/test_database.py::TestReportModel::test_create_report PASSED [ 52%]
tests/test_unit/test_database.py::TestReportModel::test_report_get_data PASSED [ 56%]
tests/test_unit/test_database.py::TestReportModel::test_report_get_field_value PASSED [ 60%]
tests/test_unit/test_database.py::TestReportModel::test_report_get_field_value with custom default PASSED [ 64%]
tests/test_unit/test_database.py::TestReportModel::test_report_template_title PASSED [ 68%]
tests/test_unit/test_database.py::TestReportModel::test_report_has_pdf_false PASSED [ 72%]
tests/test_unit/test_database.py::TestReportModel::test_report_to_dict PASSED [ 76%]
tests/test_unit/test_database.py::TestReportModel::test_report_to_dict with template PASSED [ 80%]
tests/test_unit/test_database.py::TestReportModel::test_report_str_representation PASSED [ 84%]
tests/test_unit/test_database.py::TestReportModel::test_report_default_values PASSED [ 88%]
tests/test_unit/test_database.py::TestModelRelationships::test_template_reports_relationship PASSED [ 92%]
tests/test_unit/test_database.py::TestModelRelationships::test_report_template_relationship PASSED [ 96%]
```

الشكل 29 نتائج اختبارات الوحدة

وتم اختبار التكامل بين أجزاء التطبيق (Integration tests) بهدف التأكد من تفاعل المكونات المختلفة بشكل صحيح، وكيفية تبادلها للبيانات والمعلومات. يهدف إلى اكتشاف الأخطاء الناتجة عن تكامل الوحدات معاً، والتأكد من أن واجهات التواصل بينها تعمل بشكل سليم. مثلاً تكامل نماذج قاعدة البيانات مع خدمات الأعمال تكامل حفظ البيانات في الملفات مع استرجاعها تكامل خدمات التنبؤ مع واجهات برمجة التطبيقات (APIs). تم اختبار واجهات البرمجة للتحقق من صحة نقاط النهاية (Endpoints) في النظام، والتأكد من أنها تستقبل الطلبات بشكل صحيح وتعطي الاستجابات المناسبة. تشمل هذه الاختبارات التحقق من رموز الحالة، تنسيق البيانات، ومعالجة الأخطاء.

نتائج أحد تجارب اختبارات التكامل

```
collected 8 items

tests/test_integration/test_prediction_routes.py::TestPredictionRoutes::test_predict_endpoint_success PASSED [ 12%]
tests/test_integration/test_prediction_routes.py::TestPredictionRoutes::test_predict_endpoint_invalid_model PASSED [ 25%]
tests/test_integration/test_prediction_routes.py::TestPredictionRoutes::test_save_patient_endpoint PASSED [ 37%]
tests/test_integration/test_prediction_routes.py::TestPredictionRoutes::test_save_patient_with_doctor_modification PASSED [ 50%]
tests/test_integration/test_prediction_routes.py::TestPredictionRoutes::test_update_diagnosis_endpoint PASSED [ 62%]
tests/test_integration/test_prediction_routes.py::TestPredictionRoutes::test_get_temp_patient PASSED [ 75%]
tests/test_integration/test_prediction_routes.py::TestPredictionRoutes::test_get_temp_patient_not_found PASSED [ 87%]
tests/test_integration/test_prediction_routes.py::TestPredictionRoutes::test_predict_with_ai_interpretation PASSED [100%]

===== 8 passed in 0.23s =====
```

الشكل 30 نتائج اختبارات التكامل

بالإضافة لذلك قمنا باختبارات End-to-End تمثل اختبارات E2E المستوى الأعلى في هرم الاختبارات، حيث تحاكي سيناريوهات المستخدم الحقيقية من البداية إلى النهاية. تختبر هذه الاختبارات النظام ككل، منطق الأعمال، قاعدة البيانات، والخدمات الخارجية، للتأكد من أن كل شيء يعمل معاً بشكل متكامل منها سير عمل تحليل صورة تخطيط قلب سير عمل إدارة القوالب الطبية.

نتائج أحد اختبارات E2E

```
collected 5 items

tests/test_e2e/test_full_workflow.py::TestEndToEndWorkflow::test_full_doctor_workflow PASSED [ 20%]
tests/test_e2e/test_full_workflow.py::TestEndToEndWorkflow::test_error_handling_workflow PASSED [ 40%]
tests/test_e2e/test_full_workflow.py::TestEndToEndWorkflow::test_data_integrity_workflow PASSED [ 60%]
tests/test_e2e/test_full_workflow.py::TestEndToEndWorkflow::test_concurrent_operations_workflow PASSED [ 80%]
tests/test_e2e/test_full_workflow.py::TestEndToEndWorkflow::test_pdf_generation_with_special_characters PASSED [100%]

===== 5 passed in 0.97s =====
```

الشكل 31 نتائج اختبارات E2E

بالإضافة إلى ذلك، تم تنفيذ اختبارات على الواجهات (UI tests) باستخدام أدوات آلية لمحاكاة تفاعل المستخدم مع النظام، بهدف التأكد من أن الواجهات تعرض البيانات بشكل صحيح وتستجيب للأحداث وفقاً للتوقعات، مما يضمن تجربة استخدام مستقرة ومتناسقة.

بيئة الاختبار

تم استخدام بيئة اختبار معزولة تعتمد على قاعدة بيانات في الذاكرة (In-Memory Database) لعزل الاختبارات وضمان سرعة التنفيذ وكائنات وهمية (Mock Objects) لمحاكاة المكونات بالإضافة لبيانات اختبارية تم إنشاؤها خصيصاً لتغطية سيناريوهات متنوعة.

أدوات الاختبار

▪ Pytest-Framework : لتشغيل وإدارة الاختبارات.

- Flask Testing: لاختبار تطبيقات الويب .
- unittest.mock: لإنشاء الكائنات الوهمية.
- Requests Library: لاختبار واجهات برمجة التطبيقات APIs.

الخاتمة والآفاق المستقبلية

قدم هذا المشروع نظاماً معلوماتياً متكاملًا للمساعدة في تشخيص أمراض القلب، يهدف إلى دعم القرار الطبي للطبيب من خلال الاعتماد على مصدرين رئيسيين للبيانات: البيانات السريرية المهيكلة وصور تخطيط القلب الكهربائي (ECG) .

من خلال توظيف التطورات الأخيرة في مجال تعلم الآلة وخاصة التعلم العميق، واستخدام نماذج تعلم التقليدية للبيانات المهيكلة والنماذج المتقدمة في الرؤية الحاسوبية لصور تخطيط القلب.

أظهرت نتائج التجارب أظهرت النتائج أن استخدام المصدرين معاً البيانات السريرية وصور ECG في حال توافرها يؤدي إلى تحسين الأداء بشكل ملحوظ مقارنة باستخدام كل مصدر بمفرده، مما يعزز أهمية التكامل بين الأنواع المختلفة من البيانات الطبية في رفع دقة التشخيص ودعم القرار الطبي. قدرة النظام على تحقيق دقة جيدة نوعاً ما في تصنيف الحالات الطبية، مما يفتح المجال لتطبيق هذه التقنية في بيئات صحية حقيقية تسعى إلى التعامل مع تشخيص و تصنيف أمراض القلب بكفاءة عالية.

نظراً للتجارب التي قدمت يمكن تحسين أداء نماذج تخطيط القلب من خلال إضافة صور لفئات جديدة مصنفة ومدروسة من قبل أطباء مختصين للوصول لنماذج قوية قادرة على تصنيف الصور لعدد أكبر من الفئات ما يزيد من قدرة النظام على تشخيص حالات أوسع لأمراض القلب.

ويمكن تحسين أداء النموذج من خلال التدريب على أنواع أخرى من البيانات كالأشارات لتخطيط القلب بهدف زيادة قدرة النموذج على التعميم، وهو الأمر الذي لم يتم في هذا البحث بسبب محدودية الوقت .

بالإضافة لإمكانية تحسين نماذج التصنيف السريرية من خلال أضافة مجموعات بيانات وميزات جديدة لزيادة قدرة النماذج على تصنيف عدد كبير من أمراض القلب بدقة أعلى والتمييز بين الأنواع المختلفة من الأمراض القلبية.

من ناحية هندسة البرمجيات، اتبع المشروع مبادئ البنية متعددة الطبقات التي ساعدت في بناء نظام مرن وقابل للتوسع والصيانة، وهو أمر جوهري لتطبيقات الطبية التي تتطلب تحديثات مستمرة وتكيفاً مع المتطلبات المتغيرة. ختاماً، يمكن توسيع هذا العمل مستقبلاً بإضافة أو دمج مصادر بيانات إضافية لزيادة قدرة النظام على التعميم. كما يمكن تطوير آليات شرح وتفسير القرار التي يقدمها النظام لتعزيز ثقة المستخدمين من الكادر الطبي ودعم عملية اتخاذ القرار بشكل أفضل.

المراجع

- [1] "Cardiovascular diseases (CVDs), World Health Organization 2023. [متصل]. Available: [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))
- [2] "A Comprehensive Review of Cardiovascular Disease Management: V. R. Netala Cardiac Biomarkers, Imaging Modalities, Pharmacotherapy, Surgical Interventions, Cells", and Herbal Remedies 2024, p. 1471.
- [3] "An artificial intelligence-enabled ECG algorithm for the identification of patients with atrial fibrillation during sinus rhythm: a retrospective analysis of outcome prediction 2019, The Lancet", Z. I. Attia
- [4] "Heart disease – Symptoms and causes, M. Clinic 2022. [متصل]. Available: <https://www.mayoclinic.org/diseases-conditions/heart-disease/symptoms-causes/syc-20353118>.
- [5] Pathophysiology of Heart Disease, L. S. Lilly 2020, Philadelphia.
- [6] "Electrocardiogram (ECG or EKG), M. Clinic 2024. [متصل]. Available: <https://www.mayoclinic.org/tests-procedures/ekg/about/pac-20384983>.

- [7] Goldberger's Clinical ،A. Shvilkin و Z. D. Goldberger ،A. L. Goldberger
.2023 ،Philadelphia: Elsevier ،Electrocardiography: A Simplified Approach
- [8] "XGBoost: A scalable tree boosting system" ،C. Guestrin و T. Chen
*Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge
Discovery and Data Mining* .2016 ،
- [9] Breiman, L. ،L. Breiman ،Breiman, L. "،pp. 5-32 ،2001
- [10] "Support-vector networks" ،V. Vapnik و C. Cortes
pp. ،*Support-vector networks* ،1995 ،297-273
- [11] A training algorithm for optimal margin classifiers " ،V. N. Vapnik و I. M. Guyon ،B. E. Boser
Proceedings of the 5th Annual Workshop on Computational Learning Theory ،1992 ،
- [12] Hosmer, D. W. ; Lemeshow, S. ; ،R. X. Sturdivant و S. Lemeshow ،D. W. Hosmer
،2013 ،Hoboken: Wiley ،Sturdivant, R. X.
- [13] "Greedy function approximation: A gradient boosting machine" ،J. H. Friedman
،2001 ،pp. 1189-1232 ،*The Annals of Statistics*
- [14] ،2022 ،Cham: Springer ،Computer Vision: Algorithms and Applications ،R. Szeliski
- [15] ،2015 ،pp. 436-444 ،*Nature* "،Deep learning " ،G. Hinton و Y. Bengio ،Y. LeCun
- [16] "BPLight- ،D. Sahoo و R. Mahapatra ،S. Pasricha ،S. V. R. Chittamuru ،D. Dang
،CNN: A photonics-based backpropagation accelerator for deep learning
،2021 ،pp. 1-26 ،*Journal on Emerging Technologies in Computing Systems (JETC)*
- [17] "،Deep residual learning for image recognition" ،J. Sun و S. Ren ،X. Zhang ،K. He
Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR) ،2016 ،778-770 ،

- [18] "Comparing some Machine Learning ,N. M. Ahmed , S. N. Mohammad Ali
 .2025 ,p. 7 ,*GPMSJ. Med. Sci*",Models for Cardiovascular Disease
- [19] D. D. Siva , G. Durgesh Babu ,K. Vijendra ,K. Satya Vijay Ram ,D. Ratna Giri
International ","Detection of Cardiovascular Diseases through ECG Images ,Ganesh
 ,pp. 72–78 ,*Journal of Innovative Research in Computer Science and Technology*
 .2025
- [20] "Predicting the prevalence of cardiovascular ,M. C. M. A. S. M. Bernada E. Sianga
 ,p. 11 ,*Intelligence–Based Medicine* ",diseases using machine learning algorithms
 .2025
- [21] "Cardiologist–level arrhythmia detection and classification in ,A. Y. e. a. Hannun
 pp. ,*Nature Medicine* ",ambulatory electrocardiograms using a deep neural network
 .2019 ,65–69
- [22] M. , S. Karimi ,M. Eljamili ,M. I. Rhoujati ,H. Nabawi ,R. Zerhoudi ,B. Maatof
 ", "Is there an Electro–Angiographic Correlation in RD Infarction? ,Elhattaoui
 .2023 ,pp. 1–7 ,*Cardiology and Angiology: An International Journal*
- [23] ", "Look before you place: A bizarre ECG artifact due to lead placement ,J. Brock
 .2023 ,*American Journal of Emergency Medicine*
- [24] "Cardiac Classification with Multi–Scale Convolutional ,G. Peng ,J. Yi ,X. Cheng
 .2025 , " medRxiv,Neural Network From Paper ECG
- [25] .2022 ,Cham: Springer ,Computer Vision: Algorithms and Applications ,R. Szeliski
- [26] ,Cambridge: MIT Press ,Deep Learning ,A. Courville , Y. Bengio ,I. Goodfellow
 .2016
- [27] .2015 ,pp. 436–444 ,*Nature* ", "Deep learning ,G. Hinton , Y. Bengio ,Y. LeCun

- [28] "The perceptron: A probabilistic model for information storage and organization in the brain", F. Rosenblatt, 1958, pp. 386–408, *Psychological Review*.
- [29] "Very deep convolutional networks for large-scale image recognition", A. Zisserman, K. Simonyan, *Proceedings of the International Conference on Learning Representations (ICLR)*, 2015.
- [30] "Densely connected convolutional networks", K. Q. Weinberger, L. Van Der Maaten, Z. Liu, G. Huang, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, 2269–2281.
- [31] "EfficientNet: Rethinking model scaling for convolutional neural networks", Q. V. Le, M. Tan, *Proceedings of the International Conference on Machine Learning (ICML)*, 2019.

